

THESE DOCTORALE

Universite Paris-Sorbonne

Master 2 Intelligence Economique - Intelligence Warfare

AI FOR AMERICANS FIRST

Protectionnisme IA, Energie et Semi-conducteurs :

Trajectoires de divergence US/Europe 2024-2030

Analyse geostrategique et economique integree

**76,9 pct compute IA
operationnel mondial = USA**

**1,59x cout energie EU/US
(ajuste-PPA)**

**3,46:1 ratio CACI US/EU (Power
Mode)**

Fabrice Pizzi

(handle mo0ogly)

Paris - fevrier 2026

11 chapitres | 4 scenarios prospectifs | 4 zones geographiques (Europe, Amerique du Sud, Asie, Afrique) | 108 figures

Mots-cles : intelligence artificielle, protectionnisme technologique, semi-conducteurs, controles a l'exportation, compute souverain, geopolitique IA, France, Etats-Unis, Chine.

Resume executif

Cette these analyse l'emergence d'un regime protectionniste IA americain (decret implicite AI for Americans First) et ses consequences geostrategiques pour la France, l'Europe, et le reste du monde sur la periode 2024-2030. L'etude mobilise un appareil empirique original (tableau de bord public Epoch AI snapshot avril 2026) et propose un cadre theorique unifie (indice CACI - Compute-Adjusted Competitive Index) integrant FLOPs, capital humain, regulation et cout energetique selon une formule geometrique ponderee.

Sur le snapshot avril 2026, les Etats-Unis concentrent 76,9 pour cent du compute IA operationnel mondial. Le ratio brut compute installe US/UE(13) atteint 17,6:1, traduit par la formule geometrique CACI Power Mode ($F^{0,40} \times L^{0,20} \times R^{0,15} / E^{0,25}$) en un ratio US/UE de 3,46:1. La decomposition Phys/Sov rigoureusement calculee a partir du champ Owner d'Epoch AI revele un cas extreme : 99,6 pct du F_{total} emirati est detenu par des operateurs US-side, faisant chuter le CACI souverain emirati de 55,7 (Physique) a 6,0. L'UE, en revanche, est largement souveraine sur son F installe (99,2 pct). La vulnerabilite europeenne se situe non sur le compute installe mais sur la couche operationnelle des charges cloud (majoritairement hebergees sur AWS/Azure/GCP).

Quatre scenarios prospectifs 2026-2030 sont developpes (Statu quo, Fracture, Partenariat asymetrique, Souverainete subie), avec un point de basculement identifie en 2028 a la convergence de la saturation compute/energie UE et de l'activation potentielle des Cloud Sovereignty Mandates US. La fenetre d'action strategique 2026-2028 est etroite : apres cette date, les positions se cristallisent autour de la baseline 17,6:1 brut / 3,46:1 CACI Power Mode.

Les recommandations strategiques s'articulent en cinq axes (compute, energie, alliances, regulation, talent) sur trois horizons (2026-2027, 2027-2029, 2029-2032). La France dispose d'avantages distinctifs (parc nucleaire 70 pct du mix, cout PPA 1,35x USA, Mistral AI valorise 11,7 milliards EUR, ASML partenaire industriel) qui en font le pilier credible d'une trajectoire d'autonomie strategique ciblee - ni alignement total (Japon : 550 milliards USD investis aux US), ni confrontation (Chine : 246-300 EFLOP/s sous restriction), ni hesitation (Bresil : double bind US/Chine). L'enjeu n'est pas l'autarcie mais la capacite de choix.

Table des matieres

1. Chapitre I - Introduction et cadrage theorique
2. Chapitre II - Methodologie
3. Chapitre III - Diagnostic empirique 2020-2026
4. Chapitre IV - Mecanismes de l'avantage concurrentiel US
5. Chapitre V - Scenarios prospectifs 2026-2030
6. Chapitre VI - Consequences pour la France et l'Europe
7. Chapitre VI bis - Consequences pour l'Amerique du Sud et le Bresil
8. Chapitre VI ter - Consequences pour l'Asie
9. Chapitre VI quater - Consequences pour l'Afrique
10. Chapitre VII - Recommandations strategiques
11. Conclusion generale

Note : une table des matieres dynamique (avec sous-sections et numeros de page) est integree ci-dessous. Sous Microsoft Word, faire Ctrl+A puis F9 pour la mettre a jour. Sous LibreOffice, faire clic-droit sur la table et choisir 'Mettre a jour l'index'.

CHAPITRE I - INTRODUCTION ET CADRAGE THEORIQUE

CHAPITRE I

Introduction et cadrage theorique

1.1 Question de recherche

L'intelligence artificielle reconfigure les fondations de la competitivite economique mondiale. Depuis le lancement de ChatGPT en novembre 2022 et l'acceleration spectaculaire des investissements dans les modeles de fondation, l'IA generative s'est imposee comme un facteur transformateur transversal de l'economie, affectant simultanement la finance, l'industrie, la sante, les transports et les services. Or cette transformation repose sur un substrat materiel precis : une capacite de calcul considerable, alimentee par des semi-conducteurs de pointe et une energie electrique abondante. La maitrise de ce triptyque - compute, puces, energie - est devenue un enjeu geostrategique de premier ordre.

Dans ce contexte, les Etats-Unis ont progressivement erige un regime de controle sur l'accès aux technologies IA de frontiere. Des octobre 2022, le Bureau of Industry and Security (BIS) du Department of Commerce a impose des restrictions a l'exportation des GPU avances vers la Chine. En janvier 2025, l'administration Biden a etendu ces controles a plus de 120 pays via l'AI Diffusion Rule, creant un systeme de segmentation par paliers conditionnant l'accès aux puces IA les plus puissantes au degre d'alignement geopolitique avec Washington. L'administration Trump, entree en fonction en janvier 2025, a remplace ce cadre par une approche plus explicitement competitive, culminant en juillet 2025 avec la publication du America's AI Action Plan, puis en janvier 2026 avec l'imposition de tarifs de 25 pour cent sur certains semi-conducteurs IA avances (Nvidia H200, AMD MI325X) au titre de la Section 232.[1]

Ces mesures, officiellement motivees par des imperatifs de securite nationale, produisent de facto un avantage competitif structurel pour les entreprises americaines : elles beneficent d'un acces illimite au compute de frontiere, tandis que les acteurs d'autres regions - y compris les allies europeens - voient leurs capacites plafonnees, rencheries ou conditionnees. Nous assistons ainsi a l'emergence d'un nouveau type de protectionnisme technologique, ou la taxe n'est pas seulement tarifaire mais egalement reglementaire, logistique et strategique.

Cette etude pose la question suivante : dans quelle mesure le protectionnisme technologique americain sur l'IA - controles a l'exportation, tarifs, priorisation du compute domestique - cree-t-il une divergence structurelle de competitivite entre les Etats-Unis et l'Europe, et quelles en sont les consequences mesurables pour la France a l'horizon 2030 ?

Cette question de recherche se decompose en trois sous-questions articulant les dimensions empirique, prospective et normative de l'analyse :

(a) Quel est l'ecart actuel de capacite de calcul IA (compute gap) entre les Etats-Unis et l'Union europeenne, et comment cet ecart evolue-t-il selon differents scenarios de politique commerciale et technologique americaine ?

(b) Comment l'asymetrie d'accès au compute se traduit-elle en productivite sectorielle, en couts d'entrainement des modeles et en parts de marche dans les services IA ?

(c) Les contraintes energetiques europeennes et la montee de la robotique IA amplifient-elles la divergence, et la France peut-elle mobiliser son avantage nucleaire pour mitiger ce desavantage structurel ?

L'originalite de cette etude reside dans son approche integree. La litterature existante traite separement les controles a l'exportation (Carnegie Endowment, CSIS, Hudson Institute), les projections energetiques des centres de donnees (AIE), la dynamique du marche des semi-conducteurs (McKinsey, SIA, Deloitte), la souverainete du compute (Hawkins, Lehdonvirta et Wu, 2025) et les barrieres concurrentielles liees a l'IA (Bruegel, OCDE). Aucun travail ne propose la trajectoire causale complete que nous cherchons a etabliir ici : protectionnisme americain puis restriction du compute europeen puis divergence de productivite puis dependance strategique, avec l'energie et la robotique comme facteurs amplificateurs.

1.2 Definitions operationnelles

L'analyse deployee dans cette etude repose sur un ensemble de concepts qui requierent une definition rigoureuse, leur usage variant selon les contextes disciplinaires.

Compute de frontiere. Nous definissons le compute de frontiere comme la capacite de calcul installee sous forme d'accelerateurs IA - GPU (Nvidia A100, H100, H200, B200), ASIC (Google TPU) ou circuits specialises - deployes dans des centres de donnees a l'echelle industrielle. Cette capacite se mesure en FLOPs (operations en virgule flottante par seconde) agreges au niveau national ou regional, en H100-equivalents (la metrique utilisee par le jeu de donnees Epoch AI), ou en GW de charge IT. Le compute de frontiere constitue l'intrant fondamental du developpement et du deploiement de l'IA de frontiere : sans lui, il est impossible d'entrainer des modeles de fondation competitifs ou d'operer des services d'inference a grande echelle.

Protectionnisme technologique IA. Le protectionnisme technologique IA designe l'ensemble des mesures etatiques - controles a l'exportation, tarifs, quotas, licences d'exportation, priorisation logistique, restrictions sur les poids de modeles et les API - qui creent une asymetrie d'accès au compute, aux modeles et aux services IA entre regions geographiques. Ce concept etend la notion classique de protectionnisme commercial en integrant la dimension immaterielle (logiciels, modeles, services cloud) et la dimension infrastructurelle (energie, capacites de production de puces). A la difference des barrieres tarifaires traditionnelles, le protectionnisme technologique IA peut operer par des canaux non tarifaires - par exemple en priorisant les livraisons de GPU aux entreprises domestiques en contexte de penurie mondiale.

Compute gap. Le compute gap mesure le ratio de capacite de calcul IA effectivement disponible entre deux regions. Nous le definissons comme le ratio entre les FLOPs IA installes et accessibles (ou H100-equivalents) pour les acteurs economiques de la region A et ceux de la region B, normalise par la population active ou le PIB. Un compute gap de x15 entre les Etats-Unis et l'UE signifie que, par unite de PIB, les acteurs americains

disposent de quinze fois plus de puissance de calcul IA que leurs homologues européens. Ce ratio constitue un indicateur synthétique de l'avantage structurel en IA.

Souveraineté du compute. Nous adoptons la définition proposée par Hawkins, Lehdonvirta et Wu (2025), qui décomposent la souveraineté du compute en trois niveaux : (1) la quantité de compute IA physiquement présente sur le territoire national, (2) la nationalité des entreprises propriétaires des centres de données, et (3) la nationalité des fournisseurs d'accélérateurs dont les puces alimentent ces centres.[2] Un pays peut disposer d'une capacité de calcul significative sur son sol tout en étant dépendant d'opérateurs et de fournisseurs étrangers, ce qui limite sa souveraineté réelle. Ce concept est essentiel pour comprendre pourquoi la présence de centres AWS ou Azure en Europe ne constitue pas, en soi, une forme de souveraineté européenne sur le compute.

Vendor lock-in géopolitique. Nous proposons le concept de vendor lock-in géopolitique pour désigner la dépendance structurelle d'un écosystème économique à des fournisseurs technologiques étrangers dont l'accès peut être restreint, renchéri ou conditionné par décision politique d'un gouvernement tiers. Ce concept étend la notion classique de vendor lock-in informatique (coûts de migration entre fournisseurs cloud, par exemple) en y ajoutant une dimension géopolitique : le risque que l'accès à une infrastructure critique soit utilisé comme levier de négociation entre États. L'épisode Starlink-Ukraine de mars 2025, où le contrôle américain d'un système de communication a été perçu comme un instrument de pression, illustre de façon saisissante ce type de risque.[3]

Compute-Adjusted Competitiveness Index (CACI). Nous construisons, comme indicateur original central de cette étude, un Compute-Adjusted Competitiveness Index combinant en un composite géométrique pondéré les quatre dimensions identifiées ci-dessus. Dans sa formulation absolue, dite Power Mode, l'indicateur s'écrit $CACI = F^{0,40} \times L^{0,20} \times R^{0,15} / E^{0,25}$, où F est le compute IA installé (H100-équivalents, total ou souverain), L est la main-d'œuvre pertinente (millions de travailleurs qualifiés en IA), R est un indice d'accès géopolitique (0 à 1) et E est le prix moyen de l'électricité industrielle (USD par MWh). Les quatre exposants (40, 20, 15, 25) somment à un et reflètent l'importance relative attribuée au compute, au travail, à l'accès géopolitique et au coût de l'énergie. Une seconde formulation, dite Intensity Mode, divise le résultat par le PIB pour obtenir une densité de compétitivité par unité de richesse nationale. La dérivation méthodologique complète est présentée au chapitre II et l'indicateur est mis à jour en temps réel sur le tableau de bord public.[a]

Deux variantes de l'indicateur sont utilisées en parallèle. Le CACI physique intègre tout le compute physiquement présent sur le territoire (F_{total}), indépendamment de la propriété. Le CACI souverain restreint F au compute possédé et opéré par des acteurs domestiques (F_{dom}), capturant ainsi l'autonomie souveraine effective. L'écart entre les deux variantes mesure la dépendance structurelle d'une région aux hyperscalers étrangers. Pour l'Union européenne, cet écart constitue la mesure quantitative la plus directe de la vulnérabilité stratégique que cette étude cherche à caractériser.

1.3 Cadre théorique

Notre analyse s'enracine dans quatre courants theoriques complementaires, qui fournissent les outils conceptuels necessaires pour articuler les dimensions technologique, economique et geopolitique du phenomene etudie.

1.3.1 L'IA comme General Purpose Technology

Le premier ancrage theorique est la theorie des General Purpose Technologies (GPT) formalisee par Bresnahan et Trajtenberg (1995). Une GPT est une technologie caracterisee par trois proprietes : sa pervasivite (elle est utilisee comme intrant dans de nombreux secteurs en aval), son potentiel inherent d'amelioration technique, et ses complementarites d'innovation (la productivite R&D dans les secteurs utilisateurs croit en consequence de l'amelioration de la GPT).[4] Le modele predit que les GPT generent des rendements d'echelle croissants et que leur diffusion dans l'economie est source de gains de productivite generalises. Toutefois, Bresnahan et Trajtenberg soulignent egalement qu'une economie decentralisee peut peiner a exploiter pleinement le potentiel d'une GPT, les transactions de marche entre le producteur de GPT et ses utilisateurs pouvant conduire a une innovation insuffisante et tardive.

Brynjolfsson, Rock et Syverson (2019) ont applique ce cadre a l'IA contemporaine, demontrant que l'IA, et en particulier le machine learning, satisfait les trois criteres de Bresnahan et Trajtenberg pour etre qualifiee de GPT.[5] Leur modele de productivity J-curve explique pourquoi les gains de productivite lies a une GPT peuvent etre initialement invisibles dans les statistiques : les entreprises doivent d'abord investir massivement dans des actifs intangibles (reorganisation, formation, reingenierie des processus) avant d'en recolter les benefices.

Ce cadre est fondamental pour notre analyse car il implique que l'acces precoce et massif au compute IA - c'est-a-dire la capacite a investir dans la GPT a grande echelle des les premieres phases de deploiement - genere des avantages cumulatifs difficilement reversibles. Les complementarites d'innovation creent une dynamique de path dependence : les acteurs qui accedent tot a un compute abondant developpent des modeles superieurs, captent des donnees d'usage, generent des revenus qu'ils reinvestissent dans le compute, et creusent ainsi un ecart qui s'auto-renforce dans le temps. Toute politique restreignant l'acces au compute pour une region donnee a donc des consequences non lineaires : elle ne fait pas que retarder l'adoption, elle la compromet structurellement.

1.3.2 Interdependance armee et controle des reseaux mondiaux

Le deuxieme ancrage theorique est la theorie de la weaponized interdependence developpee par Farrell et Newman (2019). Ces auteurs demontrent que les reseaux economiques mondiaux, loin de creer des relations symetriques d'interdependance mutuelle comme le postulait la theorie liberale classique, tendent a produire des structures asymetriques dans lesquelles certains noeuds (hubs) deviennent bien plus connectes que d'autres. Les Etats exerçant une juridiction politique sur ces noeuds centraux peuvent les instrumentaliser a des fins coercitives, via deux mecanismes : l'effet panopticon (collecte d'informations strategiques) et l'effet chokepoint (capacite de couper ou de restreindre les flux).[6]

L'application a la chaine de valeur IA est remarquablement pertinente. Les Etats-Unis controlent plusieurs chokepoints critiques : la conception des accelerateurs IA (Nvidia detient plus de 80 pour cent du marche

GPU pour centres de données), l'infrastructure cloud (AWS, Azure et Google Cloud représentent environ 70 pour cent du marché mondial) et les modèles de fondation les plus avancés (OpenAI, Anthropic, Google DeepMind). Le contrôle de ces chokepoints permet au gouvernement américain de moduler l'accès mondial au compute IA comme un levier géopolitique, exactement comme le système SWIFT a été utilisé comme levier dans le domaine financier. Farrell et Newman ont eux-mêmes reconnu, dans une mise à jour publiée dans *Foreign Affairs* en décembre 2025, que les semi-conducteurs et l'IA étaient devenus un terrain d'application majeur pour leur théorie, l'administration Trump ayant explicitement utilisé les contrôles à l'exportation sur les puces IA comme monnaie d'échange dans les négociations avec la Chine.[7]

1.3.3 Economie de la concentration et rentes d'innovation

Le troisième ancrage théorique mobilise la littérature sur la concentration des marchés numériques et les barrières à l'entrée dans l'écosystème IA. Martens (2024), dans un policy brief pour Bruegel, démontre que les coûts d'entraînement des modèles de fondation croissent exponentiellement, constituant une barrière à l'entrée insurmontable pour la plupart des acteurs.[8] Il estime qu'une ferme de calcul de l'ordre du trillion de dollars est concevable à moyen terme, un seuil d'investissement totalement hors de portée du financement public et de la grande majorité des entreprises. Seules les GAFAM (Google, Apple, Meta, Microsoft, Amazon, Nvidia) disposent des ressources pour y accéder.

L'OCDE (2025) confirme cette analyse dans son rapport sur la concurrence dans l'infrastructure IA, identifiant des barrières à l'entrée à plusieurs niveaux de la chaîne d'approvisionnement : exigences capitalistiques extrêmement élevées, économies d'échelle massives, coûts de switching entre fournisseurs et absence de standards d'interopérabilité.[9] La Federal Reserve Board (octobre 2025), dans une analyse comparative de la compétitivité IA dans les économies avancées, montre que les États-Unis concentrent plus de 75 pour cent de l'investissement mondial en venture capital dans l'IA générative, et que l'Europe accuse un retard significatif non seulement en investissement mais aussi en adoption d'entreprise, les coûts énergétiques élevés constituant un frein supplémentaire.[10]

Cette dynamique de concentration a une conséquence directe pour notre analyse : le protectionnisme technologique américain ne se contente pas de limiter l'accès européen au compute, il renforce la position des acteurs dominants qui sont précisément ceux qui bénéficient de l'exemption domestique. C'est un mécanisme de double avantage : réduction des contraintes pour les entreprises américaines, augmentation des contraintes pour leurs concurrentes.

1.3.4 Souveraineté numérique et autonomie stratégique européenne

Le quatrième ancrage théorique mobilise le courant européen de la souveraineté numérique, analysé notamment par Mugge (2024) dans le *Journal of European Public Policy*. Mugge identifie trois tensions fondamentales dans l'ambition de souveraineté IA européenne : la souveraineté oppose-t-elle l'UE aux autres puissances IA, ou les citoyens aux grandes plateformes ? Vise-t-elle la compétitivité économique ou la protection des droits ? Et qui en bénéficie réellement - les champions européens ou l'écosystème entier ? [11] Ces tensions sont précisément celles que le protectionnisme américain exacerbe : en comprimant l'espace de souveraineté technologique européen, il force l'UE à arbitrer entre ces objectifs contradictoires dans un contexte d'urgence.

Hawkins, Lehdonvirta et Wu (2025) apportent une contribution empirique decisive en mesurant la souverainete du compute a travers l'infrastructure des neuf principaux fournisseurs cloud mondiaux, qui representent environ 70 pour cent du marche mondial. Leurs resultats revelent que le degre de souverainete varie considerablement selon le niveau d'analyse (territorial, corporate ou hardware), et que la plupart des pays europeens presentent un deficit de souverainete sur au moins deux de ces trois niveaux.[12] McKinsey (decembre 2025) estime l'opportunit  IA souveraine europeenne a 480 milliards d'euros par an a l'horizon 2030, conditionnelle a un scenario de souverainete technologique forte combine a une adoption IA elevee. [13]

1.4 Revue de litterature ciblee et identification du gap

L'etat de la litterature en fevrier 2026 revele un champ de recherche en formation rapide, mais qui demeure tres fragmente. Nous identifions cinq corpus principaux, chacun couvrant une dimension de notre question de recherche.

Corpus 1 : Controles a l'exportation et geopolitique IA. Le Carnegie Endowment for International Peace fournit l'analyse la plus detaillee de la politique americaine de controle a l'exportation IA. Winter-Levy et Phillips-Robins (mai 2025) ont decrit l'AI Diffusion Rule de Biden comme un compromis entre trois objectifs - controle, promotion et levier geopolitique - et analyse les options de remplacement sous Trump.[14] Le CSIS, le Hudson Institute et Pillsbury Law ont documente les mecanismes legaux et les developpements recents, notamment les tarifs Section 232 de janvier 2026. Contrary Research (novembre 2025) propose une analyse particulierement riche du dilemme temporel sous-jacent : si l'AGI est a cinq ans, les controles a l'exportation renforcent la domination americaine ; si elle est a dix ans ou plus, ils accelerent l'autonomisation technologique chinoise.[15]

Corpus 2 : Energie et infrastructure des centres de donnees. Le rapport special Energy and AI de l'AIE (avril 2025) constitue la reference mondiale en matiere de projections energetiques pour les centres de donnees. Il etablit que la consommation electrique mondiale des centres de donnees atteindra 945 TWh en 2030 dans le scenario central, contre 415 TWh en 2024, l'IA etant le principal moteur de cette croissance.[16] Aux Etats-Unis, les centres de donnees consommeront plus d'electricite que toute l'industrie energo-intensive combinee a l'horizon 2030. En Europe, la croissance sera de plus 45 TWh (plus 70 pour cent), avec un risque de retard sur environ 20 pour cent des projets lie aux contraintes du reseau electrique. L'AIE-4E a publie en parallele une revue critique des modeles d'estimation, soulignant l'ampleur des incertitudes (les projections 2030 varient d'un facteur 40 selon les etudes).[17]

Corpus 3 : Marche des semi-conducteurs. McKinsey (janvier 2026) a revise significativement a la hausse ses estimations de la taille du marche des semi-conducteurs en integrant les concepteurs captifs (Apple, Amazon, Tesla) et les operateurs fabless dont la valeur n'appara t pas dans les statistiques traditionnelles. Leur estimation centrale passe de 775 milliards USD en 2024 a 1 600 milliards USD en 2030, soit un TCAM de 13 pour cent.[18] La SIA rapporte des ventes record de 627,6 milliards USD en 2024, tandis que Deloitte (fevrier 2026) anticipe que les puces IA generatives representent a elles seules pres de la moitie du chiffre d'affaires du secteur en 2026.[19]

Corpus 4 : Souverainete et competitivite IA europeennes. Plusieurs publications recentes documentent le deficit europeen. Le Parlement europeen (2025) constate que seules 11 pour cent des petites entreprises europeennes utilisent l'IA, contre 58 pour cent des petites entreprises americaines.[20] Accenture (novembre 2025) rapporte que 62 pour cent des organisations europeennes recherchent des solutions souveraines face a l'incertitude geopolitique, mais seulement 19 pour cent y voient un avantage competitif. La majorite (48 pour cent) est motivee par des obligations de conformite reglementaire, suggerant une approche defensive plutot que strategique.[21] Le rapport Draghi (septembre 2024) sur la competitivite europeenne avait deja identifie le deficit d'investissement numerique comme un facteur structurel du declin europeen.

Corpus 5 : Barrieres concurrentielles et concentration. Bruegel, l'OCDE et la Federal Reserve Board convergent sur le constat d'une concentration croissante de l'ecosysteme IA autour d'un petit nombre d'acteurs. Le rapport CERRE (juin 2025) sur la politique de concurrence pour le cloud et l'IA identifie des barrieres a la migration, des pratiques de cloud credits susceptibles de creer du lock-in, et une dependance croissante des petits developpeurs IA aux hyperscalers pour l'acces au compute accelere.[22] La collaboration structurelle entre startups IA et Big Tech, illustree par l'accord Mistral-Microsoft, temoigne de cette dependance.

Le gap que cette etude entend combler. L'examen de ces cinq corpus revele un espace analytique non couvert : aucune etude ne propose une trajectoire integree liant le protectionnisme technologique americain a la divergence de competitivite UE via le triptyque compute-energie-semi-conducteurs. Les travaux existants traitent chaque dimension isolement - controles a l'exportation sans energie, energie sans semi-conducteurs, semi-conducteurs sans productivite. Par ailleurs, l'angle specifique de la robotique IA comme amplificateur de la demande energetique est quasiment absent de la litterature. C'est precisement ce gap que notre etude entend combler, en proposant un cadre analytique unifie et un indicateur original - le Compute-Adjusted Competitiveness Index (CACI) - permettant la mesure et la projection de cette divergence. L'indicateur et le jeu de donnees sous-jacent sont accessibles publiquement et mis a jour en temps reel sur le tableau de bord du projet.[a]

1.5 Structure du rapport

Le rapport est organise en huit chapitres. Apres cette introduction, le chapitre II presente la methodologie, detaillant l'approche multi-scenarios, les sources de donnees, la construction du CACI et les limites methodologiques. Le chapitre III etablit le diagnostic empirique 2020-2026, couvrant les trajectoires energetiques, le marche des semi-conducteurs, le compute installe et la chronologie des controles a l'exportation. Le chapitre IV analyse les mecanismes de l'avantage competitif americain. Le chapitre V presente quatre scenarios 2026-2030 structures autour de deux axes d'incertitude. Le chapitre VI detaille les consequences pour la France et l'Europe, differenciees par type d'acteur et par secteur. Le chapitre VII formule des recommandations strategiques a trois horizons temporels. Le chapitre VIII conclut en synthetisant les apports de l'etude et en identifiant des pistes de recherche futures.

Notes

1. Pillsbury Law (2026), 'Trump Admin Targets Advanced AI Semiconductors, Defers Broader Tariffs,' January 15, 2026. The Section 232 proclamation imposes a 25 percent tariff on logic integrated circuits meeting specific technical parameters (TTP > 14,000, DRAM bandwidth > 4,500 GB/s), covering notably Nvidia H200 and AMD MI325X destined for re-export.
2. Hawkins, Z.J., Lehdonvirta, V. and Wu, B. (2025), 'AI Compute Sovereignty: Infrastructure Control Across Territories, Cloud Providers and Accelerators,' SSRN, June 2025, <https://ssrn.com/abstract=5312977>
3. Carnegie Endowment for International Peace (2025), 'The EU AI Power Play: Between Deregulation and Innovation,' May 2025. See also the March 2025 revelation on the use of Starlink as a pressure lever on Ukraine.
4. Bresnahan, T.F. and Trajtenberg, M. (1995), 'General Purpose Technologies Engines of Growth?,' *Journal of Econometrics*, 65(1), pp. 83-108.
5. Brynjolfsson, E., Rock, D. and Syverson, C. (2019), 'Artificial Intelligence and the Modern Productivity Paradox: A Clash of Expectations and Statistics,' in Agrawal, Gans and Goldfarb (eds.), *The Economics of Artificial Intelligence*, University of Chicago Press, pp. 23-57. See also Brynjolfsson, Rock and Syverson (2021), 'The Productivity J-Curve,' *American Economic Journal: Macroeconomics*, 13(1), pp. 268-320.
6. Farrell, H. and Newman, A.L. (2019), 'Weaponized Interdependence: How Global Economic Networks Shape State Coercion,' *International Security*, 44(1), pp. 42-79. doi:10.1162/isec_a_00351
7. Farrell, H. and Newman, A.L. (2025), 'The Weaponized World Economy: Surviving the New Age of Economic Coercion,' *Foreign Affairs*, December 2025.
8. Martens, B. (2024), 'Why artificial intelligence is creating fundamental challenges for competition policy,' *Bruegel Policy Brief* 16/2024.
9. OECD (2025), 'Competition in Artificial Intelligence Infrastructure,' https://www.oecd.org/en/publications/competition-in-artificial-intelligence-infrastructure_623d1874-en.html
10. Federal Reserve Board (2025), 'The State of AI Competition in Advanced Economies,' *FEDS Notes*, October 6, 2025.
11. Mugge, D. (2024), 'EU AI sovereignty: for whom, to what end, and to whose benefit?,' *Journal of European Public Policy*, 31(8), pp. 2200-2225. doi:10.1080/13501763.2024.2318475
12. Hawkins, Lehdonvirta and Wu (2025), op. cit.
13. McKinsey (2025), 'Accelerating Europe AI Adoption: The Role of Sovereign AI Capabilities,' December 2025.
14. Winter-Levy, S. and Phillips-Robins, A. (2025), 'The Trump Administration May Be About to Repeal the AI Diffusion Rule. Here Is What It Should Do Next,' *Carnegie Endowment*, May 8, 2025.
15. Contrary Research (2025), 'Deep Dive: Export Controls and the AI Race,' November 6, 2025. <https://research.contrary.com/report/drawing-geopolitical-boundaries>
16. IEA (2025), 'Energy and AI,' special report, April 10, 2025. <https://www.iea.org/reports/energy-and-ai>
17. IEA-4E (2025), 'Data Centre Energy Use: Critical Review of Models and Results.'
18. McKinsey (2026), 'Hiding in Plain Sight: The Underestimated Size of the Semiconductor Industry,' January 2026.
19. Deloitte (2026), '2026 Semiconductor Industry Outlook,' February 2026. SIA (2025), 2024 sales = 627.6 billion USD (WSTS).
20. European Parliament (2025), 'Making Europe an AI Continent,' *EPRS BRI(2025)775923*. EU large enterprise AI adoption: 41 percent vs 11 percent for small ones. US small business adoption: 58 percent (US Chamber of Commerce, August 2025).
21. Accenture (2025), 'Europe Seeking Greater AI Sovereignty,' November 3, 2025. Survey of 1,928 organizations in 28 countries.
22. CERRE / Meyers, Z. (2025), 'A Competition Policy for Cloud and AI,' *Issue Paper*, June 2025.
23. [a] Public dashboard: <https://moOogly.github.io/America-First-IA/dashboard/>. Working Paper: https://moOogly.github.io/America-First-IA/pdf/Working_Paper_CACI_AI_Competitiveness.pdf. The CACI Power Mode formula $F^{0.40} \times L^{0.20} \times R^{0.15} / E^{0.25}$ reproduces the live calculation; the headline ratio of 3.46:1 between USA and EU (aggregated) is computed on the live dataset as of April 2026.

CHAPITRE II - METHODOLOGIE

CHAPITRE II

Methodologie

2.1 Approche generale : analyse prospective multi-scenarios mixte

Cette etude combine une analyse empirique retrospective (diagnostic 2020-2026) avec une projection prospective par scenarios (2026-2030). Cette architecture a deux volets repond a la nature du phenomene etudie : le protectionnisme technologique IA est simultanement un fait observable (controles a l'exportation, tarifs Section 232) et un processus en cours dont la trajectoire future depend de variables politiques discretionnaires, des reponses strategiques europeennes et de developpements technologiques partiellement imprevisibles.

Le volet retrospectif emploie une methode quantitative descriptive, fondee sur l'agregation et le croisement de donnees issues de sources institutionnelles (AIE, SIA/WSTS, Eurostat, EIA), de rapports industriels (McKinsey, Deloitte, Epoch AI) et de documents reglementaires (Federal Register, BIS, Maison-Blanche). L'objectif est d'etablir un socle factuel rigoureux et source couvrant trois dimensions : la consommation energetique des centres de donnees, le marche des semi-conducteurs et la capacite de calcul IA installee par region.

Le volet prospectif s'appuie sur la tradition du scenario planning telle que formalisee par Schwartz (1991) et pratiquee chez Royal Dutch/Shell depuis les annees 1970.[1] Cette methode, appartenant a l'ecole Intuitive Logics (Bradfield et al., 2005), consiste a construire des scenarios plausibles et internement coherents - non pour predire l'avenir, mais pour explorer l'espace des possibles et evaluer la robustesse de differentes strategies face a des evolutions environnementales divergentes.[2] Elle est particulierement adaptee aux situations caracterisees par une forte incertitude politique et technologique, ou les modeles econometriques classiques atteignent leurs limites - ce qui est precisement le cas du protectionnisme technologique IA.

Justification du choix methodologique. Trois raisons fondent le choix de la methode des scenarios sur la modelisation econometrique pure. Premierement, les variables analytiques cles sont largement politiques et discretionnaires : la decision d'un president americain d'imposer ou non des quotas GPU a l'Europe ne peut etre modelisee par une fonction de regression. Deuxiemement, les interactions entre les dimensions energetique, technologique et geopolitique sont non lineaires et systemiques : une restriction sur les GPU peut, par effets de cascade, alterer les flux d'investissement energetique, les decisions de localisation des centres de donnees et la structure concurrentielle de secteurs entiers. Troisiemement, les donnees disponibles sur le compute installee par region sont partielles et heterogenes : aucune base publique unifiee de FLOPs IA par pays n'existe, ce qui rend prematuree une calibration econometrique rigoureuse.

La methode retenue combine donc la rigueur quantitative du diagnostic empirique (donnees sourcees, series temporelles, ratios mesurables) avec la flexibilite qualitative de la construction de scenarios, dans l'esprit de ce que Schoemaker (1995) appelle une heuristique disciplinee.[3] Les scenarios ne sont pas des previsions

probabilistes mais des recits strategiques coherents, chacun fonde sur des hypotheses explicites et developpant ses consequences a travers des metriques mesurables.

2.2 Sources de donnees : classification et evaluation critique

L'etude s'appuie sur trois categories de sources, dont la fiabilite et les biais potentiels doivent etre explicitement reconnus. Cette transparence methodologique est conforme aux recommandations du OECD/JRC Handbook on Constructing Composite Indicators (Nardo et al., 2008), qui prescrit la documentation systematique des sources, de leurs limites et de leurs biais dans toute construction d'indicateur composite.[4]

2.2.1 Sources primaires (documents officiels et reglementaires)

Cette categorie regroupe les textes normatifs ou institutionnels : proclamations presidentielles (Section 232), regles BIS (AI Diffusion Rule, Entity List), rapports AIE, publications du Parlement europeen (EPRS), donnees statistiques officielles (SIA/WSTS pour les semi-conducteurs, Eurostat et EIA pour l'energie, RTE pour la France). Ces sources offrent la plus haute fiabilite factuelle mais peuvent contenir des biais de cadrage institutionnel : l'AIE tend a privilegier les scenarios moderes, le Parlement europeen a souligner les risques pour la souverainete de l'UE.

2.2.2 Sources academiques et think tanks

Cette categorie inclut les articles a comite de lecture (Farrell et Newman, 2019 ; Bresnahan et Trajtenberg, 1995 ; Brynjolfsson et al., 2019 ; Mugge, 2024) et les publications de think tanks reconnus (Bruegel, Carnegie Endowment, CSIS, OCDE, Federal Reserve Board). Les premiers fournissent un ancrage theorique robuste ; les seconds proposent des analyses politiques empiriquement fondees mais potentiellement influencees par l'orientation ideologique de chaque institution. Nous privilegions le croisement de sources d'orientations differentes (Bruegel / Carnegie / Fed) pour limiter ce biais.

2.2.3 Sources industrielles et conseil

McKinsey, Deloitte, Accenture, Epoch AI et CFG Europe fournissent des donnees de marche, des projections sectorielles et des estimations de capacite indisponibles dans les sources publiques. Ces sources presentent un biais systematique potentiel : les cabinets de conseil ont interet a amplifier les tendances (pour justifier des missions de transformation) et les estimations de marche sont souvent optimistes. Nous attenuons ce biais en triangulant les chiffres avec les donnees institutionnelles et en signalant explicitement les divergences entre sources. Par exemple, les ventes de semi-conducteurs 2024 sont de 627,6 milliards USD selon la SIA (perimetre traditionnel) mais de 775 milliards USD selon McKinsey (perimetre elargi), un ecart de 24 pour cent refletant des differences methodologiques et non des incoherences.[5]

2.2.4 Donnees compute IA : le jeu de donnees Epoch AI GPU Clusters

Mesurer le compute IA installe par pays constitue le defi methodologique central de cette etude. Nous nous appuyons principalement sur le jeu de donnees Epoch AI GPU Clusters (Pilz, Rahman, Sanders et Heim, 2025), qui catalogue plus de 500 supercalculateurs et clusters GPU dans le monde pour la periode 2019-

2025.[6] Ce jeu de données, disponible sous licence ouverte Creative Commons Attribution, constitue la source la plus complète et la plus systématiquement documentée sur l'infrastructure mondiale de compute IA à ce jour. Il est utilisé comme référence par le Stanford AI Index Report (2025), par plusieurs rapports gouvernementaux et par des institutions telles qu'OpenAI et DeepMind.

Le jeu de données couvre pour chaque cluster : pays de localisation, type de puce (H100, A100, GB200, TPU, etc.), performance computationnelle en FLOP/s 16 bits, nombre d'équivalents H100, date de mise en service, secteur (privé/public), puissance électrique (MW) et coût matériel estimé. Cette granularité permet une agrégation par pays et par année, répondant directement aux besoins de notre variable $F(r)$ dans le CACI.

Limites du jeu de données Epoch AI. Trois limites doivent être soulignées. Premièrement, la couverture est estimée à 10-20 pour cent de la performance compute IA agréée mondiale (mars 2025), avec une hétérogénéité significative entre entreprises et types de puces : environ 20-37 pour cent des Nvidia H100, 12 pour cent des A100, mais moins de 4 pour cent des TPU Google et une fraction négligeable des puces custom d'AWS, Microsoft ou Meta.[7] Deuxièmement, les systèmes chinois sont anonymisés (noms retirés, valeurs arrondies à un chiffre significatif), limitant la précision analytique pour la Chine. Troisièmement, la localisation physique d'un cluster ne détermine pas l'accès : de nombreux clusters sont accessibles via des services cloud depuis d'autres pays.

Nous complétons ces données avec le Working Paper OCDE de Lehdonvirta, Wu, Hawkins et al. (octobre 2025), qui développe une méthodologie pour estimer la disponibilité du compute IA dans le cloud public par pays, en dénombant les régions cloud des principaux fournisseurs équipées d'accélérateurs IA (A100, H100, GB200) sur 39 économies.[8] Cette approche complémentaire distingue compute installé (Epoch AI) et compute accessible (OCDE), distinction cruciale pour le CACI.

2.3 Construction des scénarios

La construction des scénarios suit un protocole en quatre étapes, inspiré de la méthodologie de la matrice 2x2 (Schwartz, 1991 ; van der Heijden, 2004) et adapté au contexte géostratégique de l'IA.[9]

Étape 1 - Identification des forces motrices. Les éléments prédéterminés (dont l'évolution est raisonnablement prévisible quel que soit le scénario) incluent : la croissance continue de la demande mondiale de compute IA ; l'augmentation structurelle de la consommation énergétique des centres de données ; la dépendance européenne aux fonderies asiatiques et américaines pour les puces de pointe ; la concentration du cloud mondial autour de trois hyperscalers américains ; et l'augmentation exponentielle des coûts d'entraînement des modèles de frontière.

Les incertitudes critiques (dont l'évolution dépend de choix politiques, de réactions stratégiques ou de disruptions technologiques) sont regroupées selon deux dimensions. Dimension 1 - Intensité du protectionnisme technologique américain : cette dimension couvre un spectre allant du maintien des restrictions actuelles à un durcissement agressif (quotas GPU pour l'UE, restrictions sur les API et les modèles, priorisation explicite des livraisons aux entreprises américaines). Dimension 2 - Capacité de réponse européenne : cette dimension couvre un spectre allant d'une posture passive (adaptation marginale, acceptation de la dépendance) à une réponse active (Compute Zones avec énergie dérogatoire, AI

Factories accelerees, SMR nucleaires pour data centers, partenariats alternatifs Japon-Coree-Taiwan, revision de l'AI Act).

Etape 2 - Matrice 2x2 et generation des scenarios. Le croisement des deux dimensions d'incertitude genere une matrice a quatre scenarios. Le choix de quatre scenarios plutot que trois est delibere. Schwartz (1991) et les praticiens de la methode Shell recommandent de ne jamais construire trois scenarios, l'esprit humain ayant tendance a traiter le scenario median comme le plus probable, ce qui reduit l'utilite de l'exercice.[10] La matrice 2x2 force l'analyste a explorer les quadrants extremes - precisement ou se jouent les ruptures strategiques.

Etape 3 - Developpement narratif et quantification. Chaque scenario est developpe selon un protocole standardise comprenant trois composantes : un recit strategique decrivant la sequence plausible d'evenements entre 2026 et 2030 ; une quantification de metriques cles calibrees sur les donnees empiriques 2020-2026 et projetees selon les hypotheses du scenario ; et des indicateurs avances (leading indicators) permettant d'identifier, des 2026-2027, vers quel scenario la realite converge.

Etape 4 - Analyse de sensibilite et robustesse. Pour chaque recommandation formulee au chapitre VII, nous evaluons sa robustesse a travers les quatre scenarios. Une recommandation est consideree robuste si elle produit des resultats positifs ou neutres dans au moins trois des quatre scenarios.

2.4 Metriques cles et indicateur original : le CACI

Nous definissons six metriques a calculer ou estimer dans le diagnostic empirique (chapitre III), puis a projeter dans chaque scenario (chapitre V). Ensemble, elles forment un tableau de bord de la divergence US/UE en IA : M1 (compute gap, ratio US/UE des FLOPs IA installes normalise par le PIB), M2 (cout relatif du FLOP pour l'entrainement), M3 (dependance cloud, part des charges IA UE sur infrastructure US), M4 (productivite IA sectorielle), M5 (contrainte energetique, ratio demande/capacite des centres de donnees) et M6 (delocalisations IA).

2.4.1 Fondements theoriques du CACI

Ancrage dans la litterature. La construction d'un indicateur composite de competitivite IA centre sur le compute repond a un besoin identifie par plusieurs courants de recherche convergents. Depuis 2023-2024, la litterature academique et institutionnelle souligne de plus en plus que la capacite computationnelle est devenue le facteur de production le plus discriminant pour l'IA de frontiere (Sevilla et al., 2022 ; Epoch AI, 2025 ; Pilz et al., 2025). Les controles a l'exportation americains (BIS, octobre 2022 ; mises a jour 2023 et 2025) placent explicitement le compute avance au coeur de la competition geopolitique, tandis que Hawkins, Lehdonvirta et Wu (2025) introduisent le concept de souverainete du compute comme dimension structurante de l'autonomie strategique.[11]

Pourtant, les indices existants de competitivite IA ne placent pas le compute au centre de leur construction. L'AI Preparedness Index du FMI (Cazzaniga et al., 2024), couvrant 174 pays, agrege quatre dimensions (infrastructure numerique, capital humain, innovation/integration economique, regulation/ethique) sans mesurer directement la capacite de compute installee.[12] Le Global AI Index de Tortoise Media (2024),

classant 83 pays sur 122 indicateurs en trois piliers (Implementation, Innovation, Investment), inclut une composante infrastructure/supercalcul mais la subsume dans un indice additif pondere ou le compute n'est qu'un facteur parmi d'autres.[13] Le Stanford AI Index (2025) fournit des donnees riches sur les tendances compute mais ne propose aucun indice composite. Aucun de ces instruments ne formalise le mecanisme par lequel le compute, ajuste de son cout energetique et rapporte a la capacite d'absorption d'une economie, determine la competitivite IA.

Le CACI vise a combler ce gap en proposant un indicateur parcimonieux mais theoriquement fonde, qui capture l'interaction multiplicative entre quatre facteurs : compute accessible, main-d'oeuvre pertinente, conditions d'accès geopolitique et cout energetique.

2.4.2 Definition formelle

Le CACI pour une region r a la periode t est defini en deux modes complementaires. En Power Mode (absolu) : $CACI(r,t) = F(r,t)^{0,40} \times L(r,t)^{0,20} \times R(r,t)^{0,15} / E(r,t)^{0,25}$. En Intensity Mode (par unite de richesse nationale) : $CACI(r,t) = F(r,t)^{0,40} \times L(r,t)^{0,20} \times R(r,t)^{0,15} / (E(r,t)^{0,25} \times PIB(r,t))$.

$F(r,t)$ - capacite de compute IA installee et accessible en region r a la periode t . Nous agregeons le jeu de donnees Epoch AI GPU Clusters par pays, en H100-equivalents (la metrique utilisee par Epoch AI), complete par les estimations OCDE de compute cloud accessible. F admet deux specifications utilisees en parallele : F_{total} (tous les clusters localises sur le territoire, independamment de la propriete, definissant le CACI physique) et F_{dom} (clusters possedes et operes par des acteurs domestiques, definissant le CACI souverain).

$L(r,t)$ - population active avec competences IA (proxy : diplomes STEM plus formations IA certifiees plus densite des competences IA selon LinkedIn Economic Graph). Ce facteur capture la capacite d'absorption au sens de Cohen et Levinthal (1990) : un compute abondant sans capital humain pour l'exploiter ne produit pas de competitivite.[14]

$R(r,t)$ - indice d'accès geopolitique (entre 0 et 1) capturant la position du pays dans le regime des controles a l'exportation. $R = 1$ pour les Etats-Unis (accès illimite au compute de frontiere), $R = 0,95$ pour les allies Tier-1 proches (Royaume-Uni), $R = 0,9$ pour l'UE et la France (Tier-1 avec restrictions selectives), $R = 0,85$ pour l'Inde (Tier-2), $R = 0,7$ pour la Chine (fortement restreint).

$E(r,t)$ - cout energetique effectif moyen du compute en region r , en USD par MWh, ajuste des Power Purchase Agreements des hyperscalers. Les valeurs de reference du tableau de bord pour le snapshot d'avril 2026 sont USA 85, Chine 92, France 115, Allemagne 140, Royaume-Uni 190 USD/MWh. Ces chiffres correspondent aux prix ajustes PPA effectivement supportes par les centres de donnees, non aux tarifs Eurostat industriels bruts (qui sont typiquement plus eleves en Europe). Les couts effectifs UE dans ce perimetre PPA-ajuste sont 1,4 a 1,7 fois les niveaux US.[15]

$PIB(r,t)$ - produit interieur brut de la region r (Banque mondiale, Eurostat). Utilise uniquement en Intensity Mode pour normaliser entre economies de tailles tres differentes.

Justification de la forme multiplicative. Le choix d'une agregation multiplicative (geometrique) plutot qu'additive (arithmetique) est delibere et repose sur trois arguments. Premièrement, la theorie des General

Purpose Technologies (Bresnahan et Trajtenberg, 1995) postule une forte complementarité entre les intrants d'innovation : un compute sans énergie abordable ou sans capital humain qualifié ne produit pas de gains de compétitivité, justifiant une forme ou la faiblesse sur un facteur pénalise l'ensemble. Deuxièmement, le OECD/JRC Handbook (2008, p. 33) recommande l'agréation géométrique lorsque les composantes ne sont pas parfaitement substituables : contrairement à la moyenne arithmétique, la moyenne géométrique ne permet pas à un score très élevé sur une dimension de compenser pleinement un score très faible sur une autre. Troisièmement, des travaux récents sur la construction d'indices IA (Koronakos, Kritikos et Sotiros, 2024 ; analyse du GAI Tortoise via intégrale de Choquet) confirment que les dimensions de compétitivité IA présentent des interactions (complémentarités et redondances) qui rendent problématique l'agréation linéaire simple.[16]

Interprétation économique. En forme logarithmique, le CACI en Intensity Mode peut s'écrire $\ln(\text{CACI}) = 0,40 \ln(F) + 0,20 \ln(L) + 0,15 \ln(R) - 0,25 \ln(E) - \ln(\text{PIB})$. Cette transformation linéarise la relation et permet d'interpréter chaque coefficient comme une élasticité. L'indicateur est conçu pour la comparaison bilatérale : le ratio $\text{CACI}(\text{US})/\text{CACI}(\text{UE})$ mesure l'avantage compétitif relatif. Le snapshot d'avril 2026 donne un ratio de 3,46:1 en Power Mode (F_{total}) - c'est le chiffre principal de cette étude.

2.4.3 Protocole de calibration et sources de données

La calibration du CACI suit un protocole en quatre étapes cohérent avec les recommandations du OECD/JRC Handbook (2008) : identification et collecte des données brutes ; traitement des valeurs manquantes et normalisation ; agréation ; et analyse de sensibilité.

$F(r,t)$ - Capacité de compute IA installée. L'estimation suit une approche bottom-up. La couche principale provient du jeu de données Epoch AI GPU Clusters (version avril 2026), fournissant la performance en FLOP/s 16 bits et en équivalents H100 agréée par pays pour 2019-2026. Les parts nationales de compute opérationnel sur le snapshot d'avril 2026 sont : USA 76,9 pour cent, Chine 12,8 pour cent, UE (13 économies principales) 4,4 pour cent, Norvège 1,1 pour cent, Japon 1,0 pour cent.[17] Lorsque tous les clusters reportés sont inclus (opérationnels plus planifiés), la part US passe à environ 50 pour cent, le Golfe (EAU, Arabie saoudite) et la Corée captant une large part de la construction projetée 2027-2030. La couche complémentaire provient de l'OCDE (Lehdonvirta et al., 2025), cataloguant les régions cloud avec accélérateurs IA dans 39 économies, capturant la dimension d'accessibilité que le compute physiquement installé ne reflète pas pleinement.

Procédure d'agréation de F . Pour chaque couple pays-année, nous extrayons du jeu de données Epoch AI la somme des H100-équivalents de tous les clusters localisés dans le pays, en filtrant les systèmes confirmés (certitude supérieure ou égale à Likely) ; appliquons un facteur d'extrapolation pour corriger la sous-couverture du jeu de données (10 à 20 pour cent du compute mondial), en utilisant les estimations de couverture sectorielle d'Epoch AI par type de puce ; et ajoutons les capacités cloud accessibles estimées via la méthodologie OCDE pour les pays où le compute cloud étranger représente une part significative de la capacité effective. Les données brutes et le code de calcul (Python/pandas) sont documentés dans l'annexe méthodologique et sur le tableau de bord public.[18]

$E(r,t)$ - Cout energetique. Les valeurs de reference du CSV du tableau de bord utilisees dans cette etude, en USD par MWh et ajustees PPA, sont : USA 85, Chine 92, France 115, Allemagne 140, Royaume-Uni 190, Inde 88. Ces chiffres integrent les tarifs negociés pour grands consommateurs (PPA hyperscalers), en utilisant les estimations IEA (2025, Energy and AI) du mix energetique des centres de donnees par region. Ils sont systematiquement inferieurs aux tarifs Eurostat industriels bruts en Europe, parce que les PPA hyperscalers et le sourcing direct nucleaire/renouvelable reduisent materiellement le cout effectif supporte par les centres de donnees IA. La Federal Reserve Board (octobre 2025) documente une correlation negative significative entre couts energetiques et adoption IA au niveau des entreprises europeennes.[19]

$PIB(r,t)$ et $L(r,t)$. Le PIB est disponible aupres de la Banque mondiale (World Development Indicators) et d'Eurostat. Le snapshot d'avril 2026 du tableau de bord utilise les valeurs PIB en milliers de milliards USD : USA 29,3 ; Chine 18,7 ; UE 18,9 ; France 3,16 ; Allemagne 4,68 ; Royaume-Uni 3,6. Le proxy de capital humain IA $L(r,t)$ combine trois sous-indicateurs : nombre de diplomes STEM (OCDE, Education at a Glance) ; densite des competences IA mesuree par LinkedIn Economic Graph (profils avec competences IA rapportes a la population active) ; et certifications IA (estimations basees sur les programmes cloud certifies AWS/Google/Microsoft par pays). Le snapshot du tableau de bord utilise, en millions de travailleurs qualifies en IA : USA 3,5 ; Chine 4,8 ; UE 3,1 ; France 1,5 ; Allemagne 1,9 ; Royaume-Uni 1,8. Nous reconnaissons un biais favorisant les pays anglophones et les economies ou LinkedIn est dominant, et documentons l'effet de ce biais dans l'analyse de sensibilite (section 2.4.5).[20]

Normalisation du CACI et choix du benchmark. Le CACI brut produit des valeurs absolues heterogenes dont l'interpretation directe est difficile. Conformement a la pratique standard (Nardo et al., 2008 ; Saisana et Tarantola, 2002), nous appliquons une normalisation min-max au leader : le CACI normalise de chaque pays s'exprime en pourcentage du CACI brut des Etats-Unis, de sorte que $CACI_norm(USA) = 100$ par construction.

Ce choix de normalisation est methodologiquement fonde sur trois arguments. Premierement, les Etats-Unis constituent un benchmark naturel etant donne leur position dominante sur les quatre facteurs du CACI : 76,9 pour cent du compute IA operationnel mondial (Epoch AI, avril 2026), les couts energetiques industriels effectifs les plus bas parmi les grandes economies OCDE (85 USD/MWh, ajuste PPA, contre 115 en France et 140 en Allemagne - CSV du tableau de bord, avril 2026), le PIB nominal le plus eleve, et un ecosysteme de capital humain IA inegale. Deuxiemement, la normalisation au leader est la convention etablie pour les indices de competitivite relative : le RCA de Balassa (1965), le GCI du WEF (Schwab, 2019) et le Competitive Industrial Performance Index de l'ONUDI procedent tous par ratio au leader sectoriel ou national. Troisiemement, cette normalisation elimine les ambiguïtes d'interpretation des valeurs absolues et permet les comparaisons temporelles : un CACI France passant de 25 a 35 entre 2024 et 2028 signifie un rattrapage partiel, meme si les valeurs brutes des deux pays ont augmente.

La consequence methodologique la plus importante de cette normalisation est la revelation d'un ecart structurel que les indices traditionnels masquent. L'AI Preparedness Index du FMI (Cazzaniga et al., 2024) attribue des scores de 0,85 (USA) et 0,74 (France), un ratio de 1,15:1, suggerant une quasi-parite. Le Global AI Index de Tortoise produit des ecartes similaires. Pourtant, le CACI normalise en Power Mode place la France a environ 25 et l'Allemagne a environ 5 sur une echelle ou les Etats-Unis = 100, soit des ratios respectifs de 4:1 et 19:1. Le ratio principal US/UE (UE agreee comme 13 economies principales) est de

3,46:1. Cette divergence n'est pas contradictoire : elle resulte du fait que les indices multidimensionnels agregent lineairement des dimensions normatives (regulation, ethique, publications) qui compensent arithmetiquement les deficits sur les facteurs materiels (compute, energie). Le CACI, en isolant ces facteurs materiels, expose le gouffre physique que les metriques composites moyennent.

Cette propriete du CACI - reveler l'ampleur reelle du compute gap - constitue la contribution analytique centrale de l'indice et la these empirique fondamentale de cette etude. L'ecart CACI n'est pas un artefact de normalisation : c'est le resultat scientifique.

2.4.4 Positionnement par rapport aux indices existants de competitivite IA

L'AI Preparedness Index (AIPI) du FMI couvre 174 pays (2023) et agregue quatre piliers : infrastructure numerique, capital humain et politiques du marche du travail, innovation et integration economique, regulation et ethique. L'AIPI ne mesure pas le compute IA installe et ne pondere pas par le cout energetique. Sa correlation attendue avec le CACI est positive mais imparfaite : les pays bien classes a l'AIPI (Singapour, Danemark, Pays-Bas) ne sont pas necessairement ceux dont le compute effectif par unite de PIB est le plus eleve.[21]

Le Global AI Index (GAI) de Tortoise Media classe 83 pays sur 122 indicateurs en trois piliers (Implementation, Innovation, Investment). Il inclut une composante infrastructure/supercalcul mais l'agregue lineairement avec des poids subjectifs (reconnu par Tortoise comme une limite). Le GAI est plus large et plus multidimensionnel que le CACI, mais precisement parce qu'il est large, il dilue le signal compute dans un composite a nombreux indicateurs. Comme le montrent Koronakos et al. (2024), la subjectivite des ponderations du GAI peut inverser les classements de pays selon les scenarios de ponderation choisis.

Le Stanford AI Index (2025) constitue la reference la plus complete en termes de donnees brutes (modeles notables par pays, investissement, publications, brevets, tendances compute). Il ne propose pas d'indice composite mais fournit les series temporelles utilisees par de nombreux autres indices. Les donnees publiques du Stanford AI Index sont accessibles via un dossier Google Drive ouvert.[22]

Valeur ajoutee specifique du CACI. Le CACI se distingue par quatre proprietes : il place le compute au centre plutot qu'a la peripherie de l'indicateur, refletant le role desormais dominant du compute dans l'IA de frontiere ; il integre explicitement le cout energetique comme goulot d'etranglement, coherent avec les conclusions de l'IEA (2025) ; il utilise une agregation multiplicative theoriquement fondee plutot qu'additive ; et il est parcimonieux (quatre variables), le rendant transparent et reproductible, au prix d'une exhaustivite moindre.

2.4.5 Limites du CACI et analyse de sensibilite

Premiere limite - opacite de $F(r,t)$. La mesure du compute installe depend de donnees privees incompletes. Le jeu de donnees Epoch AI ne couvre que 10-20 pour cent du compute mondial, avec une couverture inegale entre secteurs et entreprises. L'attribution nationale est elle-meme discutable : une part croissante du compute est detenue par quelques hyperscalers prives operant globalement. Mitigation : nous documentons systematiquement les marges d'incertitude, presentons des intervalles plutot que des valeurs

ponctuelles, et vérifions la stabilité des résultats lorsque F varie de plus ou moins 30 pour cent. La décomposition Physique/Souverain traite partiellement le problème d'attribution.

Deuxième limite - hétérogénéité qualitative du compute. Le CACI agrège des FLOPs sans distinguer les générations de GPU (un H200 ne vaut pas un A100 en efficacité énergétique et performance réelle). Mitigation : le jeu de données Epoch AI fournit la performance en équivalents H100, offrant une normalisation partielle. Nous proposons un facteur de pondération par génération de GPU en annexe et montrons que l'ajustement modifie marginalement les classements.

Troisième limite - le proxy de capital humain $L(r,t)$. La combinaison STEM plus LinkedIn plus certifications présente un biais favorisant les pays anglophones. Ce biais sous-estime probablement la Chine et certaines économies asiatiques. Mitigation : nous répliquons l'analyse en utilisant le sous-indice Human Capital de l'AIPI du FMI comme proxy alternatif et montrons la sensibilité des classements à ce choix.

Quatrième limite - statisme de l'indicateur. Le CACI mesure un état à un instant donné, non une dynamique. C'est pourquoi nous le calculons sur plusieurs années (2022, 2024, 2026) et le projetons dans chaque scénario, permettant le suivi de trajectoire et l'évaluation de l'évolution de l'écart.

Cinquième limite - endogénéité. Les pays gagnant en productivité IA investissent massivement dans le compute, créant un risque de causalité inverse : le CACI pourrait capturer la conséquence plutôt que la cause de la compétitivité. Cette étude, dans son cadre de thèse, n'instrumente pas formellement cette relation (pas de variables instrumentales ni de stratégie GMM). Cependant, nous notons que le choc exogène des règles BIS d'octobre 2022 offre une quasi-expérience naturelle qui pourrait fonder une stratégie d'identification causale en Difference-in-Differences. Nous identifions le traitement formel de cette endogénéité (DiD, IV ou GMM Arellano-Bond) comme une piste de recherche prioritaire pour toute extension publishable de ce travail.[23]

Sixième limite - biais de normalisation pour les petites économies. L'analyse comparative du CACI face aux indices AIPI du FMI et GAI de Tortoise révèle une anomalie instructive : certains pays à faible PIB et à main-d'œuvre IA réduite obtiennent des scores CACI disproportionnellement élevés. L'Afrique du Sud est emblématique : classée dernière ou avant-dernière aux indices AIPI et Tortoise, elle peut apparaître comme leader mondial sur le CACI en Intensity Mode lorsque la normalisation par le PIB amplifie un effet de petit dénominateur. Ce phénomène est un cas classique de biais de normalisation identifié dans la littérature des indicateurs composites. Le OECD/JRC Handbook (Nardo et al., 2008, pp. 27-29) avertit que la normalisation par le PIB ou la population peut produire des résultats trompeurs pour les petites économies. Notre mitigation est triple : un seuil de masse critique sur F (excluant les économies sous 10 000 H100-équivalents) ; un facteur d'échelle $\alpha(r) = \min(1, F(r) / F_{\text{median}})$ pour les tests de sensibilité ; et un classement double (Power Mode pour la puissance absolue, Intensity Mode pour la densité), avec la réserve explicite que les comparaisons bilatérales dans cette étude se concentrent sur les USA, l'UE, la France et la Chine.[24]

2.4.6 Chiffres reproductibles - snapshot avril 2026

Pour permettre au lecteur de rejouer le calcul à partir des CSV du tableau de bord public, nous exposons ici les entrées et sorties utilisées tout au long de cette étude. Les quatre variables d'entrée sont sources depuis

le dossier de donnees du tableau de bord (energy_prices.csv, gdp_data.csv, workforce_data.csv, gpu_clusters.csv) a <https://mo0ogly.github.io/America-First-IA/dashboard/data/>.

Entrees (snapshot avril 2026). USA : $F_{total} = 39,65$ millions de H100-eq, $L = 3,5$ millions, $R = 1,00$, $E = 85$ USD/MWh, PIB = 29,3 milliers de milliards USD. UE (13 economies principales agreees) : $F_{total} = 2,62$ millions de H100-eq, $L = 3,1$ millions, $R = 0,90$, $E = 135$ USD/MWh, PIB = 18,9 milliers de milliards USD. France : $F_{total} = 2,44$ millions de H100-eq, $L = 1,5$ millions, $R = 0,90$, $E = 115$ USD/MWh, PIB = 3,16 milliers de milliards USD. Allemagne : $F_{total} = 0,05$ million de H100-eq, $L = 1,9$ millions, $R = 0,90$, $E = 140$ USD/MWh, PIB = 4,68 milliers de milliards USD. Chine : $F_{total} = 0,40$ million de H100-eq, $L = 4,8$ millions, $R = 0,70$, $E = 92$ USD/MWh, PIB = 18,7 milliers de milliards USD.

Sorties (Power Mode F_{total} , normalisees a USA = 100). USA = 100,0 ; UE(13) = 28,9 ; France = 25,3 ; Inde = 22,2 ; Chine = 15,7 ; Royaume-Uni = 7,0 ; Allemagne = 5,4. EAU = 55,7 en CACI Physique mais seulement 6,0 en CACI Souverain (F_{dom} restreint aux clusters detenus par des entites domestiques G42, MGX, Mubadala, Khazna, TII), illustrant la decomposition Physique/Souverain : 99,6 pour cent du F_{total} des EAU est detenu par des acteurs US-side (Stargate UAE, Microsoft, OpenAI). Ratios principaux : US/UE(13) = 3,46:1 ; US/France = 3,96:1 ; US/Allemagne = 18,59:1 ; US/Chine = 7,46:1.

Ces sorties sont reproduites en direct sur le tableau de bord public. Toute mise a jour ulterieure du tableau de bord (nouveaux clusters, revisions energetiques, rafraichissement PIB) rafraichira mecaniquement les chiffres ; la methodologie ne change pas. Le ratio de 3,46:1 en Power Mode F_{total} reporte sur la couverture et tout au long de cette etude correspond exactement a ce snapshot.

2.5 Perimetre et delimitations

Perimetre géographique. L'analyse se concentre sur la relation bilaterale Etats-Unis / Union europeenne, avec un focus specifique sur la France. La Chine est traitee comme variable contextuelle (cible principale des controles a l'exportation americains, facteur de pression sur les capacites de production de puces) mais ne fait pas l'objet d'une analyse approfondie. Le Japon, la Coree du Sud et Taiwan apparaissent comme acteurs de la chaine d'approvisionnement en semi-conducteurs.

Perimetre temporel. Le diagnostic couvre 2020-2026, les scenarios couvrent 2026-2030. L'horizon 2030 est choisi parce qu'il correspond a la convergence de plusieurs echeances : projections AIE pour l'energie des centres de donnees, maturite attendue de l'EU Chips Act, objectifs SNIA France 2030 et arrivee potentielle des premiers SMR nucleaires operationnels.

Perimetre technologique. L'etude couvre l'IA de frontiere (modeles de fondation, intensifs en compute) et ses prerequis materiels (GPU/ASIC, centres de donnees, energie). Elle integre la robotique IA comme facteur amplificateur de la demande energetique. Elle ne traite pas l'IA embarquee edge (smartphones, IoT), sauf dans la mesure ou elle constitue un objectif specifique de la SNIA francaise.

2.6 Limites methodologiques generales

Incertitude politique radicale. Le protectionnisme technologique depend de decisions politiques discretionnaires a predictibilite structurellement faible. Un changement d'administration americaine en 2028, un accord commercial UE-USA inattendu ou une escalade du conflit US-Chine pourrait invalider certaines hypotheses. C'est precisement pourquoi nous proposons quatre scenarios plutot qu'une trajectoire unique.

Disruptions technologiques. L'episode DeepSeek (janvier 2025), ou un modele chinois a atteint des performances proches de la frontiere avec un budget d'entrainement substantiellement reduit, illustre la possibilite de perrees en efficacite qui modifieraient les termes du probleme. L'IEA (2025, Energy and AI) consacre une etude de cas a DeepSeek et conclut que meme avec des ameliorations significatives d'efficacite, la croissance de la demande absorbe les gains (effet rebond de Jevons).[25]

Opacite des donnees compute. Le nombre exact de GPU deployes par hyperscaler, la distribution geographique precise des centres de donnees et les volumes de GPU exportes par region sont des donnees partiellement ou totalement confidentielles. Nos estimations de compute installe portent des marges d'erreur significatives, que nous documentons systematiquement.

Biais des sources de conseil. Comme note en section 2.2, les sources industrielles portent un biais d'optimisme systematique. Nous l'attenuons par triangulation mais ne pouvons l'eliminer entierement.

Ces limites ne compromettent pas la validite de l'analyse. La methode des scenarios est precisement concue pour fonctionner dans des environnements de haute incertitude, ou l'objectif n'est pas la prediction mais l'exploration structuree des possibles. Comme le note Schwartz : les scenarios ne sont pas des previsions ; ce sont des histoires plausibles qui aident a penser.[26] Notre contribution reside dans la rigueur du cadrage, l'explicitation des hypotheses, la transparence des sources de donnees et l'originalite de l'indicateur CACI, plutot que dans la precision des projections numeriques.

Notes

1. Schwartz, P. (1991), *The Art of the Long View: Planning for the Future in an Uncertain World*, New York, Doubleday. See also Wack, P. (1985), 'Scenarios: Uncharted Waters Ahead,' *Harvard Business Review*, Sept.-Oct. 1985, pp. 72-89.
2. Bradfield, R., Wright, G., Burt, G., Cairns, G. and Van Der Heijden, K. (2005), 'The Origins and Evolution of Scenario Techniques in Long Range Business Planning,' *Futures*, 37(8), pp. 795-812.
3. Schoemaker, P.J.H. (1995), 'Scenario Planning: A Tool for Strategic Thinking,' *MIT Sloan Management Review*, 36(2), pp. 25-40.
4. Nardo, M., Saisana, M., Saltelli, A. and Tarantola, S. (2008), *Handbook on Constructing Composite Indicators: Methodology and User Guide*, OECD Publishing, Paris.
5. The SIA/McKinsey gap is explained by scope: McKinsey (January 2026, 'Hiding in Plain Sight') includes the value of captive designers (Apple, Amazon, Tesla) and fabless operators whose sales do not appear in WSTS statistics.
6. Pilz, K.F., Rahman, R., Sanders, J. and Heim, L. (2025), 'Trends in AI Supercomputers,' *arXiv:2504.16026*, April 2025. Dataset accessible at <https://epoch.ai/data/gpu-clusters> under Creative Commons Attribution licence.
7. Epoch AI (2025), *GPU Clusters Documentation*. Coverage estimated at 20-37 percent of NVIDIA H100s, 12 percent of A100s and 18 percent of AMD MI300X, but less than 4 percent of Google TPUs.
8. Lehdonvirta, V., Wu, B., Hawkins, Z.J., Caira, C. and Russo, L. (2025), 'Measuring Domestic Public Cloud Compute Availability for Artificial Intelligence,' *OECD AI Papers No. 49*, <https://doi.org/10.1787/8602a322-en>.
9. Van der Heijden, K. (2004), *Scenarios: The Art of Strategic Conversation*, 2nd ed., Chichester, Wiley.

10. Schwartz (1991), op. cit., pp. 241-243.
11. Hawkins, Z.J., Lehtonvirta, V. and Wu, B. (2025), 'AI Compute Sovereignty,' SSRN, June 2025, <https://ssrn.com/abstract=5312977>. Sevilla, J. et al. (2022), 'Compute Trends Across Three Eras of Machine Learning,' arXiv:2202.05924.
12. Cazzaniga, M. et al. (2024), 'Gen-AI: Artificial Intelligence and the Future of Work,' IMF Staff Discussion Note 2024/001. The AI Preparedness Index is accessible via the IMF dashboard.
13. Tortoise Media (2024), The Global Artificial Intelligence Index 2024. See also Koronakos, G., Kritikos, M. and Sotiros, D. (2024), 'Mitigating Subjectivity and Bias in AI Development Indices,' Expert Systems with Applications.
14. Cohen, W.M. and Levinthal, D.A. (1990), 'Absorptive Capacity: A New Perspective on Learning and Innovation,' Administrative Science Quarterly, 35(1), pp. 128-152.
15. Effective costs are derived from the dashboard energy_prices.csv and reflect PPA-adjusted prices. Raw Eurostat industrial tariffs in Europe (consumption band IE) can be 1.5 to 2 times higher; the gap between raw and effective prices is documented in Chapter III. The Federal Reserve Board (October 2025) documents a significant negative correlation between energy costs and AI adoption at the European firm level.
16. Geometric aggregation is also used by the UNDP Human Development Index since 2010, for analogous reasons of non-substitutability between dimensions. See OECD/JRC Handbook (2008), pp. 31-33.
17. Operational shares computed by aggregating Epoch AI clusters with status Existing/Operational/Online/In progress on the April 2026 snapshot.
18. The Python code and data are reproducible. The Epoch AI dataset is downloadable in CSV at https://epoch.ai/data/gpu_clusters.csv (daily refresh). The dashboard CSVs are mirrored at <https://moOogly.github.io/America-First-IA/dashboard/data/>.
19. The LinkedIn bias is documented: in countries where LinkedIn is rarely used (China, Russia, some Southeast Asian economies), AI skills density is mechanically underestimated.
20. IMF (2024), AI Preparedness Index Dashboard. Singapore, Denmark, Netherlands and the US occupy top positions; China ranks 31st (score 0.63).
21. Maslej, N. et al. (2025), 'Artificial Intelligence Index Report 2025,' Stanford Institute for Human-Centered AI, April 2025.
22. Tortoise Media (2024), op. cit. Stanford AI Index public data: open Google Drive folder.
23. The most promising causal identification strategy would exploit the exogenous shock of the October 2022 BIS rules in a Difference-in-Differences framework. See Arellano, M. and Bond, S. (1991), 'Some Tests of Specification for Panel Data,' Review of Economic Studies, 58(2), pp. 277-297.
24. OECD/JRC Handbook (2008), pp. 27-29. The dual ranking solution (intensity / scale) is also used by Tortoise Media (2024) in the Global AI Index. Saisana, M. and Tarantola, S. (2002), State-of-the-art Report on Current Methodologies and Practices for Composite Indicator Development, JRC European Commission, pp. 14-16.
25. IEA (2025), Energy and AI, devotes a case study to DeepSeek and concludes that even with significant efficiency improvements, demand growth absorbs gains (Jevons rebound effect).
26. Schwartz (1991), op. cit., p. 38. Author translation.

CHAPITRE III - DIAGNOSTIC EMPIRIQUE 2020-2026

CHAPITRE III

Diagnostic empirique 2020-2026

Ce chapitre établit la base factuelle de l'analyse. Il couvre quatre dimensions interdépendantes : la trajectoire énergétique des centres de données, l'évolution du marché des semi-conducteurs, la répartition géographique du compute IA installé et la chronologie des mesures réglementaires américaines. Les données présentées ici constituent les éléments prédéterminés (au sens de Schwartz) qui structurent les scénarios prospectifs du chapitre V. Toutes les séries temporelles sont sourcées, et lorsque les sources divergent, l'écart est explicite. Tous les ratios impliquant le compute ont été recalibrés sur le snapshot d'avril 2026 du tableau de bord public.

3.1 Trajectoire énergétique des centres de données : doublement de la demande en six ans

3.1.1 Consommation mondiale 2020-2024

L'Agence internationale de l'énergie (AIE, avril 2025) estime la consommation électrique mondiale des centres de données à environ 415 TWh en 2024, soit 1,5 pour cent de la consommation électrique mondiale. [1] Cette consommation a cru en moyenne de 12 pour cent par an depuis 2017, soit un rythme quatre fois supérieur à la croissance totale de la consommation d'électricité. En 2020, elle était d'environ 270 TWh ; l'augmentation représente donc +54 pour cent en quatre ans.

La distribution géographique est très concentrée. Les États-Unis absorbent 45 pour cent de la consommation mondiale des centres de données (environ 180 TWh en 2024), suivis de la Chine (25 pour cent, ~102 TWh) et de l'Europe (15 pour cent, ~70 TWh pour l'UE selon la Commission européenne).[2] Les quatre principaux pays européens (Allemagne, France, Royaume-Uni, Pays-Bas) totalisent environ 41 TWh, soit 10 pour cent du total mondial. La capacité mondiale installée de centres de données a atteint près de 100 GW en 2024. Pres de la moitié de la capacité américaine est concentrée dans cinq clusters régionaux.

3.1.2 Projections 2024-2030 : le scénario central de l'AIE

Le scénario central de l'AIE (Base Case) projette une consommation mondiale de 945 TWh d'ici 2030, soit un doublement par rapport à 2024 et l'équivalent de la consommation électrique actuelle du Japon. L'IA est identifiée comme le principal moteur de cette croissance. La part de l'IA dans la consommation des centres de données, estimée à 5 à 15 pour cent ces dernières années, pourrait atteindre 35 à 50 pour cent d'ici 2030. [3]

La croissance est géographiquement inégale. Les États-Unis ajoutent environ +240 TWh (+130 pour cent par rapport à 2024), la Chine +175 TWh (+170 pour cent), et l'Europe seulement +45 TWh (+70 pour cent). L'AIE note un risque de 20 pour cent de retard des projets en Europe, lié aux contraintes de raccordement au

reseau et aux delais d'autorisation.[4] Aux Etats-Unis, les centres de donnees representent pres de la moitie de la croissance de la demande electrique d'ici 2030 ; le pays consommera plus d'electricite pour ses centres de donnees que pour la production combinee d'aluminium, d'acier, de ciment et de produits chimiques.

3.1.3 Le facteur energetique comme avantage competitif

L'asymetrie energetique constitue un avantage structurel pour les Etats-Unis. L'AIE note que le gaz naturel fournit actuellement 40 pour cent de l'electricite des centres de donnees americains, les renouvelables 24 pour cent, le nucleaire 20 pour cent et le charbon 15 pour cent. En Europe, le mix energetique est davantage contraint par les objectifs climatiques et des couts energetiques plus eleves. Les prix de l'electricite industrielle sont typiquement 2 a 3 fois plus eleves en Europe qu'aux Etats-Unis sur le tarif Eurostat non ajuste. Une fois pris en compte les Power Purchase Agreements negocies par les hyperscalers, l'ecart se reduit a environ 1,4 a 1,7 fois (1,59x pour l'agregat UE a la reference du tableau de bord d'avril 2026 : 135 USD/MWh dans l'UE contre 85 USD/MWh aux Etats-Unis). Comme le documente la Federal Reserve Board (octobre 2025), il existe une correlation negative significative entre couts energetiques et adoption de l'IA au niveau des entreprises europeennes, meme apres correction PPA.[5]

La France dispose toutefois d'un atout specifique dans ce contexte : son mix electrique nucleaire (environ 65 a 70 pour cent de la production), qui offre une electricite relativement bon marche, decarbonee et disponible en base. RTE estime un besoin supplementaire de +10 GW pour les centres de donnees en France d'ici 2030, qui reste compatible avec la capacite installee sous reserve d'investissements dans le reseau de transport.

3.1.4 Effet amplificateur : robotique IA et demande energetique industrielle

Un facteur encore peu quantifie dans la litterature est l'impact de la robotique IA sur la demande energetique. Les robots autonomes necessitent a la fois du compute embarque (edge computing) et du compute centralise (cloud IA pour l'entrainement et les mises a jour de modeles). Le deploiement massif de l'automatisation IA dans l'industrie pourrait ajouter 20 a 30 pour cent de demande energetique supplementaire dans les secteurs concernes, en plus de la croissance des centres de donnees. Ce facteur est integre comme variable de sensibilite dans nos scenarios (chapitre V), aucune estimation precise et fiable n'existant encore. L'AIE consacre neanmoins une section de son rapport a l'effet rebond de Jevons : meme avec des gains d'efficacite significatifs (illustres par le cas DeepSeek), la croissance de la demande absorbe les gains.[6]

3.2 Marche des semi-conducteurs : une croissance tiree par l'IA

3.2.1 Trajectoire des ventes mondiales 2020-2025

Le marche mondial des semi-conducteurs a suivi une trajectoire remarquable depuis 2020. Apres un record de 555,9 milliards USD en 2022, le secteur s'est contracte de 8,2 pour cent en 2023 (526,8 milliards USD), avant un rebond spectaculaire en 2024 : les ventes mondiales ont atteint 630,5 milliards USD (donnees

SIA/WSTS revisees, mars 2025), une hausse de 19,1 pour cent en glissement annuel et un nouveau record absolu.[7]

L'annee 2025 a confirme l'acceleration. La SIA a annonce en fevrier 2026 des ventes mondiales de 791,7 milliards USD en 2025, une hausse de 25,6 pour cent par rapport a 2024.[8] Le quatrieme trimestre 2025 (236,6 milliards USD) etait 37,1 pour cent plus eleve que le meme trimestre en 2024. La SIA projette desormais des ventes proches de 1 000 milliards USD en 2026, un seuil symbolique qui semblait hors de portee il y a deux ans.

Deux segments tirent cette croissance. Les puces logiques (processeurs, GPU, ASIC) ont atteint 301,9 milliards USD en 2025 (+39,9 pour cent), devenant la premiere categorie par les ventes. La memoire (DRAM, NAND) a atteint 223,1 milliards USD (+34,8 pour cent). Ensemble, ces deux segments representent plus de 66 pour cent des ventes mondiales et refletent directement la demande d'infrastructure IA : serveurs, centres de donnees et HPC (High Performance Computing).

3.2.2 La question du perimetre : SIA vs McKinsey

Comme note au chapitre II, un ecart methodologique notable existe entre les donnees SIA/WSTS et les estimations McKinsey. La SIA enregistre les ventes de semi-conducteurs au sens strict (composants vendus par les fabricants). McKinsey (janvier 2026) adopte un perimetre elargi incluant la valeur des designers captifs (Apple, Amazon, Tesla, Google), c'est-a-dire la valeur economique des puces concues en interne mais fabriquees par des fonderies sous contrat. Sous ce perimetre elargi, McKinsey valorise le marche a environ 775 milliards USD en 2024 et projette 1,5 a 1,8 trillions USD d'ici 2030.[9] Le perimetre elargi est plus pertinent pour notre analyse car il capture la pleine valeur de la chaine IA, y compris les investissements de design des hyperscalers.

3.2.3 Concentration regionale de la capacite de fabrication

La distribution geographique de la capacite de fonderie constitue un facteur cle de vulnerabilite. Taiwan (TSMC) concentre l'essentiel de la production de pointe (noeuds sub-7 nm). Les Etats-Unis representent environ 10 pour cent de la capacite installee mondiale mais croissent rapidement (le Chips Act a genere pres de 500 milliards USD d'investissement prive annonce, avec un objectif de tripler la capacite americaine d'ici 2032).[10] L'UE represente environ 8 pour cent de la capacite mondiale, un chiffre que l'EU Chips Act (43 milliards EUR) vise a porter a 20 pour cent d'ici 2030, un objectif juge irrealiste par de nombreux observateurs. La Chine, malgre les restrictions, progresse de 21 pour cent vers un objectif de 30 pour cent de capacite installee d'ici 2030, principalement sur les noeuds matures (28 nm et au-dessus).

3.3 Repartition geographique du compute IA installe

3.3.1 Domination americaine : trois quarts du compute operationnel

La donnee la plus significative pour notre analyse est la repartition geographique de la capacite de calcul dediee a l'IA. Les travaux d'Epoch AI (Pilz et al., avril 2025) fournissent le jeu de donnees fondamental,

rafraichi mensuellement sur le tableau de bord public.[11] A avril 2026, le tableau de bord catalogue 786 clusters, dont 609 operationnels et 171 planifies ou annonces.

Le resultat est sans ambiguïte. Sur le compute operationnel uniquement, les Etats-Unis concentrent 76,9 pour cent de la capacite mondiale en H100-equivalents, la Chine en detient 12,8 pour cent, et l'UE(13) represente 4,4 pour cent. Les autres pays se partagent environ 6 pour cent. Le ratio US/UE en H100-equivalents operationnels est donc de 17,6:1, un ecart de magnitude considerable qui s'est legerement creuse depuis le snapshot GeoCoded/Sanchez de mai 2025 (74,5 / 14,1 / 4,8 pour cent).[12]

Deux dynamiques expliquent cette concentration. Premierement, la part du secteur prive dans le compute IA mondial est passee de 40 pour cent en 2019 a 80 pour cent en 2025, et les entreprises technologiques investissant massivement dans l'IA sont quasi exclusivement americaines (Microsoft, Meta, Google, Amazon, xAI). Deuxiemement, la taille des clusters a explose : les systemes de plus de 10 000 puces etaient rares en 2019 ; en 2024, xAI a deploye un cluster Colossus de 200 000 GPU. La performance des supercalculateurs IA de pointe double tous les neuf mois.[13]

Le tableau change substantiellement lorsque la capacite planifiee est incluse. La vue F_total du tableau de bord, qui compte a la fois les clusters operationnels et annonces, montre la part US tomber a 49,9 pour cent. Le decalage n'est pas du a des acteurs etrangers construisant une capacite independante, mais aux hyperscalers americains delocalisant vers des juridictions allies : le campus annonce de 5 GW aux EAU et le Stargate UAE Phase 2 representent 22,9 millions de H100-equivalents, l'Arabie saoudite 7,2 millions, et la Coree du Sud 5,3 millions, tous largement detenus ou operes par des entreprises americaines. Cette distinction entre CACI Physique (ou se trouve le cluster) et CACI Souverain (qui le controle) est developpee au chapitre V. La part chinoise s'effondre a 0,5 pour cent en F_total, un artefact de la methodologie Epoch AI plutot qu'un veritable changement de position : le jeu de donnees anonymise les systemes chinois et les arrondit agressivement, de sorte que la capacite chinoise annoncee est structurellement sous-enregistree. La part UE(13) en F_total descend egalement a 3,3 pour cent car le campus Fluidstack 1 GW en France tire le total vers le haut tandis que le reste de l'UE compte peu d'annonces majeures.

3.3.2 Puissance electrique totale du parc de puces IA

Epoch AI (janvier 2026) estime la capacite electrique totale du parc mondial de puces IA a environ 30 GW fin 2025, comparable a la consommation de pointe de l'Etat de New York.[14] Cette estimation repose sur les ventes trimestrielles de puces IA des principaux fabricants (Nvidia, AMD, Google TPU), multipliees par leur puissance nominale (TDP) et un facteur 2,5x pour l'infrastructure des centres de donnees. La production mondiale de puces IA double tous les sept mois, un rythme qui depasse toutes les previsions anterieures. Les cinq plus grands investisseurs americains en serveurs IA (Microsoft, Google, Meta, Amazon, xAI) ont annonce 320 milliards USD d'investissements en 2025, contre 230 milliards USD en 2024.

3.3.3 Implications pour la metrique CACI

Ces donnees permettent une calibration precise du CACI defini au chapitre II. En utilisant la formule geometrique ponderee $CACI = F^{0,40} \times L^{0,20} \times R^{0,15} / E^{0,25}$ (Power Mode), avec les valeurs de reference du tableau de bord d'avril 2026 : compute US operationnel de 2 759 968 PetaFLOP/s (FP16) contre

156 632 PetaFLOP/s pour l'UE(13), un ratio energie UE/US ajuste-PPA de 1,59x (135 contre 85 USD/MWh), des ordres de grandeur de population active comparables (3,5 contre 9,6 millions a travers l'UE(13)), et des facteurs d'accès geopolitique $R(US) = 1,0$ contre $R(UE) = 0,9$, le ratio $CACI(US)/CACI(UE)$ en Power Mode s'establit a 3,46:1.

L'ecart est substantiellement atténue par rapport a l'avantage brut de 17,6:1 en H100-equivalents car les exposants geometriques (F a 0,40 ; L a 0,20 ; R a 0,15 ; E a 0,25) appliquent des rendements décroissants a la massive avance US sur le compute et recompensent partiellement l'UE sur le travail, l'accès geopolitique et des multiplicateurs energetiques plus faibles. En Intensity Mode (en divisant additionnellement par le PIB), l'ecart se resserre encore a environ 1,4:1, raison pour laquelle le ratio principal utilise dans toute cette etude est le ratio Power Mode de 3,46:1. Le chapitre V projette l'evolution de ce ratio dans chaque scenario.

3.4 Chronologie des mesures reglementaires americaines (2022-2026)

La sequence des mesures americaines de controle des semi-conducteurs et de l'IA constitue le fil directeur de notre hypothese. Quatre phases sont identifiabiles, marquant une escalade progressive dans l'etendue et l'intensite des restrictions.

Phase 1 - Le choc initial (7 octobre 2022)

Le BIS (Bureau of Industry and Security) du departement du Commerce publie une regle interimaire definitive qui transforme radicalement les controles a l'exportation americains sur les semi-conducteurs. Les mesures couvrent trois composantes : (i) controles sur les puces de calcul avancees (GPU au-dessus des seuils de performance definis par TTP - Total Processing Performance), (ii) controles sur les equipements de fabrication de semi-conducteurs (SME, y compris les lithographies EUV et DUV), et (iii) restrictions sur les activites de US persons soutenant la fabrication de puces avancees en Chine.[15] La cible est explicitement la Chine : l'objectif annonce est d'empecher la modernisation militaire chinoise via l'accès au compute IA. Les restrictions incluent trois nouvelles regles Foreign Direct Product (FDP) qui etendent la juridiction americaine aux produits fabriques hors des Etats-Unis si des technologies americaines sont utilisees dans leur production.

Phase 2 - Comblér les failles (octobre 2023)

Le BIS publie deux nouvelles regles interimaires qui renforcent et elargissent les controles d'octobre 2022. Les seuils techniques sont ajustes pour capturer les puces Nvidia specifiquement concues pour contourner les restrictions (A800, H800). Le perimetre geographique est etendu a environ 40 pays supplementaires (Country Groups D:1, D:4 et D:5), avec un regime de licences differencie par categorie de pays.[16] Les controles sur les equipements de fabrication sont approfondis. C'est durant cette phase que les acteurs europeens commencent a percevoir les effets indirects des restrictions, meme si l'UE n'est pas la cible principale.

Phase 3 - L'AI Diffusion Rule (janvier 2025, Biden)

L'administration Biden publie en janvier 2025 l'AI Diffusion Rule, qui représente un changement qualitatif. Pour la première fois, les restrictions s'appliquent non seulement aux puces physiques mais aussi aux poids des modèles IA et à l'accès au compute cloud. La règle classe 120 pays en trois catégories : (i) alliés de confiance (accès large), (ii) pays intermédiaires (quotas), (iii) pays embargos.[17] Les réactions européennes sont fortes : le Parlement européen alerte sur les restrictions menaçant la capacité de l'UE à entraîner des modèles sur ses AI Factories. La France et l'Allemagne sont classées comme partenaires de confiance, mais d'autres États membres font face à des plafonds sur les volumes de GPU importables.

Phase 4 - La rupture Trump : Section 232 et protectionnisme explicite (janvier 2026)

Le 14 janvier 2026, le président Trump signe la Proclamation 11002, invoquant la Section 232 du Trade Expansion Act de 1962.[18] Cette action marque une rupture qualitative avec les phases précédentes, pour trois raisons.

Premièrement, l'instrument juridique change. Les phases 1 à 3 relevaient des contrôles à l'exportation (régulation des exportations, logique défensive de sécurité nationale). La Section 232 est un instrument tarifaire (droits à l'importation), dont la logique est protectionniste : elle vise à protéger la production domestique, et non simplement à restreindre l'accès d'un adversaire.

Deuxièmement, le tarif crée un avantage compétitif explicite pour les entreprises américaines. Le tarif de 25 pour cent frappe les GPU avancés (H200, MI325X) importés sauf s'ils sont destinés à des usages domestiques américains : centres de données US, R&D, startups, secteur public, applications industrielles et grand public hors centres de données. Concrètement, une entreprise américaine utilisant ces puces sur le sol américain ne paie pas le tarif ; une entreprise étrangère important les mêmes puces pour réexportation vers la Chine paie 25 pour cent.[19]

Troisièmement, la proclamation annonce une expansion imminente. Le texte prévoit que le secrétaire au Commerce et l'USTR négocient dans les 90 jours avec les pays producteurs de semi-conducteurs, et que des tarifs plus larges, accompagnés d'un programme de tariff offset pour les entreprises investissant dans la production américaine, pourraient être imposés. Le secrétaire au Commerce doit fournir d'ici juillet 2026 un rapport sur le marché des semi-conducteurs utilisés dans les centres de données américains.[20]

3.4.5 Interprétation : du contrôle défensif au protectionnisme offensif

La séquence 2022-2026 révèle une transformation qualitative de la politique américaine. Les phases Biden (2022-2025) suivent une logique de stratégie de denial : empêcher un adversaire désigné (la Chine) d'accéder à des technologies clés, dans un cadre multilatéral (coordination avec le Japon, les Pays-Bas). La phase Trump (2025-2026) ajoute une logique de stratégie de capture : générer des revenus (tarif de 25 pour cent), prioriser les entreprises américaines (exemptions domestiques) et utiliser l'accès au compute comme levier de négociation avec des pays tiers.

C'est précisément la transformation qui valide l'hypothèse centrale de notre étude : le protectionnisme technologique américain ne se limite plus à nier l'accès à un adversaire ; il construit activement un avantage compétitif structurel pour les entreprises américaines. Les exemptions domestiques de la Section 232 signifient que, pour la première fois, le coût d'accès au compute de pointe est légalement différencié par

la nationalite de l'utilisateur. Meme si les effets directs sur l'UE restent limites en janvier 2026 (le tarif cible principalement la reexportation vers la Chine), la proclamation ouvre la voie a une expansion qui pourrait directement affecter l'Europe, precisement le territoire des scenarios B, C et D de notre analyse.

3.5 Synthese diagnostique : les elements predetermines de 2026

Les quatre dimensions du diagnostic convergent vers un tableau coherent qui structure les scenarios du chapitre V.

- (1) La demande de compute IA croit de maniere exponentielle (doublement des ventes de puces en deux ans, doublement projete de la consommation energetique sur six ans), et cette croissance ne montre aucun signe de ralentissement.
- (2) Cette demande est structurellement concentree aux Etats-Unis. Le snapshot du tableau de bord d'avril 2026 chiffre la part US a 76,9 pour cent du compute IA operationnel en H100-equivalents et a 49,9 pour cent en incluant les clusters annonces ; 45 pour cent de la consommation electrique des centres de donnees ; et plus de 80 pour cent des investissements prives dans l'IA de frontiere. La concentration sur le compute operationnel s'accroit au fil du temps.
- (3) L'Europe part d'une position structurellement deficitaire : environ 4,4 pour cent du compute operationnel en H100-equivalents, environ 15 pour cent de la consommation des centres de donnees, des couts energetiques 1,4 a 1,7 fois superieurs apres correction PPA (et 2 a 3 fois superieurs sur les tarifs Eurostat industriels non ajustes), et 72 a 80 pour cent de dependance aux hyperscalers US pour les charges IA cloud. Les plans d'investissement de l'UE (Chips Act, AI Factories, SNIA) portent des budgets au moins un ordre de grandeur inferieurs aux annonces des Big Tech 2025 (320 milliards USD pour les cinq seuls investisseurs US frontier-AI).
- (4) Le cadre reglementaire americain a franchi un seuil qualitatif en janvier 2026 avec le passage des controles a l'exportation aux tarifs Section 232, creant un mecanisme legal de differenciation des couts d'accès au compute par nationalite. La proclamation signale explicitement la possibilite d'une expansion, dont la portee et le calendrier dependront de variables politiques, precisement les incertitudes critiques qu'explorent nos scenarios.

Le chapitre suivant (chapitre IV) analyse les mecanismes par lesquels cette asymetrie de compute se traduit en avantage competitif mesurable pour les entreprises americaines.

Tableau 4. Consommation electrique des centres de donnees par region, 2020-2030.

Source : AIE (2025), *Energy and AI*.

Region	2020	2024	2030 (AIE)	Delta 24-30	Part mondiale 2024
Etats-Unis	~120 TWh	~180 TWh	~420 TWh	+240 TWh	45 pct
Chine	~60 TWh	~102 TWh	~280 TWh	+175 TWh	25 pct
Europe (UE)	~45 TWh	~70 TWh	~115 TWh	+45 TWh	15 pct
Monde	~270 TWh	~415 TWh	~945 TWh	+530 TWh	100 pct

Tableau 5. Ventes mondiales de semi-conducteurs, 2020-2026.

Sources : SIA/WSTS (fev. 2025, fev. 2026). La projection 2026 est basee sur la prevision automne 2025 du WSTS (975,4 milliards USD) et la declaration SIA de fevrier 2026.

Annee	2020	2022	2023	2024	2025	2026 (proj.)
Ventes (milliards USD, SIA)	440	556	527	631	792	~975-1000
Croissance (pct)	+6,8	+3,3	-8,2	+19,1	+25,6	+23-26

Tableau 6. Indicateurs de domination US dans le compute IA (snapshot tableau de bord avril 2026).

Sources : Epoch AI GPU Clusters dataset avril 2026 ; AIE (2025) ; Sanchez/GeoCoded (2025).

Indicateur	Etats-Unis	Chine	UE(13)	Ratio US/UE
Part H100-eq operationnel	76,9 pct	12,8 pct	4,4 pct	17,6:1
Part F_total (op + planifie)	49,9 pct	0,5 pct	3,3 pct	15,1:1
Part secteur prive (2025)	~65 pct mondial	~12 pct	~3 pct	~22:1
Conso centres de donnees 2024	180 TWh	102 TWh	70 TWh	2,6:1
Investissement IA 2025	320 mds USD (5 Big Tech)	n.d.	~20 mds EUR (UE total)	>15:1
CACI Power Mode (avril 2026)	100	15,7	28,9	3,46:1

Tableau 7. Chronologie des mesures reglementaires americaines sur les semi-conducteurs et l'IA (2022-2026).

Sources : BIS, Maison-Blanche, Pillsbury Law (2026), Gibson Dunn (2026).

Date	Admin.	Mesure	Perimetre / Cible
Oct. 2022	Biden	Controles export BIS : GPU avances, SME, US persons	Chine (militaire)
Oct. 2023	Biden	Renforcement seuils + extension 40 pays + HBM	Chine + 40 pays (D:1/D:4/D:5)
Dec. 2024	Biden	Vague 3 : 24 types SME, HBM, 140 entites, ECAD	Chine (chaîne complete)
Jan. 2025	Biden	AI Diffusion Rule : poids modeles, cloud, 3 paliers pays	120+ pays (effets UE inclus)
Jul. 2025	Trump	America's AI Action Plan : dereglementation, US compute	USA (strategie domestique)
Sep. 2025	Trump	Annonce : ventes Chine autorisees contre 25 pct revenus	Chine (monetisation)
Jan. 2026	Trump	Section 232 : tarif 25 pct GPU avances + licence BIS Chine	Mondial (exemption domestique US)

Notes

1. IEA (2025), Energy and AI, Paris, IEA. <https://www.iea.org/reports/energy-and-ai>. The 415 TWh figure includes all data centers (cloud, enterprise, colocation), not just AI-dedicated data centers. The IEA notes that consumption has grown by 12 percent per year since 2017.
2. IEA (2025), op. cit., chapter 'Energy demand from AI.' European Commission (November 2025), 'In Focus: Data Centres - An Energy-Hungry Challenge,' energy.ec.europa.eu. The 70 TWh figure for the EU is an IEA estimate in the absence of precise consumption data.
3. IEA (2025), op. cit.; Carbon Brief (September 2025), 'AI: Five Charts that Put Data-Centre Energy Use - and Emissions - into Context.' The 35-50 percent range comes from a report prepared for the IEA (Kamiya and Coroama, 2025, IEA-4E).
4. IEA (2025), op. cit. The IEA further notes that in its Headwinds scenario, global consumption would only reach 790 TWh, 40 percent less than the central scenario, illustrating the scale of uncertainty.
5. Federal Reserve Board (October 2025), State of AI Competition in Advanced Economies. The report documents a significant correlation between industrial energy costs and AI adoption rates, particularly for large European companies. The PPA-adjusted reference values (USA 85, China 92, France 115, Germany 140, EU aggregate 135 USD/MWh) are documented on the public dashboard.
6. IEA (2025), op. cit., chapter 'Case study: DeepSeek and efficiency gains.' The IEA concludes that algorithmic efficiency gains, while significant, tend to be absorbed by demand growth (Jevons paradox).
7. SIA (February 2025, revised March 2025), 'Global Semiconductor Sales Increase 19.1 percent in 2024.' The initial figure of 627.6 billion USD was revised to 630.5 billion USD by the WSTS.
8. SIA (February 2026), 'Global Annual Semiconductor Sales Increase 25.6 percent to 791.7 Billion USD in 2025.' Q4 2025 sales (236.6 billion USD) were 37.1 percent higher than Q4 2024, marking a notable acceleration.
9. McKinsey (January 2026), 'Hiding in Plain Sight: The Semiconductor Industry Expanding Perimeter.' The gap with the SIA is explained by the inclusion of captive designers and vertically integrated fabless operators.
10. SIA (July 2025), State of the U.S. Semiconductor Industry Report. The SIA notes that the Chips and Science Act has generated nearly 500 billion USD in announced private investment and is expected to create or support more than 500,000 jobs.
11. Pilz, K.F., Rahman, R., Sanders, J. and Heim, L. (2025), 'Trends in AI Supercomputers,' arXiv:2504.16026. The dashboard refresh of April 2026 reaches 786 catalogued clusters, of which 609 are operational and 171 are planned, representing 10 to 20 percent of estimated global capacity.
12. Sanchez, C. (2025), 'GeoCoded Special Report: State of Global AI Compute (2025 Edition),' Sanchez.vc. The May 2025 estimate cross-references Epoch AI and Georgetown University data and produced shares USA 74.5 / China 14.1 / EU 4.8. The April 2026 dashboard snapshot is based on the same data feed but with eleven additional months of cluster commissioning, which explains the small drift in shares.
13. Pilz et al. (2025), op. cit. Leading AI supercomputer performance doubles every nine months, driven by a 1.6x per year increase in chip count and a 1.6x per year increase in per-chip performance.
14. Epoch AI (January 2026), 'Global AI Power Capacity Is Now Comparable to Peak Power Usage of New York State.' The 30 GW estimate is based on quarterly AI chip sales x TDP x 2.5x infrastructure factor.
15. BIS (October 7, 2022), 'Commerce Implements New Export Controls on Advanced Computing and Semiconductor Manufacturing Items to the People Republic of China,' Federal Register. See also GAO (2025), 'Export Controls: Commerce Implemented Advanced Semiconductor Rules,' GAO-25-107386.
16. Skadden (October 2023), 'BIS Updates October 2022 Semiconductor Export Control Rules.' The new rules notably capture the A800 and H800, Nvidia chips specifically designed to fall just below the October 2022 thresholds.
17. Carnegie Endowment (May 2025), Winter-Levy, H. and Phillips-Robins, A., 'What Is the AI Diffusion Rule?' The AI Diffusion Rule remained in effect only briefly before being partially replaced by the Trump approach, but it established the precedent of control over models and cloud, not just physical chips.
18. White House (January 14, 2026), Presidential Proclamation 11002, 'Adjusting Imports of Semiconductors, Semiconductor Manufacturing Equipment, and Their Derivative Products into the United States.' The proclamation invokes Section 232 of the Trade Expansion Act of 1962 (19 U.S.C. 1862).

19. Pillsbury Law (January 2026), 'Trump Admin Targets Advanced AI Semiconductors, Defers Broader Tariffs.' The legal analysis notes that the combination of Section 232 and the BIS rule of January 15, 2026 operationalizes the September 2025 announcement that the US government would collect 25 percent of AI chip sales to China.

20. White House (January 14, 2026), Fact Sheet: 'President Donald J. Trump Takes Action on Certain Advanced Computing Chips to Protect America Economic and National Security.' Gibson Dunn (January 2026), 'The Trump Administration New Tariffs on and Export Licensing Requirements for Advanced Semiconductors.'

CHAPITRE IV - MECANISMES DE L'AVANTAGE CONCURRENTIEL US

CHAPITRE IV

Mecanismes de l'avantage concurrentiel americain par l'IA

Le chapitre III a etabli les faits : les Etats-Unis concentrent 76,9 pour cent du compute IA operationnel mondial (49,9 pour cent en incluant les clusters planifies), 45 pour cent de la consommation electrique des centres de donnees, et controlent 70 pour cent du marche cloud europeen via trois hyperscalers. Ce chapitre analyse les mecanismes par lesquels cette asymetrie de compute se traduit en avantage competitif mesurable. Nous identifions quatre canaux de transmission : les couts d'entrainement comme barriere a l'entree, la concentration cloud comme vecteur de dependance, la productivite differenciee selon les regions, et la captation des rentes d'innovation par les premiers entrants.

4.1 Les couts d'entrainement comme barriere a l'entree

4.1.1 L'explosion exponentielle des couts d'entrainement

Le canal le mieux documente est celui des couts d'entrainement des modeles de fondation. Martens (Bruegel, octobre 2024) etablit que le cout d'entrainement d'un modele de frontiere est passe de 1 000 USD en 2017 a pres de 200 millions USD en 2024, et pourrait atteindre plusieurs milliards d'ici 2030.[1] Cette croissance exponentielle suit les scaling laws identifiees par Kaplan et al. (2020) : l'amelioration de la performance cognitive des modeles est soumise a des rendements constants en intrants complementaires (parametres, donnees d'entrainement, capacite de compute). Autrement dit, chaque gain marginal de performance exige une augmentation proportionnelle du compute, des donnees et de la taille du modele.

Cottier et al. (2024), cites par Martens, decomposent les couts d'entrainement en cinq composantes : personnel, puces IA, cout des serveurs, interconnexion reseau et energie. Ils estiment les couts d'infrastructure (materiel plus centre de donnees) a dix fois le cout de l'entrainement lui-meme, avec un taux d'amortissement de 140 pour cent par an (amortissement complet en 8,5 mois, correspondant au rythme de renouvellement des generations de puces). L'infrastructure de GPT-4 fin 2023 etait estimee a environ 800 millions USD. Par extrapolation, les couts d'infrastructure pourraient atteindre 500 milliards USD d'ici 2030, repliques sur une demi-douzaine d'hyperscalers.[2]

4.1.2 L'avantage US : compute abondant et subventionne

Dans ce contexte, l'acces au compute de pointe devient le facteur discriminant. Les Big Tech americaines (Microsoft, Meta, Google, Amazon, xAI) ont collectivement investi 320 milliards USD en 2025 dans l'infrastructure IA (serveurs, centres de donnees, puces), contre 230 milliards USD en 2024.[3] Meta developpe un systeme de calcul IA dote de 350 000 processeurs H100, estime a plus de 10 milliards USD.

Comme le note Martens, cette barriere a l'entree est totalement hors de portee du financement public ; seules les plus grandes entreprises peuvent y aspirer.[4]

Pour les acteurs europeens, cette asymetrie se traduit concretement. Le cout d'entrainement d'un modele comparable a GPT-4 est estime a environ 100 millions USD aux Etats-Unis (avec acces direct au GPU, energie peu chere, amortissement sur une base installee massive). En Europe, le meme entrainement couterait 2 a 5 fois plus, en raison de : (i) un acces indirect au compute via le cloud US (marges des hyperscalers), (ii) des couts energetiques 1,4 a 1,7 fois superieurs apres correction PPA (et 2 a 3 fois superieurs sur les tarifs Eurostat industriels non ajustes - chapitre III), et (iii) l'absence d'economies d'echelle comparables. L'ecart de cout du FLOP (metrique CACI M2) est estime entre 2,4x et 3,6x une fois cumules les marges cloud, l'energie et l'amortissement, alors meme que le ratio energetique sous-jacent ajuste-PPA n'est que de 1,59x.[5]

4.1.3 Co-opetition forcee : startups europeennes et Big Tech US

Les couts exponentiels creent un mecanisme de dependance structurelle. Comme l'analyse Martens (Bruegel), les startups IA - y compris europeennes - sont contraintes de cooperer avec les Big Tech americaines pour acceder a l'infrastructure de calcul et aux canaux de distribution. Cette co-opetition (cooperation forcee avec un concurrent) place les startups dans une position subordonnee : elles dependent des plateformes US pour entrainer leurs modeles, puis se retrouvent en concurrence directe avec les modeles proprietaires de ces memes plateformes. La Competition and Markets Authority britannique (CMA, 2024) et la Commission europeenne ont identifie ces accords comme potentiellement anti-concurrentiels.[6] Azoulay et al. (2024), cites par Martens, soutiennent que le partage de ressources est la seule voie pour eviter la concentration, sauf si un acteur fox utilise l'ouverture comme strategie competitive - ce que Meta a partiellement fait avec LLaMA.

4.2 La concentration cloud comme vecteur de dependance geopolitique

4.2.1 Le marche cloud europeen : 70 pour cent sous controle US

Le second mecanisme est la concentration du marche cloud europeen. Synergy Research Group (juillet 2025) etablit que le marche europeen des services d'infrastructure cloud a atteint 61 milliards EUR en 2024 (multiplie par six depuis 2017) et devrait depasser 75 milliards EUR en 2025 (+24 pour cent). Amazon (AWS), Microsoft (Azure) et Google (GCP) representent 70 pour cent de ce marche. La part des fournisseurs europeens est passee de 29 pour cent en 2017 a 15 pour cent en 2022, ou elle stagne depuis.[7]

Parmi les fournisseurs europeens, SAP et Deutsche Telekom sont en tete avec environ 2 pour cent de part de marche chacun, suivis par OVHcloud, Telecom Italia et Orange. John Dinsdale, analyste en chef de Synergy, observe que les fournisseurs US investissent 10 milliards EUR par trimestre en capex europeen, et que les trois hyperscalers exploitent desormais plus de 140 centres de donnees hyperscale en Europe.[8] La croissance la plus rapide (140 a 160 pour cent) concerne les services specifiquement lies a l'IA generative (GPU-as-a-Service, GenAI PaaS), un segment ou les acteurs europeens sont quasi absents.

4.2.2 Du verrouillage commercial au verrouillage geopolitique

Cette concentration dépasse le simple enjeu commercial. Le concept de geopolitical vendor lock-in (défini au chapitre I) décrit une situation où la dépendance technique à un fournisseur étranger est aggravée par un risque réglementaire lié aux décisions souveraines du pays d'origine du fournisseur. Le CLOUD Act (2018) oblige les fournisseurs cloud américains à fournir aux autorités US les données hébergées sur leurs serveurs, y compris ceux situés en Europe. En mai 2025, la directrice juridique de Microsoft France a reconnu sous serment l'incapacité de garantir que les données des citoyens français ne seraient jamais transmises aux autorités américaines.[9]

Dans le contexte IA, le verrouillage géopolitique opère à trois niveaux. Au niveau infrastructure (IaaS), les charges IA sont déployées sur des serveurs physiquement contrôlés par des entités soumises à la juridiction américaine. Au niveau plateforme (PaaS), les frameworks d'entraînement et d'inférence sont intégrés dans des écosystèmes propriétaires (Azure ML, SageMaker, Vertex AI). Au niveau modèle (MaaS - Model-as-a-Service), l'accès aux modèles state-of-the-art (GPT-4, Claude, Gemini) passe par des API contrôlées par des entreprises US, avec des conditions de service modifiables unilatéralement. Le protectionnisme Section 232, en différenciant le coût de l'accès matériel, renforce simultanément les trois niveaux.

La distinction du chapitre I entre CACI Physique (F_{total}) et CACI Souverain (F_{dom}) est ici essentielle : alors que le compute UE opérationnel est largement détenu par des opérateurs UE (OVH, Scaleway, Sesterce, EuroHPC, AI Factories), les charges IA UE tournent majoritairement sur infrastructure détenue par les US. La dépendance ne porte pas sur le compute installé, mais sur le compute utilisé, et sur les couches plateformes et modèles superposées au-dessus.

4.2.3 Le rapport Draghi et le diagnostic européen

Le rapport Draghi (septembre 2024), commandé par la Commission européenne, constitue la reconnaissance institutionnelle la plus complète de cette dépendance. Draghi observe que les restrictions européennes sur le stockage et le traitement des données créent des coûts de conformité élevés et entravent la création de grands jeux de données intégrés pour l'entraînement de modèles IA. Il recommande la création d'une infrastructure cloud hyperscale européenne, la consolidation des fournisseurs cloud européens et un investissement massif dans l'IA, l'informatique quantique et les supercalculateurs EuroHPC.[10] Martens (Bruegel, 2025) modère toutefois cet optimisme, observant que les supercalculateurs EuroHPC ne sont pas conçus pour l'IA générative et que la mise à niveau aux standards compétitifs dépasse la capacité financière des budgets européens.[11]

4.3 Productivité différenciée : le dividende du compute abondant

4.3.1 Le potentiel macroéconomique théorique

Le troisième canal de transmission est l'impact de l'IA sur la productivité du travail et son asymétrie régionale. Le McKinsey Global Institute (mai 2024, décembre 2025) estime que l'IA générative pourrait permettre à l'Europe d'atteindre un taux de croissance annuel de la productivité de 3 pour cent d'ici 2030 dans un scénario d'adoption accélérée avec redéploiement proactif de la main-d'œuvre.[12] Ce chiffre suffit à combler l'essentiel de l'écart de productivité avec les États-Unis. Toutefois, dans un scénario d'adoption

lente, la croissance de la productivite ne serait que de 0,3 pour cent - proche des niveaux actuels et insuffisante pour financer le modele social europeen.

Le FMI (Working Paper, mars 2025) fournit une analyse plus granulaire.[13] En croisant les indices d'exposition des taches a l'IA (Felten et al., Eloundou et al.) avec les donnees sectorielles, le FMI estime des gains de productivite totale des facteurs (TFP) significativement plus eleves dans les economies avancees que dans les pays a revenu intermediaire, en raison de leur part plus elevee de valeur ajoutee dans les secteurs a forte exposition IA (services financiers, conseil, technologie) et de leurs niveaux salariaux plus eleves, qui justifient davantage l'automatisation. Les etudes microeconomiques sous-jacentes (essais randomises controles) montrent des gains allant de 14 pour cent pour les taches peu qualifiees a plus de 50 pour cent pour les ingenieurs logiciels.

4.3.2 L'ecart conditionne par l'acces au compute

Pourtant, la realisation de ces gains de productivite est conditionnee par l'acces au compute. C'est ici que l'asymetrie diagnostiquee au chapitre III produit ses effets. La Commission IA francaise (2024) estime l'impact potentiel de l'IA sur la croissance francaise a 1,3 point de pourcentage par an, par analogie avec les effets de l'electricite - mais cette estimation suppose un acces non contraint au compute de pointe. De meme, McKinsey (decembre 2025) conditionne le scenario optimiste europeen a une adoption acceleree qui implique des investissements massifs en infrastructure.[14]

L'ecart d'investissement est considerable. McKinsey (janvier 2026) estime que les grandes entreprises europeennes font face a un deficit annuel de 700 milliards USD en R&D et depenses en capital par rapport a leurs homologues americaines. Dans les seules technologies numeriques, les entreprises americaines ont investi 2 trillions EUR de plus que les entreprises europeennes sur la periode 2021-2025.[15] L'ecart annualise entre janvier 2024 et septembre 2025 s'eleve a 580 milliards EUR pour l'investissement corporate et 300 milliards EUR pour les startups et scale-ups.

Ce deficit d'investissement, combine a l'asymetrie de compute et aux couts energetiques, produit un ecart de productivite IA conditionnel. Dans notre modelisation, nous distinguons le potentiel theorique (identique pour US et UE avec des structures sectorielles comparables) et le potentiel realisable, qui depend de l'acces effectif au compute. Avec un CACI(US)/CACI(UE) de 3,46:1 en Power Mode (chapitre III) sur le snapshot du tableau de bord d'avril 2026, le potentiel realisable europeen est structurellement inferieur. Traduit en scores CACI normalises, l'UE se situe a 28,9 contre un benchmark US de 100, la France a 25,3, l'Allemagne a 5,4 - l'ecart n'est donc pas de 7 a 12 fois inferieur comme le suggeraient des analyses anterieures, mais precisement de 3,46 pour 1 en intensite competitive ajustee au compute, avec une variation forte entre Etats membres.

4.4 Captation des rentes d'innovation : un avantage auto-renforçant

4.4.1 Le mecanisme du first-mover advantage en IA

Le quatrième canal est le plus structurellement significatif à long terme. La théorie des général purpose technologies (GPT, Bresnahan et Trajtenberg, 1995) prédit que les early adopters d'une technologie générale captent des rentes d'innovation disproportionnées, qui deviennent auto-renforçantes via trois mécanismes.

Premièrement, les effets d'échelle des données. Les entreprises qui déploient l'IA en premier accumulent des données d'usage (boucles de rétroaction, fine-tuning) qui améliorent la performance de leurs modèles. Ces données sont non-rivales mais exclusives : une fois capturées par un acteur, elles ne profitent pas aux concurrents. McKinsey estime que 75 pour cent du potentiel économique de l'IA générative est concentré sur quatre fonctions clés (service client, développement logiciel, marketing, R&D), où les données d'usage sont particulièrement déterminantes.[16]

Deuxièmement, les effets de réseau de plateforme. Les hyperscalers US bénéficient d'un cercle vertueux : plus de clients mènent à plus de revenus, qui mènent à plus d'investissement en infrastructure, qui mènent à une meilleure offre, qui mènent à plus de clients. Ce mécanisme explique pourquoi, malgré les discussions sur la souveraineté numérique, la part des fournisseurs européens stagne à 15 pour cent : l'écart de qualité de service (latence, gamme de services, support technique, écosystème d'intégration) est trop important pour être comblé par les seuls arguments de souveraineté.

Troisièmement, la captation des talents. Les entreprises américaines offrent des packages de rémunération combinant salaires et equity qui attirent les meilleurs chercheurs et ingénieurs IA mondiaux, y compris européens. Martens note que le personnel IA qualifié est rare et que les entreprises se livrent à une concurrence féroce pour le recruter, avec des packages de rémunération difficiles à égaler pour les institutions européennes. Ce brain drain IA affaiblit le facteur $L(r)$ du CACI européen et renforce l'avantage américain en capital humain.[17]

4.4.2 Le risque d'irréversibilité

Ces trois mécanismes produisent un effet cumulatif potentiellement irréversible. Comme l'analyse l'OCDE (Martens, 2021) par analogie avec les vagues technologiques précédentes (internet haut débit, cloud), les retardataires dans l'adoption d'une technologie générale deviennent structurellement dépendants des plateformes étrangères, subissent des marges comprimées et perdent progressivement leur autonomie stratégique. La pénurie de semi-conducteurs de 2022, qui a coûté 100 milliards EUR au seul secteur automobile européen, illustre les conséquences concrètes d'une dépendance technologique non anticipée. [18]

La trajectoire est d'autant plus préoccupante que l'UE est absente de quatre des huit segments de la chaîne de valeur de l'IA générative tels que cartographiés par McKinsey (2024) : semi-conducteurs IA-design (dominés par Nvidia), plateformes cloud IA (AWS, Azure, GCP), modèles de fondation (OpenAI, Google, Anthropic, Meta) et outils de développement IA. Elle n'est compétitive que sur les segments d'application aval : applications sectorielles (SAP, Siemens), intégration industrielle, et semi-conducteurs spécialisés (semi-conducteurs de puissance : Infineon, STMicroelectronics, NXP, avec environ 15 pour cent de part de marché mondiale).[19]

4.5 Synthèse : la mécanique de l'avantage compétitif US

Les quatre canaux identifiés forment un système renforçant. L'asymétrie de compute (chapitre III) alimente des coûts d'entraînement différenciés (4.1), qui renforcent la dépendance au cloud US (4.2), qui contraint la productivité réalisable (4.3), qui ralentit l'investissement européen et renforce la captation des rentes par les acteurs américains (4.4), qui à son tour creuse l'écart de compute. Avec le snapshot d'avril 2026 - 76,9 pour cent de part de compute opérationnel, 1,59x de coût énergétique ajusté-PPA et un ratio CACI Power Mode de 3,46:1 - ce cercle constitue ce que Farrell et Newman (2019) décriraient comme une weaponisation de l'interdépendance structurelle : la dépendance européenne à l'infrastructure américaine, initialement fondée sur l'efficacité économique, devient un levier de pouvoir géopolitique lorsqu'elle est instrumentalisée par des mesures comme la Section 232.

Le protectionnisme Trump (chapitre III, phase 4) n'a pas créé cette asymétrie, elle préexistait massivement. Il l'institutionnalise et la légalise par un mécanisme tarifaire qui différencie le coût d'accès au compute selon la nationalité. Ce faisant, il transforme un avantage de fait en avantage de droit, dont le démantèlement est politiquement et juridiquement bien plus difficile. Le chapitre V examine comment ces mécanismes pourraient évoluer à travers quatre scénarios prospectifs.

Tableau 8. Marche cloud européen : domination des hyperscalers US.

Source : Synergy Research Group (juillet 2025).

Indicateur	2017	2022	2024	Tendance
Marche cloud UE (milliards EUR)	~10	~35	61	x6 en 7 ans
Part AWS+Azure+GCP	~50 pct	~67 pct	70 pct	Croissante
Part fournisseurs UE	29 pct	15 pct	15 pct	Stable (plancher)
Capex US en Europe	n.d.	n.d.	~40 mds EUR/an	10 mds EUR/trim.
Centres hyperscale en UE	~40	~80	>140	+75 pct en 2 ans

Tableau 9. Productivité IA et avantage compétitif : US vs UE (calibration avril 2026).

Sources : McKinsey (2024, 2025, 2026), Bruegel/Martens (2024), calibration CACI sur le tableau de bord public.

Dimension	Etats-Unis	Europe (UE)	Ecart
Productivité IA potentielle (McKinsey, scen. accel.)	+2,5-3,5 pct/an	+2,5-3,0 pct/an	Comparable
Productivité IA réalisable (sous contrainte compute)	+2,5-3,0 pct/an	+0,8-1,5 pct/an	-1,5 à -2 pts
Investissement annuel IA (corporate + VC)	~450 mds USD	~50-70 mds EUR	~7:1
Coût du FLOP (USD/TFlop, entraînement)	~0,5	~1,2-1,8	2,4-3,6x
CACI normalisé Power Mode (USA = 100)	100	28,9 (UE(13))	3,46:1

Notes

1. Martens, B. (2024), 'The Tension Between Exploding AI Investment Costs and Slow Productivity Growth,' Working Paper 18/2024, Bruegel, pp. 5-8. The time series is calibrated on Epoch AI training cost data for frontier models.

2. Cottier, B. et al. (2024), cited in Martens (2024), op. cit. The 10x factor between infrastructure and training costs is a central estimate, subject to variation based on post-training infrastructure utilisation.
3. IEA (2025), Energy and AI, Paris, p. 42. The IEA compiles investment announcements from Meta, Amazon, Alphabet, Microsoft and xAI for 2025.
4. Martens, B. (2024), 'Why Artificial Intelligence Is Creating Fundamental Challenges for Competition Policy,' Policy Brief 16/2024, Bruegel. Meta plans a system of 350,000 H100s (at about 30,000 USD per unit), i.e. over 10 billion USD in hardware alone.
5. Author estimate based on Bruegel (training costs), Eurostat (industrial electricity tariffs), EIA (US prices), the public dashboard PPA-adjusted reference values (USA 85, EU 135 USD/MWh), and Epoch AI (GPU performance/price). The 2.4 to 3.6x range stacks cloud markup (1.5 to 2x) on top of the 1.59x PPA-adjusted energy ratio and the absence of EU economies of scale; it depends on access mode (cloud vs on-premise) and PPA negotiations.
6. Competition and Markets Authority (2024), 'AI Foundation Models - Update Report,' London. The European Commission launched a call for contributions on competition in generative AI in 2024.
7. Synergy Research Group (July 2025), 'European Cloud Providers Local Market Share Now Holds Steady at 15 percent.' The market is defined as IaaS plus PaaS plus hosted private cloud.
8. Dinsdale, J. (2025), cited in Synergy Research Group, op. cit.: US cloud providers continue to invest 10 billion EUR every quarter in European capex, most of which comes from the big three.
9. Data Center Dynamics (July 2025), 'European Cloud Providers Hold 15 percent of Local Market Share.' The article reports the testimony of Anton Carniax, Microsoft France chief legal officer, before a parliamentary committee.
10. Draghi, M. (September 2024), The Future of European Competitiveness, report commissioned by the European Commission. Cited in Martens, B. (2025), 'Catch-Up with the US or Prosper Below the Tech Frontier? An EU Artificial Intelligence Strategy,' Bruegel Policy Brief.
11. Martens, B. (2025), op. cit. The author notes that the EuroHPC approach, centred on hardware, has characterised European digital policies for decades and is particularly poorly oriented regarding AI.
12. McKinsey Global Institute (May 2024), 'A New Future of Work: The Race to Deploy AI and Raise Skills in Europe and Beyond.' The 3 percent figure assumes an accelerated adoption scenario with full workforce redeployment.
13. IMF (March 2025), 'Artificial Intelligence and Productivity in Europe,' Working Paper WP/25/067. The analysis uses Felten et al. (2021) and Eloundou et al. (2024) exposure indices.
14. McKinsey (December 2025), 'Accelerating Europe AI Adoption: The Role of Sovereign AI Capabilities.' The report estimates European labor productivity growth at 0.2 percent on average over 2020-2025, versus a potential of 3.1 percent with full AI adoption.
15. McKinsey (January 2026), 'Transforming Europe: Bold Moves to Lift a Continent.' The 700 bn USD per year gap is calculated on the 150 largest technology companies (US vs EU) in capex plus R&D (S&P Capital IQ data).
16. McKinsey Global Institute (2024), 'The Economic Potential of Generative AI: The Next Productivity Frontier.' The four functions (customer service, software development, marketing/sales, R&D) represent about 75 percent of the identified economic potential across 63 use cases.
17. Martens, B. (2024), Working Paper 18/2024, op. cit. Personnel costs (salaries plus equity) are often the most significant component of AI model development costs.
18. McKinsey (October 2024), 'Time to Place Our Bets: Europe AI Opportunity.' The 100 bn EUR GDP loss figure for the European automotive industry comes from Allianz (September 2022) and OICA.
19. McKinsey (October 2024), op. cit. European semiconductors (Infineon, STMicro, NXP) represent about 15 percent of the global integrated design-manufacturing market (Omdia/Informa data, 2024), but primarily in power and automotive segments, not AI GPU/ASIC.

CHAPITRE V - SCENARIOS PROSPECTIFS 2026-2030

CHAPITRE V

Scenarios prospectifs 2026-2030

Ce chapitre constitue le coeur de la contribution originale de cette etude. En appliquant le protocole methodologique defini au chapitre II (matrice 2x2, six metriques de divergence, calibration CACI), nous construisons quatre scenarios d'evolution de la relation transatlantique en IA, energie et semi-conducteurs pour la periode 2026-2030. Chaque scenario est determine par la combinaison de deux incertitudes critiques identifiees au chapitre III : le degre de protectionnisme americain et la capacite de reponse strategique europeenne. Nous evaluons ensuite chaque scenario sur ses six metriques, avant de synthetiser les conditions de bascule entre trajectoires.

5.1 Elements predetermines : ce qui ne changera pas

Conformement a la methode Schwartz (1991), nous distinguons les elements predetermines (tendances quasi-certaines a l'horizon 2030) des incertitudes critiques (facteurs dont l'evolution depend de decisions politiques non encore prises). Quatre elements predetermines structurent l'ensemble des scenarios.

EP1 - Croissance exponentielle de la demande de compute IA. Les ventes de semi-conducteurs ont double en deux ans (2023-2025), la puissance des puces IA installees double tous les sept mois (Epoch AI), et aucun signe de ralentissement n'est observable au moment de fevrier 2026. Meme dans l'hypothese d'une deceleration des scaling laws (saturation Chinchilla), la diffusion de l'IA vers l'inference, la robotique et les agents autonomes maintiendra une demande de compute fortement croissante.[1]

EP2 - Concentration persistante du compute aux Etats-Unis. Le ratio US/UE de 17,6:1 en compute installe brut (chapitre III, snapshot du tableau de bord d'avril 2026 : 2 759 968 vs 156 632 PFLOP/s), se traduisant par un ratio CACI Power Mode de 3,46:1 une fois pondere par la formule geometrique $F^{0,40} \times L^{0,20} \times R^{0,15} / E^{0,25}$, reflete des decisions d'investissement prises en 2022-2025 dont les effets se materialisent jusqu'en 2028-2029 (delais de construction des centres de donnees : 18-36 mois). Meme un revirement politique immediat n'alterait pas le stock installe avant la fin de la decennie.

EP3 - Tension energetique croissante. La consommation mondiale des centres de donnees, estimee a 415 TWh en 2024, atteindra 800-950 TWh d'ici 2030 selon les projections AIE (chapitre III). L'asymetrie des couts energetiques (US 1,4-1,7x moins chers apres correction PPA, 2-3x moins chers sur les tarifs Eurostat industriels non ajustes) persistera, sauf investissement massif dans le nucleaire europeen, dont les delais de deployment (SMR : 5-7 ans pour les premiers reacteurs) depassent l'horizon 2030.[2]

EP4 - Cadre reglementaire Section 232 en place. La Proclamation 11002 du 14 janvier 2026 est un fait accompli juridique. Contrairement aux tarifs IEEPA (annules par la Cour supreme le 20 fevrier 2026[3]), les tarifs Section 232 reposent sur une base legale confirmee. Le rapport du Secretaire au Commerce sur le marche des semi-conducteurs pour centres de donnees est attendu d'ici le 1er juillet 2026, et peut

recommander une extension ou modification des tarifs. Quelle que soit la direction prise, l'instrument legal restera disponible.[4]

5.2 Incertitudes critiques et matrice 2x2

5.2.1 Axe 1 : Degre de protectionnisme americain

La premiere incertitude porte sur l'evolution de la politique americaine entre deux poles. Le pole modere correspond au maintien du statu quo de janvier 2026 : tarif de 25 pour cent limite aux puces avancees re-exportees, exemptions domestiques larges, accord commercial UE plafonnant les tarifs sur semi-conducteurs a 15 pour cent, et aucune extension significative au cloud ou aux modeles. Le coeur UE (France, Allemagne) reste dans la categorie partenaires de confiance. Le pole agressif suppose une extension apres le rapport de juillet 2026 : tarifs etendus aux semi-conducteurs derives et equipements, quotas GPU pour l'UE (incluant la France), conditions restrictives pour l'acces au cloud IA de pointe, et utilisation du compute comme levier de negociation commerciale (compute-for-concessions).[5]

5.2.2 Axe 2 : Capacite de reponse strategique europeenne

La seconde incertitude porte sur la capacite de l'UE a deployer une reponse coherente et rapide. Le pole reactif correspond a des reponses nationales fragmentees, des investissements disperses, un AI Act creant des couts de conformite supplementaires, et un deploiement lent des AI Factories/Gigafactories (delais bureaucratiques, autorisations 24+ mois). Le pole proactif suppose la mise en oeuvre acceleree du programme AI Continent (19 AI Factories plus jusqu'a 5 Gigafactories de 100 000+ GPU), l'adoption de Special Compute Zones (autorisation en 180 jours), la mobilisation effective du fonds InvestAI (20 milliards EUR), et la mise en commun de la capacite nucleaire francaise comme avantage competitif.[6]

5.2.3 Matrice et nommage des scenarios

L'intersection de ces deux axes produit quatre scenarios. UE reactive + protectionnisme US modere donne le scenario A (Statu quo renforce, derive lente vers la dependance). UE reactive + US agressif donne le scenario B (Fracture numerique, decouplage europeen structurel). UE proactive + US modere donne le scenario C (Partenariat asymetrique, partenaire technologique junior occidental). UE proactive + US agressif donne le scenario D (Souverainete contestee, course a l'autonomie sous pression).

5.3 Scenario A - Statu quo renforce (Protectionnisme modere + UE reactive)

5.3.1 Recit

Apres le rapport de juillet 2026, le Secretaire au Commerce recommande de maintenir le tarif de 25 pour cent sur les puces avancees re-exportees mais sans l'etendre significativement. L'accord commercial US-UE d'août 2025 est respecte : les tarifs sur semi-conducteurs pour l'UE restent plafonnes a 15 pour cent.[7] L'UE, rassuree par ce statu quo, ralentit le deploiement de ses propres initiatives. Les AI Factories EuroHPC peinent a atteindre leur capacite nominale (delais d'autorisation, coordination inter-Etats). Les Gigafactories

sont reportées à 2029-2030. Le fonds InvestAI est partiellement mobilisé (8-10 milliards EUR sur 20). Les entreprises européennes continuent de s'appuyer fortement sur le cloud US, dont la performance et les coûts restent imbattables.

5.3.2 Trajectoire des métriques

M1 - Ratio compute (GPU installés US/UE) : passe de 17,6:1 brut (2025) à 18-22:1 brut (2030) sur le compute installé opérationnel. L'écart se creuse légèrement à mesure que les investissements US s'accroissent (Stargate, mega-clusters xAI, Meta) tandis que l'UE n'ajoute que les 19 AI Factories (25 000 GPU max chacune, soit environ 475 000 GPU publics, un ordre de grandeur en dessous d'un seul hyperscaler US).[8]

M2 - Écart coût du FLOP (UE/US) : reste dans la fourchette 2,4-3,2x. L'absence de tarifs agressifs sur l'UE maintient l'accès au cloud US à des prix proches des niveaux actuels, mais les coûts énergétiques européens continuent de peser.

M3 - Part cloud US dans les dépenses IA européennes : passe de 70 pour cent (2024) à 72-75 pour cent (2030). Les fournisseurs européens (OVHcloud, Deutsche Telekom) conservent leurs 15 pour cent sur le segment souveraineté mais ne gagnent pas de terrain sur les services IA générative.

M4 - Productivité IA (pct/an) : US +2,5-3,0 ; UE +1,0-1,5. L'UE réalise une partie du potentiel IA via les applications aval (SAP, Siemens, fintech), mais l'adoption lente et le déficit de compute plafonnent les gains.

M5 - Dépendance énergétique (TWh centres de données) : UE environ 115 TWh en 2030 (+65 pour cent vs 2024). Le nucléaire français absorbe une partie de la demande, mais l'absence de Special Compute Zones retarde la connexion au réseau de nouveaux centres de données.

M6 - CACI(US)/CACI(UE) : passe de 3,46:1 (avril 2026) à 4-5:1 (2030). L'écart se creuse modérément à mesure que le facteur F (compute) s'accumule côté US tandis que les coûts E (énergie) pèsent côté UE.

5.3.3 Conséquences pour la France

Ce scénario est le plus probable à court terme (probabilité estimée : 40-50 pour cent). Il est aussi le plus insidieux : l'absence de choc visible démobilise les acteurs européens, tandis que la dépendance se creuse structurellement. Les entreprises françaises bénéficient de l'accès au cloud US pour l'adoption IA (BNP Paribas, Airbus, TotalEnergies via AWS/Azure), mais cette adoption renforce le verrouillage décrit au chapitre IV. Le déficit de productivité IA par rapport aux États-Unis (-1,0 à -1,5 points par an) s'accumule sur cinq ans, creusant l'écart de compétitivité de 5 à 8 points de PIB.

5.4 Scénario B - Fracture numérique (Protectionnisme agressif + UE réactive)

5.4.1 Recit

Le rapport de juillet 2026 conduit à une extension significative. Le Secrétaire au Commerce recommande des tarifs étendus aux équipements semi-conducteurs et produits dérivés, avec un tarif offset program réservé aux entreprises investissant dans la production américaine.[9] L'accord UE à 15 pour cent est révisé à la

hausse, ou accompagne de conditions restrictives (quotas de volume sur les GPU avances, exigences de reciprocite sur l'AI Act). Simultanement, l'accès au cloud IA de pointe est rendu conditionnel pour les entites non americaines (limitations d'accès aux API des modeles de frontiere, restrictions sur les poids). L'UE, fragmentee, ne parvient pas a formuler une reponse coherente : les Etats membres se divisent entre accommodation (pays nordiques, Pays-Bas) et confrontation (France, Italie).

5.4.2 Trajectoire des metriques

M1 - Ratio compute : passe de 17,6:1 brut (2025) a 25-35:1 brut (2030). Les quotas GPU limitent les importations europeennes au moment ou la demande explose. Les projets AI Factory sont compromis par l'incapacite a se procurer des GPU Nvidia/AMD aux volumes prevus.

M2 - Ecart cout du FLOP : bondit a 4-6x. Les tarifs etendus, combines aux quotas et a l'asymetrie energetique, augmentent massivement les couts du compute europeen. Les entreprises francaises font face a une surcharge de 3x a 5x pour l'entrainement de modeles.

M3 - Part cloud US : paradoxalement, monte a 78-82 pour cent. Faute d'alternative locale credible, les entreprises europeennes voulant acceder a l'IA de pointe doivent passer par les hyperscalers US, aux conditions tarifaires qu'ils dictent. Les services souverains (OVHcloud, Scaleway) manquent du materiel pour offrir des services GenAI competitifs.

M4 - Productivite IA : US +2,5-3,5 ; UE +0,3-0,8. Le potentiel IA europeen est severement contraint. Le McKinsey Global Institute estime qu'avec une adoption lente, la productivite europeenne ne depasserait pas 0,3 pour cent, proche de la stagnation.[10]

M5 - Dependance energetique : UE environ 95 TWh seulement (2030), non par vertu mais par default - le manque de GPU limite la construction des centres de donnees. Ironiquement, la contrainte de compute attene la contrainte energetique.

M6 - Ratio CACI : explose de 3,46:1 (avril 2026) a 6-8:1 (2030). C'est le scenario ou l'ecart est le plus important, avec les trois facteurs CACI se deteriorant simultanement cote europeen : F plafonne par les quotas, E gonfle par les tarifs, L affaibli par un brain drain accelere vers les Etats-Unis.

5.4.3 Consequences pour la France

Ce scenario (probabilite estimee : 15-20 pour cent) represente le pire des cas. La France subit un decouplage technologique structurel : les projets compute-intensifs (modeles de fondation Mistral, robotique Comau/Exotec, simulations Dassault) sont relocalises aux Etats-Unis ou dependent d'un acces au cloud US de plus en plus couteux. Le time-to-market des solutions IA francaises s'allonge de 25 a 40 pour cent. Les PME industrielles, incapables d'absorber les surcharges, renoncent a l'IA de pointe et optent pour des solutions degradees (modeles open-source plus petits, inference locale). L'ecart de productivite cumule avec les Etats-Unis atteint 10 a 15 points sur cinq ans.

5.5 Scenario C - Partenariat asymetrique (Protectionnisme modere + UE proactive)

5.5.1 Recit

Le protectionnisme US reste modere (comme en A), mais l'UE exploite cette fenetre pour accelerer ses propres investissements. Les AI Factories sont deployees dans les delais (2026-2027), les premieres Gigafactories de 100 000+ GPU sont commandeées fin 2026 et livrees en 2028.[11] La France joue un role central grace a son parc nucleaire (65-70 pour cent du mix electrique, cout marginal competitif), et des Special Compute Zones sont designees sur d'anciens sites industriels avec connexions reseau lourdes.[12] Toutefois, l'UE accepte de facto un statut de partenaire technologique junior : elle utilise des GPU Nvidia/AMD (pas de champion europeen en design d'ASIC IA), depend des fonderies TSMC/Samsung/Intel pour la production, et ses modeles de fondation restent un cran en dessous des leaders US.

5.5.2 Trajectoire des metriques

M1 - Ratio compute : descend de 17,6:1 brut (2025) a 8-10:1 brut (2030) sur le compute installe. Les Gigafactories et l'investissement prive (InvestAI plus co-investissements industriels) ajoutent 1-2 millions d'equivalents H100 en Europe, reduisant l'ecart sans le combler.

M2 - Ecart cout du FLOP : descend a 1,5-2,0x. Le nucleaire francais et les economies d'echelle des Gigafactories compriment les couts d'energie et d'infrastructure, bien qu'un ecart residuel persiste (absence de design GPU propriétaire).

M3 - Part cloud US : descend legerement a 60-65 pour cent. Les services souverains europeens gagnent des parts de marche sur les segments regules (defense, sante, finance), tandis que le cloud US conserve la majorite des charges commerciales. Le marche se segmente en souverain et performance.

M4 - Productivite IA : US +2,5-3,0 ; UE +1,8-2,5. L'UE atteint 60-80 pour cent de son potentiel theorique grace a un compute local suffisant pour l'adoption a grande echelle d'applications aval, meme si l'entrainement des modeles de frontiere reste dependant du materiel US.

M5 - Energie : UE environ 140 TWh (2030). La demande est plus elevee qu'en A car le compute europeen augmente, mais le nucleaire et les SMR planifies absorbent l'essentiel. RTE France confirme la faisabilite de +10 GW sous reserve d'investissements reseau.

M6 - Ratio CACI : descend de 3,46:1 (avril 2026) a 2,0-2,5:1 (2030). C'est le scenario le plus favorable realisement atteignable a l'horizon 2030. Le facteur F s'ameliore significativement, E beneficie du nucleaire, mais L reste legerement inferieur (l'ecosysteme IA US plus attractif pour les meilleurs talents).

5.5.3 Consequences pour la France

Ce scenario (probabilite estimee : 15-20 pour cent) est le plus favorable pour la France a court-moyen terme. La France devient le hub energetique IA de l'UE grace a son parc nucleaire, attirant les investissements en centres de donnees et Gigafactories. Les entreprises francaises gagnent un acces a un compute local competitif pour l'inference et le fine-tuning, reduisant la dependance au cloud US pour les usages standard. Mistral et les startups francaises peuvent entrainer des modeles specialises localement. Toutefois, l'entrainement des modeles de frontiere reste dependant du materiel US, et l'autonomie strategique est partielle : la France est souveraine en application, mais pas dans la creation des technologies fondamentales.

5.6 Scenario D - Souverainete contestee (Protectionnisme agressif + UE proactive)

5.6.1 Recit

Le protectionnisme US s'intensifie (comme en B), mais l'UE repond avec determination. La menace americaine devient le catalyseur politique d'une mobilisation industrielle europeenne sans precedent depuis le projet AIRBUS des annees 1970. Le programme AI Continent est accelere et etendu : les 5 Gigafactories sont commandeées en urgence, la France annonce 20 GW de capacite nucleaire dediee aux centres de donnees IA d'ici 2032 (combinant extension du parc existant et SMR), le projet DARE (RISC-V europeen) est escalade pour concevoir des accelerateurs IA reduisant la dependance a Nvidia.[13] Simultanement, l'UE negocie des alliances technologiques alternatives (Japon, Coree du Sud, Taiwan) pour securiser l'approvisionnement en GPU et fonderies.

5.6.2 Trajectoire des metriques

M1 - Ratio compute : evolue de 17,6:1 brut (2025) a 12-15:1 brut (2030) sur le compute installe. L'UE investit massivement mais part de tres loin. Les quotas US ralentissent les importations, mais les alliances alternatives et la production locale (Gigafactories utilisant des GPU Samsung/Intel comme alternatives a Nvidia) compensent partiellement.

M2 - Ecart cout du FLOP : 2,5-4,0x initialement (2027, pic du choc tarifaire), puis reduction progressive vers 1,8-2,5x (2030) a mesure que les Gigafactories montent en cadence et que les alternatives GPU murissent.

M3 - Part cloud US : descend a 50-55 pour cent (2030), le declin le plus prononce des quatre scenarios. La defiance geopolitique et les restrictions US poussent les entreprises europeennes vers les alternatives souveraines, meme imparfaites. Les hyperscalers US perdent du terrain sur les segments regules.

M4 - Productivite IA : US +2,5-3,5 ; UE +1,2-2,0. L'UE traverse un creux de productivite en 2027-2028 (periode de transition ou les restrictions US mordent mais les investissements europeens ne sont pas encore operationnels), puis un rattrapage partiel a partir de 2029.

M5 - Energie : UE environ 150-160 TWh (2030). C'est le scenario le plus energivore pour l'UE, la construction massive de centres de donnees locaux creant une demande enorme. Le nucleaire francais devient un actif strategique continental, mais la pression sur le reseau est maximale.

M6 - Ratio CACI : suit une trajectoire en U : degradation de 3,46:1 a 8-12:1 en 2027-2028 (pic du choc), puis amelioration vers 4-7:1 d'ici 2030. Le resultat depend fortement de la vitesse d'execution europeenne : chaque annee de retard sur les Gigafactories prolonge la periode de vulnerabilite maximale.

5.6.3 Consequences pour la France

Ce scenario (probabilite estimee : 15-20 pour cent) est le plus ambitieux et le plus risque. Il place la France au coeur d'un effort de souverainete technologique europeen sans precedent. Les investissements nucleaires massifs (SMR, extension du parc) deviennent un enjeu geopolitique de premier ordre. Le projet DARE/RISC-V pourrait, en cas de succes, constituer la premiere alternative europeenne credible aux GPU

Nvidia pour l'IA, mais sur un horizon de 5-7 ans, bien au-delà de 2030. A court terme (2026-2028), la France traverse une période de vulnérabilité maximale où les surcharges et pénuries dégradent la compétitivité, avant un rattrapage conditionnel à la vitesse de déploiement de l'infrastructure.

5.7 Synthèse comparative et conditions de bascule

5.7.1 Tableau de synthèse des métriques

Le Tableau 11 ci-dessous consolide la trajectoire des six métriques de divergence pour les quatre scénarios à l'horizon 2030, ancre sur le snapshot du tableau de bord d'avril 2026 (compute brut opérationnel US/UE 17,6:1, CACI Power Mode 3,46:1).

5.7.2 Conditions de bascule entre scénarios

La trajectoire réelle suivra probablement un chemin hybride entre ces scénarios. Trois points de bascule déterminent les transitions possibles.

Premier point de bascule : le rapport Commerce de juillet 2026. Ce rapport déterminera si le protectionnisme US s'étend (basculement vers B ou D) ou reste ciblé (maintien en A ou C). Indicateurs à surveiller : évolution du déficit commercial américain en semi-conducteurs, taux de remplissage des fabs CHIPS Act (Intel, TSMC Arizona, Samsung Taylor), pression politique intérieure (midterms 2026). Le résultat des négociations de Phase 1 (rapport du 14 avril 2026) sera un signal précoce.[14]

Deuxième point de bascule : la vitesse de déploiement des Gigafactories UE. La Commission prévoit les premières Gigafactories opérationnelles en 2027-2028. Si ce calendrier est tenu, l'UE bascule vers les scénarios proactifs (C ou D). Si les délais d'autorisation, de financement ou d'approvisionnement matériel repoussent les livraisons à 2029-2030, l'UE reste en mode réactif (A ou B). La proposition CFG des Special Compute Zones (autorisation en 180 jours vs 24+ mois actuellement) est le facteur d'accélération clé.[15]

Troisième point de bascule : la décision française sur le nucléaire pour l'IA. La France possède un atout unique en Europe : un parc nucléaire fournissant 65-70 pour cent de l'électricité, avec un coût marginal globalement compétitif. La décision de dédier une capacité significative (10-20 GW) aux centres de données IA, via l'extension du parc, les nouveaux EPR2 et les SMR, déterminera si la France devient le hub énergétique IA de l'Europe ou cède cette position à d'autres (Scandinavie avec l'hydroélectrique, Europe de l'Est avec des coûts fonciers bas). Ce point de bascule est spécifiquement français et détermine la position de la France au sein des scénarios européens.[16]

5.7.3 Le point de convergence : 2028

Les quatre scénarios convergent sur un point critique commun en 2028. C'est l'année où : (i) la demande de compute dépassera la capacité installée en Europe, créant des goulots d'étranglement matériels (même sous protectionnisme modéré) ; (ii) les premiers effets des tarifs étendus (s'ils sont adoptés) seront pleinement ressentis ; (iii) les Gigafactories, si elles sont déployées à temps, commenceront à produire un compute local significatif ; (iv) la demande énergétique des centres de données saturera la capacité de connexion au réseau dans plusieurs États membres. L'année 2028 constitue donc le moment de vérité où l'Europe découvrira si

elle est sur trajectoire A/B (dependance croissante) ou C/D (rattrapage commence). Les decisions prises en 2026-2027 (rapport Commerce US, Gigafactories, nucleaire francais) seront irreversiblement engagees.

5.8 Origines du point de bascule : fondations juridico-techniques deja en place

Le scenario du Grand Decouplage n'est pas construit ex nihilo. Il est la projection logique, a l'horizon 2028, d'une architecture de controle dont les couches fondationnelles sont deja operationnelles en 2026. Identifier ces couches releve de la rigueur academique : distinguer ce qui releve de tendances documentees de ce qui constitue une projection extrapolee.

5.8.1 La couche legale : l'extraterritorialite comme instrument structurel

La premiere couche est legale et precede largement la politique IA. Le CLOUD Act (Clarifying Lawful Overseas Use of Data Act, 2018) etablit que tout fournisseur de cloud soumis a la juridiction US est tenu de produire les donnees independamment du lieu ou ces communications, enregistrements ou autres informations sont stockes.[17] Cette loi, confirmee par la jurisprudence federale (United States v. Microsoft, resolu par l'adoption du CLOUD Act avant que la Cour supreme ne statue), cree une dissociation fondamentale entre la localisation physique des donnees et leur nationalite legale.

La consequence immediate pour le compute IA est radicale : un cluster H100 physiquement localise a Dubai, Singapour ou dans un centre AWS eu-west-1 en Irlande reste legalement americain. En cas d'ordre du gouvernement US, l'operateur (AWS, Azure, Google Cloud) est legalement tenu de se conformer, independamment de la volonte du client ou de la legislation locale. Microsoft a reconnu devant un tribunal francais en 2024 ne pas pouvoir garantir la souverainete des donnees pour les clients europeens en cas d'injonction US fondee en droit.[18]

Cette architecture legale preexistante est le substrat sur lequel se greffe le Pivot Cloud-Nationalite : les Cloud Sovereignty Mandates projetes pour 2028 ne creent pas un pouvoir nouveau. Ils activent et systematisent un pouvoir juridictionnel deja existant en l'etendant a la couche du compute operationnel.

5.8.2 La couche technique : de la verification de localisation au throttling de cluster

La seconde couche est technique. L'AI Action Plan US du 23 juillet 2025 introduit explicitement le concept de fonctionnalites de verification de localisation appliquees aux puces IA avancees. Michael Kratsios, directeur de l'OSTP de la Maison-Blanche, a confirme qu'il y a une discussion sur les types de modifications logicielles ou physiques que l'on pourrait apporter aux puces elles-memes pour faire un meilleur location-tracking, ce qui a ete explicitement inclus dans le plan.[19]

Cette annonce n'est pas rhetorique. Le BIS dispose deja, depuis le Framework for Artificial Intelligence Diffusion (janvier 2025, abroge en mai puis remplace par des mesures de guidance), d'une architecture de controle compute-tiering pour les pays de destination (Tier 1-2-3) et de plafonds de compute par entite et par pays.[20] La BIS Affiliates Rule, suspendue pour un an en novembre 2025 mais maintenue en principe,

stipule que l'affiliation d'une société à une entité mère dans un pays restreint suffit à lui refuser l'accès au compute avancé, indépendamment de la localisation physique du cluster.[21]

La trajectoire technologique vers 2028 est donc : (i) des puces équipées de mécanismes de vérification de localisation (logicielle ou matérielle), (ii) des systèmes de reporting automatique au BIS en cas de déviation, (iii) la capacité à suspendre l'accès ou throttler la performance via licence d'exportation, un cluster opérant sous licence d'exportation US potentiellement soumis à des restrictions opérationnelles par décision administrative. Ce n'est pas de la science-fiction : c'est l'extension au compute d'un principe déjà appliqué au logiciel (sanctions OFAC sur les licences logicielles, gel d'accès aux services cloud pour les entités listées).

Limitation critique de ce mécanisme. Une tension technique réelle doit être identifiée ici : throttler des clusters de production est techniquement complexe et potentiellement perturbant pour les opérateurs eux-mêmes. NVIDIA ne dispose pas actuellement de mécanisme de désactivation à distance pour les GPU H100/B200 en production. Un tel mécanisme exigerait une modification architecturale significative des firmware et des protocoles d'attestation à distance (via TPM ou équivalent). Le scénario 2028 est donc conditionnel à la mise en œuvre effective de ces modifications, hypothèse plausible sur 24-36 mois d'effort industriel, mais pas une certitude.

5.9 Le mécanisme du Pivot Cloud-Nationalité

5.9.1 Le déclencheur : Cloud Sovereignty Mandates comme extension des contrôles à l'exportation

Le scénario du point de bascule 2028 suppose que les États-Unis franchissent un palier qualitatif : passer du contrôle d'accès matériel (contrôles BIS sur les puces) au contrôle d'accès aux services de compute opérationnel (Cloud Sovereignty Mandates). Ce palier n'est pas une rupture arbitraire, il répond à une faille structurelle identifiée dans le régime de contrôle actuel.

Cette faille est documentée : malgré les restrictions BIS sur les exportations de H100/A100, des enquêtes ont révélé qu'environ 1 milliard USD de puces Nvidia ont été acheminées vers la Chine en contournant les contrôles à l'exportation via des pays tiers (Malaisie, ÉAU, Singapour) au cours des seuls premiers mois de 2025.[22] La réponse de l'AI Action Plan (fonctionnalités de vérification de localisation et monitoring de cluster) constitue le premier pas vers un contrôle continu post-exportation.

Le déclencheur plausible en 2028 est un executive order étendant les obligations du Framework for AI Diffusion à la couche cloud. Sa structure imposerait une certification Data Residency and Jurisdiction Compliance à tous les hyperscalers US opérant des clusters avancés offshore, avec révocation de l'accès au compute sur sol US comme mécanisme de mise en conformité, et le BIS se réservant le droit de throttler ou suspendre la performance des clusters autorisés en cas d'irrégularité.

5.9.2 La dissociation Facteur Physique / Facteur Souverain dans le CACI

C'est ici que le scénario produit son impact le plus analytiquement significatif sur le modèle CACI développé aux chapitres I à IV. Le modèle actuel intègre le compute $F(r)$ comme mesure de la capacité physiquement installée dans la région r . Sous activation du Pivot Cloud-Nationalité, cependant, la variable se décompose en

deux composantes distinctes : $F(r) = F_{\text{phys}}(r) \times F_{\text{sov}}(r)$, où F_{phys} est le compute physiquement installé dans la juridiction et F_{sov} est le facteur de souveraineté opérationnelle (fraction de F_{phys} hors juridiction US et donc insensible aux Cloud Sovereignty Mandates).

Notez la distinction entre ce F_{sov} dynamique 2028 et le CACI souverain statique introduit au chapitre I (Fig 1.8). Le CACI souverain du chapitre I a été calculé en filtrant les clusters Epoch AI par Owner : il capture qui détient le compute installé aujourd'hui (snapshot avril 2026). Le F_{sov} 2028 capture qui contrôle le compute sous un régime hypothétique de Cloud Sovereignty Mandates, qui dépend de la part des charges hyperscaler, pas de la capacité installée. Les deux métriques s'accordent là où le compute est détenu par des opérateurs domestiques (US, Chine, France domestique Fluidstack/Sesterce) ; elles divergent fortement pour les juridictions où les clusters domestiquement localisés sont détenus par des opérateurs US-side (EAU 99,6 pour cent, charges cloud UE majoritairement sur AWS/Azure/GCP).

Les estimations calibrées pour 2028, sous l'hypothèse d'activation des Cloud Sovereignty Mandates, sont présentées dans le Tableau 12 ci-dessous.

5.10 L'émergence de blocs IA juridictionnels (2028-2030)

Le Grand Decouplage ne produit pas un monde binaire US/non-US. Il produit une fragmentation en blocs d'intensité variable, selon la capacité de chaque zone à développer un compute souverain crédible. Quatre blocs émergent avec des caractéristiques distinctes.

5.10.1 Le bloc américain étendu (American AI Alliance)

L'AI Action Plan du 23 juillet 2025 pose explicitement les bases d'une American AI Alliance : exportation de la pile technologique US complète (matériel, modèles, logiciels, standards) aux alliés disposés, en échange de l'adoption de contrôles à l'exportation alignés.[23] La stratégie est explicitement décrite comme carrot and stick : les alliés alignés accèdent aux puces avancées et aux modèles de frontière sans restrictions supplémentaires ; ceux qui refusent sont exposés aux mécanismes Foreign Direct Product Rule et aux tarifs secondaires.

Membres du bloc américain étendu (Tier 1 confirmés) : États-Unis, Royaume-Uni, Canada, Australie, Japon, Corée du Sud, Pays-Bas, Allemagne, France (sous réserve d'alignement sur les contrôles à l'exportation). Pour ces pays, le F_{sov} effectif augmente : leurs entités accèdent aux hyperscalers US sans restriction, et le compute souverain en développement (Gigafactories UE pour l'Europe) reçoit un traitement préférentiel. Le CACI de ces pays n'est pas dégradé par les Mandates, il peut même bénéficier d'un effet d'alliance.

5.10.2 Le bloc souverain eurasien

La Chine constitue le seul exemple complet de bloc souverain préexistant. Avec un F_{sov} d'environ 0,98 et un écosystème cloud national (Alibaba Cloud, Tencent Cloud, Huawei Cloud) opérant hors de la juridiction US, les Cloud Sovereignty Mandates n'ont aucune traction directe. La contrainte chinoise reste la pénurie de puces avancées (les contrôles à l'exportation 2022-2025 ont limité l'accès aux GPU H100/A100/B200), mais le bloc américain ne peut pas throttler un cluster Huawei Ascend 910B.

La dynamique post-2028 : la Chine detient le seul compute souverain a grande echelle hors du bloc americain. Les pays cherchant a s'emanciper des Cloud Sovereignty Mandates se retrouvent structurellement face a une alternative binaire : compute americain conditionnel ou compute chinois sous d'autres formes de dependance. Cette contrainte binaire est l'impact geopolitique le plus profond du Grand Decouplage.

5.10.3 Les non-alignes numeriques : une position intenable

L'Inde, le Bresil, l'Asie du Sud-Est et les pays du Golfe (en l'absence de traites speciaux avec les Etats-Unis) constituent un bloc de non-alignement numerique. Leur position est structurellement inconfortable : trop dependants des hyperscalers US pour basculer vers la souverainete, insuffisamment integres a l'alliance americaine pour echapper aux restrictions en cas de desaccord geopolitique.

Le cas des EAU illustre cette fragilite avec une force quantitative. La Fig 1.8 du chapitre I a documente que 99,6 pour cent du F_total des EAU (22,9 millions d'equivalents H100) est detenu par des acteurs US-side (Stargate UAE, Microsoft, OpenAI), faisant s'effondrer le CACI souverain d'un Physique 55,7 a seulement 6,0. Dubai a investi massivement depuis 2022 pour devenir un hub IA regional, notamment via des accords avec AWS, Microsoft et G42. Pourtant, G42 a deja ete soumis a une intense pression US en 2024 pour rompre ses liens avec des entites chinoises, condition imposee par Washington pour l'acces aux puces avancees.[24] Sous Cloud Sovereignty Mandates, cette pression deviendrait systemique : le compute des hubs du Golfe, physiquement present mais legalement americain, deviendrait un levier de negociation permanent.

5.10.4 Le bloc europeen : entre alliance et autonomie

L'Europe occupe une position intermediaire et evolutive. Legalement Tier 1 (France, Allemagne, Pays-Bas, etc. sont explicitement dans la presumption d'approbation BIS pour les puces avancees), l'UE maintient neanmoins une ambition d'autonomie strategique que l'Alliance americaine ne satisfait pas pleinement.

Le Cloud and AI Development Act (CADA), dont la proposition formelle est attendue au T1 2026, tente de repondre a ce dilemme en definissant un EU Sovereignty Level qui exclurait structurellement les fournisseurs soumis au CLOUD Act des marches publics sensibles.[25] La Commission europeenne a publie en octobre 2025 un Cloud Sovereignty Framework definissant trois niveaux d'assurance (SOV-1 a SOV-3), avec SOV-3 exigeant que le fournisseur soit hors d'atteinte de toute legislation extraterritoriale non europeenne.[26]

Cette architecture legislative est en construction, mais son calendrier est problematique : le CADA sera au mieux operationnel en 2027-2028, precisement quand les Cloud Sovereignty Mandates US pourraient etre actives. La fenetre de vulnerabilite est maximale entre 2028 et 2030.

Une nuance importante du chapitre I : l'UE est largement souveraine sur le compute installe (99,2 pour cent du F_total est detenu par des operateurs UE). La fenetre de vulnerabilite n'est donc pas sur le F installe mais sur la couche des charges cloud (le compute reellement utilise par les entreprises UE, majoritairement heberge sur AWS/Azure/GCP). Le CADA cible exactement cette couche.

5.11 Impacts transversaux sur les scenarios A-D

Le Pivot Cloud-Nationalite se superpose aux quatre scenarios, modifiant leurs conclusions de maniere non-lineaire. Il n'invalide pas la matrice 2x2 mais ajoute une troisieme dimension : le degre d'autonomie du compute installe. Le Tableau 13 synthetise l'impact.

5.12 Implications pour la France : la question du compute reellement souverain

5.12.1 Le sovereignty washing comme risque systemique

Le terme sovereignty washing, popularise par Cristina Caffarra (Eurostack Foundation), designe la pratique des hyperscalers US qui commercialisent des offres sovereign cloud en implantant des centres de donnees sur sol europeen, tout en restant soumis au CLOUD Act.[27] Microsoft a reconnu dans sa propre documentation commerciale ne pas pouvoir garantir la souverainete pour les clients europeens en cas d'injonction US fondee en droit.[28]

Le Cloud Sovereignty Framework publie par la Commission en octobre 2025 commence a formaliser cette distinction. Le niveau SOV-3 exclut explicitement les entites soumises a une legislation extraterritoriale non europeenne. Mais si elle est maintenue dans le texte final du CADA, cette exigence excluerait de facto AWS, Azure et GCP des marches publics les plus sensibles, decision politiquement conflictuelle vis-a-vis des Etats-Unis.

5.12.2 L'avantage nucleaire francais dans la nouvelle equation

La reinterpretation souverainiste du CACI renforce paradoxalement l'atout strategique francais. Si $F(r)$ se decompose en $F_{phys} \times F_{sov}$, alors la strategie optimale de la France n'est pas seulement d'augmenter F_{phys} (attirer plus de centres de donnees hyperscaler) mais d'augmenter F_{sov} (developper du compute independant des juridictions US).

L'energie nucleaire francaise cree ici un avantage competitif de premier ordre : des Special Compute Zones adossees a une electricite nucleaire decarbonee et economiquement competitive, hebergeant des Gigafactories operees par des entites europeennes (OVHcloud, Scaleway, Mistral AI, IONOS), produiraient un compute avec un F_{sov} proche de 1, le seul compute genuinement hors d'atteinte des Cloud Sovereignty Mandates.

La decision-cle de la France en 2026-2027 n'est donc plus simplement combien de GPU mais combien de GPU sous juridiction francaise. Ces deux metriques peuvent diverger considerablement si la politique d'attraction des investissements reste indifferente a la nationalite legale des operateurs.

5.12.3 Le projet DARE/RISC-V : de l'ambition a la necessite strategique

Dans le cadre du scenario D et a fortiori sous Cloud Sovereignty Mandates, le projet DARE (Digital Autonomy with RISC-V in Europe, EuroHPC JU, 2025) change de statut : il n'est plus une ambition de long terme mais une necessite strategique.[29] Tant que l'Europe depend exclusivement des GPU NVIDIA/AMD pour son compute IA, le controle US sur ces architectures cree une vulnerabilite residuelle meme dans les Gigafactories operees par des entites europeennes, une mise a jour firmware imposee par NVIDIA dans le

cadre du programme location verification pourrait theoriquement degrader la performance des clusters europeens.

Ce risque est speculatif mais pas deraisonnable : il illustre la profondeur de la dependance architecturale. L'autonomie strategique authentique en compute IA exige in fine la capacite de concevoir des accelerateurs independants, horizon que le projet DARE situe a 2030-2032, bien au-dela du point de bascule 2028.

5.13 Synthese : le quatrieme point de bascule et les conditions d'un decouplage maitrise

Le Grand Decouplage n'est pas inevitable. Il represente un risque systemique conditionnel dont l'activation depend des choix politiques US et de la vitesse de reponse europeenne. Aux trois points de bascule identifies en 5.7.2, un quatrieme s'ajoute.

Quatrieme point de bascule : la mise en oeuvre des fonctionnalites de verification de localisation dans les GPU avances. Si le BIS et le Department of Commerce US, conformement a l'AI Action Plan de juillet 2025, parviennent a deployer des mecanismes d'attestation a distance dans les puces H100/B200/GB300 d'ici fin 2026-2027, le substrat technique du Pivot Cloud-Nationalite sera en place. La question ne sera plus de savoir si les Cloud Sovereignty Mandates sont techniquement faisables, mais uniquement s'ils sont politiquement decides. Ce point de bascule devrait etre surveille des 2026 : les premiers appels d'offres BIS/NIST sur les standards d'attestation a distance pour puces IA constitueront le signal precoce.

Pour l'Europe et la France, la strategie d'un decouplage maitrise repose sur trois piliers interdependants : (i) accelerer le deploiement du compute souverain (Gigafactories UE sous juridiction europeenne) pour augmenter F_sov avant l'activation des Mandates ; (ii) securiser le statut Tier 1 dans l'alliance americaine pour maintenir un acces sans restriction aux puces avancees, en acceptant la coordination sur les controles a l'exportation ; (iii) investir dans les alternatives architecturales (DARE/RISC-V, Huawei Ascend comme alternative court terme pour les charges non sensibles) pour reduire la dependance aux GPU US a moyen terme.

L'annee 2028 constitue le moment de verite non seulement pour les quatre scenarios initiaux mais pour une question plus fondamentale : l'Europe sera-t-elle capable de maintenir son acces au compute IA de pointe dans un monde ou la nationalite legale du compute prime sur sa localisation physique ? Les decisions prises en 2026-2027 (CADA, Gigafactories, energie nucleaire, alignement sur les controles a l'exportation) determineront si le Grand Decouplage est pour l'Europe une menace existentielle ou une opportinite de consolider son autonomie strategique.

Tableau 10. Matrice 2x2 des scenarios prospectifs 2026-2030.

Source : construction de l'auteur, methodologie Schwartz (1991).

	Reponse UE reactive	Reponse UE proactive
Protectionnisme US modere	Scenario A - Statu quo renforce (derive lente vers la dependance)	Scenario C - Partenariat asymetrique (partenaire technologique junior occidental)
Protectionnisme US agressif	Scenario B - Fracture numerique (decouplage europeen structurel)	Scenario D - Souverainete contestee (course a l'autonomie sous pression)

Tableau 11. Synthèse comparative des quatre scénarios sur les six métriques de divergence (horizon 2030).

Source : construction de l'auteur ; baseline snapshot avril 2026 (compute brut opérationnel US/UE 17,6:1, CACI Power Mode 3,46:1).

Métrique (2030)	A - Statu quo	B - Fracture	C - Partenariat	D - Souveraineté
M1 Ratio compute brut US/UE (opérationnel)	18-22:1	25-35:1	8-10:1	12-15:1
M2 Ecart coût du FLOP	2,4-3,2x	4-6x	1,5-2,0x	1,8-2,5x
M3 Part cloud US (pct)	72-75	78-82	60-65	50-55
M4 Productivité UE (pct/an)	+1,0-1,5	+0,3-0,8	+1,8-2,5	+1,2-2,0
M5 Énergie UE (TWh)	~115	~95	~140	~155
M6 Ratio CACI Power Mode	4-5:1	6-8:1	2,0-2,5:1	4-7:1 (post-croix)
Probabilité estimée	40-50 pct	15-20 pct	15-20 pct	15-20 pct

Tableau 12. Estimation du facteur F_sov par juridiction et impact CACI sous activation des Cloud Sovereignty Mandates (2028).

Source : construction de l'auteur ; Synergy Research Group (2025), Statista Enterprise Cloud (2025), et chapitre I Fig 1.8 pour le baseline souverain sur compute installé.

Juridiction	F_phys part cloud-US	F_sov estime	CACI actuel (baseline phys)	Impact CACI post-Mandate
Etats-Unis	~5 pct (cloud domestique non affecté)	1,00	100 (référence)	100 (inchange)
UE (France, Allemagne)	~77 pct (AWS/Azure/GCP dominent les charges UE)	0,28	28,9 (Power Mode)	Effondrement 30-50 pct sur les charges
EAU (hub Dubai)	~88 pct (hyperscalers US dominants)	0,12	55,7 phys / 6,0 souv sur installé	Effondrement 60-80 pct - hub illusoire
Singapour	~82 pct (hyperscalers US dominants)	0,18	élevé - hub APAC	Effondrement 55-75 pct
Chine	~2 pct (Alibaba/Tencent/Huawei Cloud)	0,98	15,7 (pénurie de puces plafonne)	Inchange - souveraineté déjà effective
Inde	~60 pct (AWS/Azure + locaux)	0,40	22,2 (Power Mode)	Effondrement modéré - position intermédiaire

Tableau 13. Impacts du Pivot Cloud-Nationalité (Cloud Sovereignty Mandates 2028) sur les quatre scénarios de la matrice 2x2.

Source : construction de l'auteur.

Scénario	Sans Mandates	Avec Mandates 2028	Impact CACI UE	Lecture stratégique
A - Statu quo	Dependance lente,	Activation partielle -	Dégradation	Plus stable mais

	CACI 4-5:1	hyperscalers coopèrent sans restriction majeure	moderee 15-25 pct sur les charges	illusion de securite revelee
B - Fracture	Decouplage structurel, CACI 6-8:1	Activation maximale - cloud US conditionnel et puces restreintes simultanement	Effet ciseau double : puces rares + compute conditionnel. Ratio CACI potentiellement > 8:1	Pire cas absolu - combo puces et cloud
C - Partenariat asymetrique	Rattrapage partiel, CACI 2,0-2,5:1	Gigafactories souveraines absorbent le choc si F_sov UE monte a 0,45-0,55	Impact limite si deploye dans les delais - Gigafactories = couverture souveraine	Meilleure resilience - investissement prealable prouve sa valeur
D - Souverainete contestee	Rattrapage sous pression, CACI 4-7:1 post-cieux	Mandates deviennent catalyseur politique - accelerent deploiement UE et alliances JP/KR/TW	Courbe en U acceleree - creux 2028-2029, rattrapage plus rapide	Paradoxal : les Mandates peuvent accelerer la souverainete UE si la reponse est assez rapide

Notes

1. Epoch AI (janvier 2026), Trends in AI Hardware and Compute. Le doublement tous les 7 mois de la production de puces IA combine 1,6x/an en quantite et 1,6x/an en performance par puce. Meme un ralentissement a 12 mois impliquerait un quadruplement d'ici 2030.
2. AIE (avril 2025), Energy and AI, Paris. Les projections 800-950 TWh correspondent aux scenarios median et haut de l'AIE. Le ratio energetique (1,4-1,7x apres correction PPA, 2-3x sur Eurostat brut) derive des valeurs de reference du tableau de bord public : USA 85, Chine 92, France 115, Allemagne 140, Royaume-Uni 190, UE 135 USD/MWh, toutes ajustees-PPA (chapitre II §2.4.6).
3. Cour supreme des Etats-Unis (20 fevrier 2026), Learning Resources Inc. v. Trump et V.O.S. Selections v. United States, decision 6-3 : 'IEEPA does not authorize the President to impose tariffs.' Voir Tax Foundation (2026), Tariff Tracker.
4. Maison-Blanche (14 janvier 2026), Proclamation 11002, section (2) : 'By July 1, 2026, the Secretary shall provide me with an update on the market for semiconductors used in United States data centers.'
5. Tax Foundation (fevrier 2026), op. cit. L'accord US-UE (aout 2025) plafonne les tarifs sur semi-conducteurs a 15 pour cent pour l'UE, mais la Proclamation 11002 prevoit explicitement des tarifs plus larges possibles apres la Phase 1.
6. Commission europeenne (2025), AI Continent Action Plan. Objectif : tripler la capacite des centres de donnees UE en 5-7 ans. 19 AI Factories selectionnees, jusqu'a 5 Gigafactories prevues. Fonds InvestAI : 20 milliards EUR. CFG (octobre 2025), 'Special Compute Zones' : autorisation en 180 jours.
7. Tax Foundation (fevrier 2026), op. cit. L'accord US-UE d'aout 2025 inclut un plafond de 15 pour cent sur les tarifs sur semi-conducteurs pour l'UE.
8. EuroHPC JU (2025). Les 19 AI Factories prevoient jusqu'a 25 000 GPU chacune (sites standards). Meme a pleine capacite, cela represente environ 475 000 GPU, moins que le seul cluster xAI Colossus (200 000 GPU H100, extensible). Segler Consulting (juin 2025) estime la capacite publique totale UE a environ 57 000 accelerateurs en 2025.
9. Proclamation 11002, section sur le tariff offset program. Snell & Wilmer (fevrier 2026), 'The Continued Utilization of Tariffs to Control the Semiconductor Industry.'
10. McKinsey Global Institute (mai 2024), op. cit. Le chiffre de 0,3 pour cent correspond au scenario d'adoption lente, proche du niveau actuel de croissance de la productivite en Europe occidentale.

11. Conseil de l'UE (decembre 2025), adoption de la position sur le reglement amende pour les Gigafactories IA. Le calendrier provisoire place les premiers appels d'offres fin 2025 et les premieres installations operationnelles en 2027-2028.
12. CFG (octobre 2025), 'Tripling the EU Data Centre Stock with Special AI Compute Zones.' La proposition prône la reutilisation de sites industriels desaffectés avec connexions réseau lourdes.
13. EuroHPC JU (mars 2025), projet DARE (Digital Autonomy with RISC-V in Europe), programme de 6 ans. Trois projets de processeurs par des entreprises distinctes.
14. Proclamation 11002, section (2) : le Secrétaire au Commerce et l'USTR doivent fournir un rapport sur l'état des négociations dans les 90 jours, soit le 14 avril 2026.
15. CFG (octobre 2025), op. cit. Le délai moyen d'autorisation pour un centre de données dans l'UE est actuellement de 24+ mois (vs 6-12 mois aux Etats-Unis). La proposition SCZ réduirait ce délai à 180 jours via un guichet unique.
16. RTE (2024), Futurs energetiques 2050, scenario N03. La France prévoit +10 GW de demande pour les centres de données d'ici 2030. L'avantage nucléaire français (65-70 pour cent du mix) est unique en Europe.
17. Clarifying Lawful Overseas Use of Data (CLOUD) Act, Pub. L. 115-141 (23 mars 2018), Title III, section 103(a). Disposition codifiée à 18 U.S.C. section 2713.
18. Microsoft France, Tribunal judiciaire de Paris (2024) - reconnaissance que la société ne peut garantir la souveraineté des données pour les clients européens en cas d'injonction US fondée en droit. Cite dans The Register (22 decembre 2025).
19. Michael Kratsios, directeur OSTP, déclarations publiques au APEC Digital and AI Ministerial Meeting, Seoul (aout 2025), cite dans TechResearchOnline (5 aout 2025), 'US AI Chip Tracking Plan.'
20. Bureau of Industry and Security, U.S. Department of Commerce, Framework for Artificial Intelligence Diffusion, Federal Register vol. 90, no. 10 (15 janvier 2025), ECCN 3A090.a - plafonds de compute de 50 000 equivalents H100 par pays Tier 2, 1 700 equivalents H100 par entité.
21. BIS, 'Suspension of the Affiliates Rule for One Year' (10 novembre 2025). La règle, bien que suspendue, conserve son architecture de contrôle et peut être réactivée par décision administrative.
22. Financial Times (25 juillet 2025), 'Nvidia AI chips worth \$1bn smuggled to China after Trump export controls' - rapport sur les circuits de contournement via la Malaisie, les EAU et Singapour dans les 6 premiers mois de 2025.
23. Maison-Blanche, Executive Order on Promoting the Export of the American AI Technology Stack (23 juillet 2025). L'AI Action Plan détaille la stratégie carrot and stick.
24. US Department of Commerce, accord G42/Microsoft (2024) - G42 (Abu Dhabi) a accepté de se désinvestir de ses partenariats avec des entités chinoises comme condition d'accès aux puces NVIDIA avancées. Confirme par les déclarations de la Secrétaire au Commerce Gina Raimondo.
25. Commission européenne, Programme de travail 2026, Cloud and AI Development Act (CADA), prévu T1 2026.
26. Commission européenne, Cloud Sovereignty Framework (octobre 2025), niveaux SOV-1 à SOV-3, publié dans le cadre du Cloud III Dynamic Purchasing System.
27. Cristina Caffarra, Eurostack Foundation, citée dans The Register (22 decembre 2025) : 'A company subject to the extraterritorial laws of the United States cannot be considered sovereign for Europe.'
28. Voir note 18.
29. EuroHPC JU, projet DARE (Digital Autonomy with RISC-V in Europe), lancé en mars 2025, programme de 6 ans.

CHAPITRE VI - CONSEQUENCES POUR LA FRANCE ET L'EUROPE

CHAPITRE VI

Consequences pour la France et l'Europe

Les chapitres precedents ont etabli le diagnostic (III), les mecanismes (IV) et les trajectoires possibles (V). Ce chapitre decline les consequences concretes pour les acteurs francais et europeens, en distinguant trois niveaux d'analyse : la declinaison sectorielle (quels secteurs sont les plus exposes ?), la differenciation par type d'acteur (grands groupes, PME, startups, secteur public), et les effets de second ordre (brain drain, delocalisation de la R&D, fragmentation normative). L'analyse s'appuie principalement sur le scenario A (le plus probable) et le scenario B (le plus severe), tout en signalant les bifurcations propres aux scenarios C et D.

6.1 Analyse sectorielle : exposition differenciee a l'asymetrie de compute

6.1.1 Services financiers : dependance avancee

Le secteur financier francais est le plus avance dans l'adoption de l'IA et, paradoxalement, le plus expose au risque de vendor lock-in geopolitique. BNP Paribas, Societe Generale, Credit Agricole et AXA deployent massivement des solutions IA pour la detection de fraude, le scoring credit, le trading algorithmique et l'optimisation des risques. AXA et BNP Paribas comptent parmi les premiers clients entreprises de Mistral AI en France.[1] Ces deploiements reposent en grande partie sur l'infrastructure cloud US (AWS pour BNP Paribas, Azure pour Societe Generale). Les gains de productivite observes dans le secteur financier mondial sont parmi les plus eleves (le FMI cite des gains microeconomiques de 20 a 40 pour cent sur les taches de conformite et d'analyse), car il s'agit d'un secteur a forte intensite cognitive et a hauts salaires - deux facteurs qui maximisent le retour sur investissement de l'automatisation.[2]

Le risque specifique au secteur financier est double. D'une part, les regulations europeennes (DORA, AI Act, RGPD) imposent des exigences de localisation et d'auditabilite qui creent une tension avec la dependance au cloud US : les banques francaises doivent garantir que les donnees de leurs clients ne sont pas accessibles aux autorites americaines (CLOUD Act), tout en dependant d'AWS et Azure pour la puissance de calcul. D'autre part, sous scenario B, un rencherissement de l'acces au cloud IA de pointe frapperait directement les applications les plus intensives en compute (modeles de risque, simulations Monte Carlo, entraînement de LLM specialises). L'ecart de productivite avec les banques americaines (JPMorgan, Goldman Sachs, qui investissent chacune plusieurs milliards par an dans l'IA) se creuserait de 3 a 5 points supplementaires par an.

6.1.2 Industrie automobile et aeronautique : compute-intensif et vulnerable

L'industrie automobile europeenne a deja subi un precedent revelateur : la penurie de semi-conducteurs de 2022 a coute environ 100 milliards d'euros au seul secteur auto UE (chapitre IV). L'IA transforme ce secteur

sur trois axes : conduite autonome (entraînement de modèles de perception, nécessitant des dizaines de milliers de GPU), optimisation de la production (digital twins, maintenance prédictive), et conception assistée (simulation aérodynamique, crash tests virtuels). Stellantis (issu de PSA) a signé un partenariat de 100 millions d'euros avec Mistral AI pour intégrer l'IA dans l'ensemble de ses métiers, du transport à la logistique.[3]

L'aéronautique (Airbus, Safran, Thales, Dassault Aviation) présente un profil similaire mais aggravé par la dimension défense. Les simulations aérodynamiques complexes, la maintenance prédictive de flottes et la conception de systèmes d'armes autonomes sont des applications extrêmement intensives en compute. Airbus s'appuie sur AWS et Azure pour ses workloads cloud. Sous scénario B, les restrictions sur les GPU avancées toucheraient directement les capacités de simulation ; sous scénario D, la pression pour rapatrier les workloads sur infrastructure souveraine créerait des coûts de transition considérables mais réduirait la vulnérabilité stratégique.

6.1.3 Santé et sciences de la vie : enjeu de souveraineté des données

Le secteur de la santé présente une vulnérabilité différente : l'intensité en compute est moindre (sauf pour la découverte de médicaments par IA, qui nécessite des clusters GPU massifs), mais la sensibilité des données est maximale. L'Espace européen des données de santé (EHDS) encadre strictement le traitement des données médicales. Sanofi, l'un des premiers groupes pharmaceutiques mondiaux, a investi 1 milliard de dollars dans des partenariats IA (dont OpenAI et Owkin, startup française spécialisée en IA pour la recherche clinique).[4] Novo Nordisk, bien que danois, illustre l'enjeu européen : plus de 8,2 milliards de dollars de R&D en 2024, avec un recours croissant à l'IA pour les digital twins du corps humain et l'accélération de la découverte de médicaments.[5]

L'impact des scénarios de protectionnisme est ici indirect mais structurel. Si l'accès aux GPU de pointe est restreint, les projets de drug discovery par IA (qui nécessitent des entraînements de modèles de plusieurs semaines sur des milliers de GPU) seront ralentis ou délocalisés vers les États-Unis. Owkin, fondée à Paris, a déjà ouvert des bureaux à New York et pourrait y transférer ses workloads les plus intensifs en compute si les coûts européens devenaient prohibitifs.

6.1.4 Robotique et industrie manufacturière : le facteur énergie

La robotique IA et l'automatisation industrielle ajoutent une dimension énergétique supplémentaire. L'entraînement de modèles de perception et de contrôle pour robots industriels est compute-intensif, mais c'est surtout le déploiement à grande échelle de robots équipés d'IA (edge computing, inférence embarquée) qui multiplie la demande énergétique industrielle. La convergence data centers + edge compute + robots pourrait ajouter 20 à 30 pour cent à la demande énergétique industrielle d'ici 2030 (chapitre III), une estimation encore peu quantifiée mais reconnue comme variable de sensibilité critique.

La France possède des acteurs significatifs : Exotec (robotique logistique, valorisée à plus de 2 milliards d'euros), Wandercraft (exosquelettes), Aldebaran/SoftBank Robotics (robots humanoïdes, fondée en France). Ces entreprises dépendent du hardware IA (GPU Nvidia, puces spécialisées) pour entraîner et déployer leurs systèmes. Sous scénario B, les quotas de GPU affecteraient directement le rythme d'innovation ; sous les

scenarios C et D, l'investissement dans les Gigafactories europeennes fournirait le compute necessaire, mais avec un retard de 2 a 3 ans sur les concurrents americains.

6.2 Differentiation par type d'acteur

6.2.1 Grands groupes : beneficiaires contraints

Les grandes entreprises francaises (CAC 40 et SBF 120) sont les premieres beneficiaires de l'IA a court terme et les plus exposees a la dependance a moyen terme. Elles disposent des budgets pour acceder au cloud US et des equipes pour deployer l'IA, mais cette adoption renforce le vendor lock-in a chaque iteration. Le cout de migration (switching cost) d'un ecosysteme cloud complet (AWS vers OVHcloud, par exemple) est estime a 12-18 mois de developpement et des millions d'euros de rearchitecture, ce qui le rend economiquement irrationnel sauf contrainte reglementaire forte. Sous scenario A, ils continuent d'adopter l'IA via le cloud US, accumulant une dependance croissante mais beneficant de gains de productivite reels. Sous scenario B, le rencherissement soudain du compute les place face a un dilemme : absorber les surcouts (compression des marges) ou ralentir les projets IA (perte de competitivite).

6.2.2 PME et ETI industrielles : exclusion progressive

Les PME et entreprises de taille intermediaire representent le tissu industriel francais (4 000 ETI, 140 000 PME). Leur acces a l'IA de pointe est deja contraint par les couts : un entrainement de modele specialise coute plusieurs centaines de milliers d'euros, hors de portee de la plupart des PME sans subvention. McKinsey (decembre 2025) observe que les gains de productivite IA sont concentres dans les grandes entreprises, creant un fossé de productivite intra-europeen entre les entreprises adoptees et les non-adoptees.[6] Sous scenario B, la hausse des couts de compute elargit ce fossé : les PME renoncent a l'IA de pointe et optent pour des solutions degradees (modeles open-source legers, inference locale sur hardware limite), perdant progressivement en competitivite face aux PME americaines qui beneficent du compute domestique exempté de tarifs.

Les AI Factories EuroHPC, concues pour donner la priorite d'accès aux startups et PME, pourraient atténuer cet effet (scenarios C et D). Mais leur capacite totale (environ 475 000 GPU, ordre de grandeur d'un seul hyperscaler US) est insuffisante pour servir l'ensemble du tissu economique europeen. Le gap entre l'offre publique de compute et la demande du marche est structurellement deficitaire.[7]

6.2.3 Startups IA francaises : entre championnat et dependance

L'ecosysteme startup IA francais est le plus dynamique d'Europe. Mistral AI, valorisee a 11,7 milliards d'euros (serie C de septembre 2025, menee par ASML), est le champion europeen de l'IA generative.[8] L'entreprise a leve 2,8 milliards d'euros au total, emploie environ 700 personnes, et developpe Mistral Compute, une plateforme cloud souveraine avec 18 000 GPU Nvidia Grace Blackwell deployees dans un data center de 40 MW en Essonne, alimente par l'energie nucleaire francaise.[9] En fevrier 2026, Mistral a annonce un investissement de 1,2 milliard d'euros pour un data center en Suede (Borlange), et l'acquisition de la startup Koyeb pour renforcer Mistral Compute.[10]

Le cas Mistral illustre à la fois le potentiel et les limites de la souveraineté IA européenne. Côté potentiel : l'entreprise prouve qu'une startup européenne peut atteindre l'échelle mondiale, attirer des investissements massifs (ASML, Nvidia, Bpifrance, a16z), et construire une infrastructure compute propre. Côté limites : Mistral reste dépendante des GPU Nvidia (pas d'alternative européenne pour les accélérateurs IA), a initialement utilisé Microsoft Azure et Google Cloud pour l'entraînement, et son investisseur Microsoft détient une position stratégique (conversion d'un investissement de 15 millions EUR). L'entreprise illustre la souveraineté de niveau applicatif (modèles, plateformes, services) sans souveraineté de niveau hardware - précisément la position de junior partner décrite dans le scénario C.

Au-delà de Mistral, l'écosystème français comprend Hugging Face (valorisé à 4,5 milliards de dollars, plateforme d'hébergement de modèles, siège à Paris mais infrastructure aux États-Unis), LightOn (modèles spécialisés pour l'entreprise), H Company (anciennement Holistic AI), Owkin (IA pour la santé), et Scaleway (cloud souverain français, premier accès européen aux GPU Nvidia Blackwell). Le financement IA en Europe a progressé de 55 pour cent au premier trimestre 2025, avec 12 nouvelles licornes au premier semestre. La France est pour la cinquième année consécutive la première destination européenne pour les investissements étrangers en IA.[11]

6.2.4 Secteur public et défense : l'imperatif de souveraineté

Le secteur public français représente un cas à part. Le ministère des Armées a lancé en février 2025 GenAI.intradef, un agent conversationnel sécurisé basé sur Mistral AI.[12] La Direction générale de l'armement (DGA) et l'ANSSI travaillent sur des cadres de classification pour l'IA souveraine. Pour la défense et le renseignement, la dépendance au cloud US est inacceptable quel que soit le scénario : les workloads classifiés doivent être exécutés sur infrastructure nationale. Ce marché captif fournit un socle de demande garanti pour les fournisseurs cloud souverains (OVHcloud S3ns, Thales S3ns, Scaleway), mais sa taille reste limitée par rapport au marché commercial.

6.3 Effets de second ordre

6.3.1 Brain drain et captation du talent IA

L'asymétrie de compute produit un effet d'attraction du talent vers les États-Unis. Les chercheurs et ingénieurs IA européens sont attirés par : (i) les packages de rémunération américains (salaire + equity), qui sont structurellement supérieurs aux standards européens ; (ii) l'accès au compute de pointe, condition nécessaire pour la recherche frontière ; (iii) l'écosystème (proximité des Big Tech, VC, communauté de recherche). Martens (Bruegel) note que le coût du personnel (salaires + equity) est souvent la composante la plus importante du coût de développement d'un modèle IA, et que les entreprises US se livrent une concurrence féroce pour recruter les meilleurs talents mondiaux.[13]

Ce brain drain affaiblit directement le facteur $L(r)$ du CACI européen. Il est partiellement compensé par l'excellence des formations françaises (ENS, Polytechnique, INRIA, universités parisiennes) qui forment un flux continu de talents - mais une proportion significative part aux États-Unis après leur doctorat. Mistral AI, fondée par des alumni de DeepMind et Meta, illustre la possibilité de retenir (ou rapatrier) des talents, mais

c'est l'exception plutôt que la règle. Sous scénarios C et D, le déploiement de Gigafactories et de Mistral Compute pourrait créer un écosystème suffisamment attractif pour retenir davantage de talents.

6.3.2 Delocalisation de la R&D

L'asymétrie de compute produit une pression à la delocalisation des activités de R&D les plus intensives en calcul. Ce phénomène est déjà observable : les plus grands centres de R&D IA des entreprises européennes sont souvent situés aux États-Unis (Bosch AI à Sunnyvale, SAP AI à Palo Alto, DeepMind à Londres mais propriété de Google). Sous scénario B, cette pression s'intensifie : 15 à 20 pour cent des projets IA critiques pourraient être delocalisés vers les États-Unis (notamment vers les zones à proximité des fabs Nvidia/TSMC en Arizona, ou des data centers de Virginie). Sous scénarios C et D, la delocalisation est atténuée par la disponibilité de compute local, mais ne disparaît pas complètement car l'écart de coût FLOP reste positif en faveur des États-Unis dans tous les scénarios.

6.3.3 Fragmentation normative : l'AI Act comme arme à double tranchant

L'AI Act européen, entre en application progressive depuis 2024, produit des effets ambivalents dans le contexte du protectionnisme américain. D'un côté, il crée des coûts de conformité supplémentaires pour les entreprises européennes (transparence des modèles, gestion des droits d'auteur dans les données d'entraînement, audits de sécurité). Draghi (2024) a observé que les restrictions européennes sur les données créent des coûts élevés et freinent l'entraînement des modèles. Martens (Bruegel, 2025) note que l'AI Omnibus risque de prolonger l'incertitude réglementaire pendant au moins deux ans supplémentaires. [14]

De l'autre côté, l'AI Act crée une barrière à l'entrée pour les concurrents américains - un effet protectionniste involontaire qui pourrait favoriser les acteurs européens conformes par design (Mistral, dont les modèles transparents et auditablement alignés sur l'AI Act). Le Code of Practice sur les droits d'auteur et les données d'entraînement, publié en juillet 2025, impose des contraintes que les modèles fermes (OpenAI, Anthropic) ont plus de difficulté à satisfaire. Sous scénarios B et D, où la méfiance géopolitique est maximale, l'AI Act pourrait devenir un outil de facto de préférence européenne, de manière analogue au RGPD qui a favorisé l'émergence de solutions européennes dans le traitement des données personnelles.

6.4 L'écosystème France IA : atouts uniques et vulnérabilités structurelles

L'analyse différenciée des sections précédentes permet de dresser un bilan des atouts et vulnérabilités spécifiques de la France dans le contexte du protectionnisme IA, présenté dans le Tableau 15.

Côté atouts, la France dispose d'avantages comparatifs uniques en Europe : un parc nucléaire (65-70 pour cent du mix électrique) qui produit une électricité compétitive et bas-carbone, un champion IA générative (Mistral AI valorisé 11,7 milliards EUR) avec ASML comme partenaire industriel, des formations d'excellence (ENS, Polytechnique, INRIA, CNRS/IDRIS, plus de 150 startups passées par Jean Zay), 109 milliards EUR d'engagements privés IA annoncés lors du Sommet de février 2025, et la première destination européenne pour les investissements IA étrangers (cinq années consécutives).

Cote vulnerabilites, la France reste structurellement dependante : absence de champion hardware IA (pas de GPU/ASIC design), compute installe limite (environ 5 pour cent du global pour la France seule, ratio US/France de l'ordre de 30:1 - coherent avec le ratio US/EU(13) brut de 17,6:1 puisque la France represente la majorite du compute UE installe), brain drain post-doctoral vers les US, permitting lent (24+ mois), reseau electrique sous tension (+10 GW necessaires selon RTE), dependance cloud US sur 70-80 pour cent des charges IA, et surcouts de conformite AI Act dans un contexte d'incertitude reglementaire (omnibus 2+ ans).

6.5 Synthese : la France face a trois futurs

L'analyse de ce chapitre converge vers trois configurations possibles pour la France a l'horizon 2030, correspondant aux trajectoires des scenarios du chapitre V.

Configuration 1 : Consommatrice dependante (scenarios A et B). La France adopte l'IA via le cloud US, gagne en productivite a court terme, mais accumule une dependance structurelle qui la place en position de vulnerabilite face a tout durcissement americain. Les grands groupes prosperent mais sont captifs ; les PME sont progressivement exclues de l'IA de pointe ; les startups les plus prometteuses delocalisent leur infrastructure aux Etats-Unis. Le brain drain s'accelere. L'ecart de productivite avec les Etats-Unis se creuse de 5 a 15 points cumules sur cinq ans.

Configuration 2 : Hub energetique et applicatif (scenario C). La France exploite son avantage nucleaire pour devenir le centre de gravite energetique de l'IA en Europe. Mistral Compute et les Gigafactories fournissent un compute local competitif pour l'inference et le fine-tuning. Les entreprises francaises sont souveraines dans l'application mais dependantes du hardware US. Sur le compute brut, le ratio US/UE descend de 17,6:1 en 2025 vers 8-10:1 en 2030 ; sur le CACI Power Mode, l'ecart se referme de 3,46:1 vers 2,0-2,5:1. Le brain drain est ralenti par l'existence d'un ecosysteme local attractif.

Configuration 3 : Pilier de la souverainete europeenne (scenario D). Le protectionnisme americain catalyse une mobilisation inedit. La France, grace a son nucleaire, ses formations d'excellence et Mistral, devient le pilier d'un effort de souverainete technologique europeen. L'investissement massif (20 GW nucleaire dedie, RISC-V/DARE, alliances Japon-Coree) cree les conditions d'un rattrapage a long terme, mais la periode de transition (2026-2028) est douloureuse. Le risque d'execution est maximal : chaque annee de retard dans les infrastructures prolonge la vulnerabilite.

Le chapitre VII elaborera les recommandations strategiques correspondant a chacune de ces configurations, en distinguant les mesures de court terme (adaptees quel que soit le scenario) des investissements structurels (dependants de la trajectoire choisie).

Tableau 14. Exposition sectorielle francaise a l'asymetrie de compute IA.

Source : construction de l'auteur, calibration sur le tableau de bord public (avril 2026).

Secteur	Intensite compute	Sensibilite donnees	Dependance cloud US	Risque scenario B
Finance	Elevee	Tres elevee	70-80 pct	Lock-in + surcouts : - 3 a -5 pts productivite/an
Auto/Aero	Tres elevee	Elevee	60-70 pct	Simulations

				ralenties, delocalisation R&D
Sante/Pharma	Haute (drug disc.)	Maximale	40-60 pct	Drug discovery delocalisee US
Robotique/Indus.	Elevee	Moderee	50-65 pct	Ralentissement innovation + surcout energie
Defense/Spatial	Tres elevee	Critique	Variable	Vulnerabilite strategique maximale

Tableau 15. Bilan atouts / vulnerabilites de la France dans le contexte du protectionnisme IA.

Source : synthese de l'auteur, calibration sur le tableau de bord public (avril 2026).

Atouts France	Vulnerabilites France
Energie nucleaire (65-70 pct du mix) : cout competitif, bas carbone, deploiement data centers	Absence de champion hardware IA (pas de GPU/ASIC design) : dependance Nvidia/AMD
Champion IA generative : Mistral AI (11,7 Md EUR valoris., Mistral Compute, ASML partenaire)	Compute installe : France environ 5 pct du global ; ratio US/France brut de l'ordre de 30:1
Formation d'excellence : ENS, X, INRIA, CNRS/IDRIS (Jean Zay, 150+ startups)	Brain drain post-doctorat vers US (salaires + equity + compute)
109 Md EUR d'engagements privs IA (Sommet fevrier 2025)	Permitting lent (24+ mois), reseau electrique sature (+10 GW besoin RTE)
1ere destination UE investissements IA etrangers (5 ans consecutifs)	Dependance cloud US : 70-80 pct workloads IA sur AWS/Azure/GCP
AI Act : conformite par design de Mistral (open-source, auditabilite)	AI Act : surcouts conformite, incertitude reglementaire (omnibus 2+ ans)

Notes

- Mistral AI (2025), communiques de partenariats. AXA et BNP Paribas figurent parmi les premiers adoptants entreprises de Mistral en France. Voir NVIDIA Blog (juin 2025), 'France Bolsters National AI Strategy With NVIDIA Infrastructure'.
- FMI (mars 2025), op. cit. Les services financiers sont parmi les secteurs a plus forte exposition IA (indices Felten et Eloundou), avec des gains microeconomiques documentes de 20-40 pour cent sur les taches de conformite et d'analyse de risque.
- Mistral AI / Wikipedia FR (2026). Stellantis (issu de PSA et Fiat-Chrysler) a signe un partenariat de 100 millions EUR avec Mistral AI en avril 2025. CMA CGM a egalement conclu un partenariat de 100 millions EUR.
- Sanofi (2024-2025), communiques de presse. Owkin, fonde a Paris en 2016, est specialise dans l'IA pour la recherche clinique et la decouverte de medicaments.
- McKinsey (janvier 2026), 'Transforming Europe: Bold Moves to Lift a Continent'. Novo Nordisk : plus de 8,2 milliards USD de R&D en 2024, utilisation de digital twins et d'IA pour la drug discovery.
- McKinsey (decembre 2025), 'Accelerating Europe's AI Adoption'. Le rapport observe que les gains de productivite IA sont concentres dans les entreprises lighthouse, avec des gains atteignant 40 pour cent de productivite du travail et 50 pour cent de reduction des delais.
- Segler Consulting (juin 2025), 'Europe's AI Gambit'. La capacite publique totale UE est estimee a environ 57 000 accelerateurs en 2025, soit un ordre de grandeur inferieur a l'infrastructure d'un seul hyperscaler US.
- Mistral AI (septembre 2025), serie C : 1,7 milliard EUR leves, valorisation 11,7 milliards EUR. ASML investisseur principal (1,3 milliard EUR pour environ 11 pct). Autres investisseurs : DST Global, a16z, Bpifrance, General Catalyst, Index Ventures, Lightspeed, Nvidia.

9. Introl Blog (decembre 2025), 'France's AI Sovereignty Push'. Mistral Compute : 18 000 GPU Grace Blackwell, data center 40 MW en Essonne (heberge par Scaleway/Eclairion), alimente par energie nucleaire. Lancement prevu 2026.
10. Mistral AI / Wikipedia FR (fevrier 2026). Data center de Borlange (Suede) : 1,2 milliard EUR, prevu pour 2027, via EcoDataCenter (energie renouvelable). Acquisition de Koyeb (17 fevrier 2026) pour renforcer l'offre serverless de Mistral Compute.
11. Dealroom (2025), cite dans FinTech Weekly. Financement IA en Europe +55 pct au T1 2025, 12 nouvelles licornes au S1 2025. La France est 1ere destination UE pour les investissements etrangers en IA depuis 2020.
12. Ministere des Armees (fevrier 2025), lancement de GenIAI.intradef. Agent conversationnel securise base sur Mistral AI, deploye sur infrastructure souveraine.
13. Martens, B. (2024), Working Paper 18/2024, Bruegel, op. cit. Le cout du personnel IA (salaires + equity) est souvent la composante la plus importante du developpement d'un modele, et les entreprises americaines offrent des packages structurellement superieurs.
14. Martens, B. (2025), 'The European Union Needs More Than the Digital Omnibus to Make Digital Services Competitive', Bruegel. L'AI Omnibus, cense acclereler les changements reglementaires, risque de prendre au moins un an pour etre adopte, plus un an pour les lignes directrices complementaires.

CHAPITRE VI BIS - CONSEQUENCES POUR L'AMERIQUE DU SUD ET LE BRESIL

CHAPITRE VI BIS

Consequences pour l'Amerique du Sud et le Bresil

L'analyse des chapitres precedents s'est concentree sur l'axe transatlantique US-Europe. Or, les consequences du protectionnisme IA americain s'etendent bien au-dela de l'OCDE. L'Amerique du Sud, et le Bresil en particulier, constituent un cas d'etude revelateur : a la fois marche dynamique pour l'IA, terrain de competition geopolitique US-Chine, et region structurellement dependante du compute etranger tout en disposant d'atouts energetiques uniques. Ce chapitre complementaire analyse les consequences specifiques du regime protectionniste sur l'Amerique du Sud, avec un focus approfondi sur le Bresil.

6bis.1 Position structurelle : le Sud global face a l'asymetrie de compute

6bis.1.1 Un ecosysteme en croissance rapide mais structurellement dependant

L'Amerique latine represente 6,6 pour cent du PIB mondial, mais n'attire que 1,12 pour cent de l'investissement mondial en IA - un ratio de 5,9 qui mesure le deficit d'investissement de la region.[1] Pourtant, les indicateurs d'adoption sont remarquablement dynamiques. L'indice latino-americain de l'intelligence artificielle (ILIA 2025), publie par la CEPALC et le CENIA chilien, classe trois pays comme pionniers (Chile, Bresil, Uruguay), huit comme adoptants (dont Colombie, Equateur, Costa Rica), et un tiers comme explorateurs avec des ecosystemes naissants.[2] La region represente 14 pour cent des visites mondiales de solutions IA et se classe troisieme mondiale pour les telechargements d'applications d'IA generative.

Cette dynamique d'adoption contraste avec un deficit infrastructurel considerable. Les pays a revenu eleve hebergent 77 pour cent de la capacite mondiale de data centers en colocation (juin 2025), contre 18 pour cent pour les pays a revenu intermediaire superieur et 5 pour cent pour les pays a revenu intermediaire inferieur.[3] Les pays a haut revenu concentrent egalement 87 pour cent des modeles IA notables, 86 pour cent des startups IA et 91 pour cent du capital-risque IA, alors qu'ils ne representent que 17 pour cent de la population mondiale. L'Amerique latine se situe dans la categorie intermediaire : consommatrice dynamique d'IA, mais quasi-entierement dependante de l'infrastructure etrangere (americaine et, de plus en plus, chinoise) pour le compute.

6bis.1.2 Classification Tier 2 : les caps d'accès au compute US

Dans le cadre de l'AI Diffusion Rule de janvier 2025 (administration Biden), l'ensemble de l'Amerique latine - y compris le Bresil, le Mexique et le Chili - est classe Tier 2, c'est-a-dire soumis a des caps quantitatifs sur les importations de GPU avancees. Le Tier 1 (accès illimité) est reserve a 20 allies proches (Australie, Canada, France, Allemagne, Japon, etc.). Le Tier 3 (accès interdit) vise la Chine, la Russie et une vingtaine de pays.[4]

Pour l'Amerique du Sud, cette classification Tier 2 signifie que les projets de data centers IA de grande envergure sont plafonnes en volume de GPU importables. Les caps initiaux de l'AI Diffusion Rule etaient d'environ 50 000 GPU entre 2025 et 2027 pour l'ensemble des pays Tier 2 (individuellement), un volume nettement insuffisant pour alimenter les megaprojets annonces. Brookings observe que meme pour les pays Tier 2 les plus favorises (Bresil, Inde), les caps americains signifient que leurs besoins en compute ne seront vraisemblablement pas satisfaits de maniere constante.[5] Bien que l'administration Trump ait rescinde l'AI Diffusion Rule en mai 2025 sans encore publier de regle de remplacement, l'incertitude reglementaire cree un risque d'approvisionnement qui pese sur les decisions d'investissement. Le BIS a publie en juillet 2025 l'America's AI Action Plan qui promeut l'export de full-stack AI export packages vers les allies, tout en durcissant l'application vers les adversaires.[6]

6bis.2 Le Bresil : hub emergent entre deux blocs

6bis.2.1 Atouts structurels du Bresil pour l'IA

Le Bresil possede des avantages competitifs objectifs pour l'infrastructure IA. Son mix electrique est renouvelable a 83 pour cent (essentiellement hydroelectrique, complete par l'eolien et le solaire en forte croissance), avec un cout de l'electricite competitif a environ 0,08 USD/kWh. Le reseau electrique national interconnecte (SIN) dispose de capacites excedentaires, et le pays possede une base de cables sous-marins de telecommunications (notamment le hub de Fortaleza) offrant l'une des routes les plus courtes vers l'Europe et l'Afrique.[7]

Le marche bresilien des data centers est le plus important d'Amerique latine, representant plus de 41 pour cent des investissements regionaux. La capacite IT installee a atteint environ 1 GW fin 2025, avec 202 projets actifs et 23 acheves prevus d'ici fin 2026. Le marche des data centers IA specifiquement est evalue a 0,55 milliard USD en 2025, projete a 1,24 milliard d'ici 2030 (croissance annuelle de 17,5 pour cent).[8] L'Association bresilienne des data centers (ABDC) projette que la demande d'energie des data centers pourrait atteindre 13,7 GW d'ici 2035.

Le gouvernement Lula a pris des mesures concretes pour accelerer le developpement. En septembre 2025, la mesure provisoire Redata a ete adoptee, creant un regime fiscal special qui reduit de 50 pour cent le cout du capital pour les data centers via l'exoneration des impots sur les actifs IT, avec des avantages valides jusqu'a decembre 2026. Le Plan bresilien d'intelligence artificielle (PBIA) vise a transformer le pays en hub mondial de data centers, et la BNDES (Banque nationale de developpement) a lance un fonds dedie IA et data centers avec un capital initial de 500 millions a 1 milliard de reaux (93-187 millions USD).[9]

6bis.2.2 Megaprojets et dualite US-Chine

Le Bresil est devenu le theatre d'une competition directe entre investissements americains et chinois en infrastructure IA, une dualite qui revele les dynamiques creees par le protectionnisme US.

Cote chinois, le projet le plus spectaculaire est le data center TikTok-ByteDance de Pecem (Ceara), annonce en decembre 2025 : 200 milliards de reaux (environ 38 milliards USD), en partenariat avec le developpeur Omnia (Patria Investments) et le producteur d'energie renouvelable Casa dos Ventos.[10] Le projet, dont la

construction doit debuter en avril 2026, sera alimente entierement par de l'energie eolienne (300 MW initiaux, extensibles a 900 MW voire 1 GW). Il constitue le plus gros investissement prive en data center jamais annonce au Bresil et le premier projet de ByteDance en Amerique latine. L'investissement s'inscrit dans un contexte ou TikTok fait face a des menaces de blocage aux Etats-Unis et ou la Chine cherche a diversifier ses infrastructures de compute hors de sa zone de risque geopolitique directe.

Cote americain, Microsoft a annonce un investissement de 2,7 milliards USD sur trois ans en infrastructure cloud et IA au Bresil, dans le cadre de son engagement global de 50 milliards USD pour le Sud global d'ici 2030.[11] AWS et Google disposent deja de regions cloud au Bresil (Sao Paulo). Les hyperscalers US controlent environ 55 pour cent du marche bresilien du cloud (AWS, Azure, GCP), une domination moindre qu'en Europe (70 pour cent) mais suffisante pour structurer la dependance.

D'autres megaprojets illustrent l'ampleur des ambitions. Scala Data Centers a annonce l'AI City d'Eldorado do Sul (Rio Grande do Sul), avec 1 800 MW de capacite et un potentiel de 5 000 MW d'ici 2033. Elea Data Centers developpe la Rio AI City, presentee comme le plus grand campus de data centers d'Amerique latine, avec 1,8 GW de capacite d'ici 2027 et 3,2 GW d'ici 2032, avec Oracle et Nvidia comme partenaires technologiques.[12]

6bis.3 Impact du protectionnisme US sur l'Amerique du Sud

6bis.3.1 Le double bind de la classification Tier 2

La position Tier 2 du Bresil et de l'Amerique du Sud cree un double bind strategique. D'un cote, les caps d'importation de GPU limitent la capacite des pays a construire une infrastructure IA souveraine et a realiser les megaprojets annonces. De l'autre, les restrictions americaines vers la Chine (Tier 3) poussent ByteDance et d'autres acteurs chinois a investir massivement en Amerique latine comme zone alternative de deployment d'infrastructure. Le Bresil devient ainsi un terrain de substitution dans la rivalite sino-americaine.

Brookings avertit que cette situation pourrait pousser les pays Tier 2 a developper des chaines d'approvisionnement independantes des Etats-Unis, y compris des liens technologiques plus forts avec la Chine.[13] Le Bresil, dont la Chine est le premier partenaire commercial, illustre parfaitement cette dynamique. L'investissement TikTok-Pecem, le plus gros investissement technologique chinois en Amerique latine, s'inscrit dans un approfondissement des liens Chine-Bresil qui preexistait a la reelection de Trump mais qui s'est accelere face aux politiques commerciales americaines.

6bis.3.2 Cinq canaux d'impact

L'impact du protectionnisme IA americain sur l'Amerique du Sud se transmet par cinq canaux distincts, dont certains sont propres a la region.

Canal 1 - Contrainte directe sur le hardware IA. Les caps Tier 2 sur les GPU de pointe limitent la capacite de construction. Meme si l'AI Diffusion Rule est rescindee, l'incertitude reglementaire pese : les projets necessitant 10 000 a 100 000 GPU (comme Scala AI City ou Elea Rio AI City) dependent entierement de la volonte americaine de livrer des accelerateurs Nvidia ou AMD. Le GAIN AI Act, actuellement en discussion au

Congres americain, propose de donner la priorite d'acces aux semi-conducteurs avances aux consommateurs americains avant de satisfaire les commandes internationales - ce qui degraderait encore l'approvisionnement de la region.[14]

Canal 2 - Dependance au cloud US renforcee. En l'absence d'infrastructure locale suffisante, les entreprises bresiliennes recourent massivement au cloud US. Le secteur financier bresilien (Itau, Nubank, Bradesco) est le plus numerise d'Amerique latine, avec 95 pour cent des transactions traitees numeriquement chez Itau Unibanco. L'Open Banking bresilien connecte 800 institutions. Cette numerisation repose en grande partie sur les hyperscalers US, creant le meme schema de dependance que pour l'Europe (chapitre IV), mais avec moins de capacite de negociation.

Canal 3 - Bifurcation technologique US-Chine. Le Bresil est confronte a un risque specifique : la fragmentation de son infrastructure IA entre ecosystemes americain et chinois. Les data centers de Pecem (ByteDance), bien qu'alimentes par de l'energie renouvelable bresilienne, utiliseront vraisemblablement du hardware Huawei ou des alternatives non-US si les restrictions americaines empechent l'export de GPU Nvidia vers des projets chinois. Cette dualite hardware cree des problemes d'interopabilite, de souverainete des donnees (CLOUD Act americain versus loi chinoise sur la securite des donnees), et de standardisation. Le Bresil risque de devenir un espace ou deux ecosystemes technologiques incompatibles coexistent, fragmentes et chacun dependant d'une puissance exterieure.

Canal 4 - Brain drain amplifie. L'ILIA 2025 signale un elargissement du fosse de talent IA en Amerique latine depuis 2022, associe a une acceleration du brain drain de specialistes.[15] Le Bresil forme d'excellents ingenieurs (USP, Unicamp, ITA), mais le differentiel de remuneration avec les Etats-Unis est encore plus marque que pour l'Europe. L'asymetrie de compute aggrave ce drain : les chercheurs IA qui restent au Bresil n'ont pas acces au compute necessaire pour la recherche frontier, ce qui renforce l'attractivite des laboratoires americains.

Canal 5 - Fosse de productivite elargi. La Banque mondiale et l'OIT observent que l'Amerique latine souffre d'un deficit de productivite persistant, en grande partie lie aux barrieres a l'innovation et a l'adoption technologique.[16] Si les pays a revenu eleve captent les gains de productivite IA (FMI : gains TFP significativement plus eleves dans les economies avancees), le protectionnisme IA risque de transformer ce qui etait un retard d'adoption (buffer temporaire) en barriere structurelle (bottleneck). L'acces contraint au compute de pointe empeche les entreprises latino-americaines de realiser les gains de productivite theoriques de l'IA, creusant l'ecart avec les Etats-Unis.

6bis.4 Scenarios specifiques pour le Bresil

En reprenant la matrice 2x2 du chapitre V, les scenarios pour le Bresil se declinent differemment de l'Europe, car le Bresil dispose d'une variable supplementaire : la possibilite de jouer la carte chinoise comme alternative a l'ecosysteme US. Le Tableau 17 detaille les quatre trajectoires possibles.

Le scenario A' (Hub neutre dual) est le plus probable a court terme. Le Bresil entretient des relations commerciales etroites avec les deux blocs et n'a aucun interet a s'aligner exclusivement. Cependant, ce scenario est intrinsequement instable : les Etats-Unis pourraient imposer des conditions (restrictions sur

l'usage de GPU Nvidia dans des data centers accueillant également des workloads chinois), forçant le Brésil à choisir. La désignation par Trump des cartels de drogue comme organisations terroristes étrangères a déjà accru l'exposition des entreprises opérant au Brésil et au Mexique aux règles de contrôle des exportations US.[17]

Le scénario B' (Sanctions secondaires) représente le risque maximal. Si les États-Unis décidaient d'appliquer des sanctions secondaires contre les pays hébergeant des infrastructures IA chinoises significatives, le Brésil se trouverait face à un dilemme existentiel : perdre l'accès à l'écosystème technologique américain (Nvidia, AWS, Azure), ou renoncer aux investissements chinois massifs. Ce scénario, bien que peu probable à court terme, n'est pas hypothétique : les États-Unis ont déjà appliqué des sanctions secondaires sur le pétrole russe et vénézuélien, et l'Affiliates Rule (suspendue jusqu'en novembre 2026) étend les restrictions aux filiales d'entités listées.[18]

6bis.5 L'Amerique du Sud au-delà du Brésil

Les autres économies d'Amérique du Sud subissent les mêmes dynamiques que le Brésil, mais avec moins de poids de négociation et moins d'atouts structurels.

Le Chili, classe pionnier par l'ILIA 2025, bénéficie de températures favorables (réduction de la consommation énergétique de refroidissement) et d'un écosystème de gouvernance IA avancé. Microsoft a lancé en juin 2025 Chile Central, sa première région cloud dans le pays, associée au programme Transforma Chile (180 000 personnes formées, 81 000 emplois créés). Mais le Chili reste entièrement dépendant du hardware et du cloud américain, sans l'alternative chinoise dont dispose le Brésil.

Le Mexique, voisin immédiat des États-Unis, présente un profil différent. Le nearshoring (relocalisation de la production depuis l'Asie) a transformé le paysage économique, et les data centers bénéficient de la proximité du marché US. Cependant, le Mexique est plus vulnérable au protectionnisme américain du fait de l'USMCA (renouvelable en juillet 2026) et de la désignation des cartels comme organisations terroristes. Son infrastructure énergétique pour data centers est aussi moins compétitive que celle du Brésil.

La Colombie, l'Argentine et le Pérou, classes adoptants, font face à des contraintes encore plus fortes : infrastructure électrique fragile, capital humain IA limité, capacité de négociation quasi nulle avec les fournisseurs de GPU. Pour ces pays, le protectionnisme IA américain se traduit principalement par un accès retardé et renchéri aux outils IA, élargissant le fossé de productivité non seulement avec les États-Unis, mais aussi avec le Brésil et le Chili au sein même de la région.

6bis.6 Synthèse : un risque de triple fracture

L'analyse de ce chapitre révèle que le protectionnisme IA américain produit en Amérique du Sud un risque de triple fracture, spécifique à la région et distinct du scénario européen.

Fracture Nord-Sud. L'écart de compute entre les États-Unis et l'Amérique du Sud est bien plus prononcé que l'écart US-Europe. Si le ratio brut US/UE(13) est de 17,6:1 sur le compute installé opérationnel et le ratio CACI(US)/CACI(UE) de 3,46:1 (chapitre III, baseline avril 2026), un ratio équivalent CACI(US)/CACI(Brasil)

serait de l'ordre de 30-50:1 en CACI Power Mode et bien superieur a 100:1 en compute brut, refletant la combinaison d'un deficit de capacite de calcul installee, d'un capital humain IA plus limite, et d'un cout du capital plus eleve (Selic bresilien a 14,25 pour cent fin 2025). Ce fosse est tel que le rattrapage est quasi impossible a l'horizon 2030 sans aide exterieure massive.

Fracture Est-Ouest. La rivalite US-Chine pour l'infrastructure IA en Amerique du Sud cree un risque de fragmentation technologique sans equivalent en Europe. Le Bresil pourrait se retrouver avec deux ecosystemes paralleles incompatibles (cloud US versus infrastructure chinoise), chacun repondant a une logique geopolitique propre plutot qu'aux besoins de l'economie locale. L'Europe, en tant qu'alliee Tier 1, ne fait pas face a cette bifurcation directe sur le compute, meme si le pivot Cloud-Nationalite analyse au chapitre V cree une vulnerabilite distincte sur les charges cloud.

Fracture intra-regionale. Au sein de l'Amerique du Sud, le Bresil attire l'essentiel des investissements IA (41 pour cent du marche LATAM), suivi du Chili et du Mexique. Les pays explorateurs (un tiers de la region selon l'ILIA 2025) risquent d'etre entierement exclus de l'economie IA, reproduisant un schema de dependance analogue a celui des matieres premieres. Le WEF suggere un consortium multi-parties prenantes regional (modele GAVI) pour mutualiser les ressources de compute et democratiser l'accès a l'IA.[19]

Pour le Bresil specifiquement, l'enjeu strategique principal est de transformer ses atouts energetiques (mix 83 pour cent renouvelable) en souverainete de compute, en evitant que la competition US-Chine ne fragmente son ecosysteme. La comparaison avec la France est eclairante : les deux pays possedent un atout energetique distinctif (nucleaire pour la France, renouvelable pour le Bresil), un champion technologique national en emergence (Mistral pour la France, ecosysteme fintech/Nubank pour le Bresil), et une ambition de hub regional IA. Mais le Bresil fait face a des contraintes supplementaires (classification Tier 2, cout du capital, brain drain amplifie) qui rendent sa trajectoire plus incertaine et sa vulnerabilite au protectionnisme plus aigue.

Tableau 16. Principaux projets de data centers IA au Bresil (2025-2030).

Source : compilation de l'auteur a partir de Bloomberg, IndustrialInfo, Introl.

Projet	Origine	Investissement	Capacite	Caracteristique
TikTok Pecem	Chine	~38 Md USD	300 MW vers 1 GW	100 pct eolien ; 1er projet LATAM ByteDance
Scala AI City	Bresil/US	Multi-Md USD	1,8 vers 5 GW	Plus grande installation planifiee Am. du Sud
Elea Rio AI City	Bresil/US	Multi-Md USD	1,8 vers 3,2 GW	Oracle + Nvidia partenaires technologiques
Microsoft Azure	US	2,7 Md USD (3 ans)	N/D	Cloud + IA + programme ConectaAI
AWS Sao Paulo	US	N/D	Multiple AZ	Region cloud active depuis 2011

Tableau 17. Scenarios specifiques du Bresil face au protectionnisme IA americain 2026-2030.

Source : construction de l'auteur, calibration sur baseline avril 2026 (US/UE(13) brut 17,6:1, CACI Power Mode 3,46:1).

Scenario Bresil	Probabilite	Consequences positives	Risques
A' : Hub neutre dual US-Chine	35-45 pct	Afflux d'investissements des deux blocs ; energie renouvelable comme atout ; diversification fournisseurs	Fragmentation ecosysteme ; pressions US pour limiter acces chinois ; vulnerabilite donnees
B' : Sanctions secondaires	15-20 pct	Acceleration investissement chinois substitutif	Perte acces ecosysteme US (Nvidia, cloud) ; isolement technologique partiel
C' : Alignement pro-US	20-25 pct	Acces Tier 1 negocie ; GPU illimitees ; investissement Microsoft/AWS accru	Dependance US totale ; perte investissement chinois (Pecem menace)
D' : Souverainete regionale LATAM	10-15 pct	Consortium regional compute ; reduction dependance ; mutualisation energie	Capacite d'execution limitee ; capital insuffisant ; retard 5-10 ans

Notes

1. CEPALC/CENIA (octobre 2025), Latin American Artificial Intelligence Index (ILIA 2025). L'Amerique latine represente 6,6 pct du PIB mondial et 1,12 pct de l'investissement mondial en IA.
2. CEPALC/CENIA (2025), ibid. Trois categories : pionniers (Chile, Bresil, Uruguay, plus de 60 pts), adoptants (Colombie, Equateur, Costa Rica, Republique Dominicaine), explorateurs (ecosystemes naissants).
3. Banque mondiale (novembre 2025), Digital Progress and Trends Report 2025 : Strengthening AI Foundations. Pays a revenu eleve : 77 pct capacite DC en colocation, 87 pct modeles IA notables, 86 pct startups IA, 91 pct capital-risque IA.
4. BIS (janvier 2025), Framework for Artificial Intelligence Diffusion. Tier 1 : 20 pays allies (acces illimite). Tier 2 : environ 140 pays dont tout le continent americain hors US/Canada (caps quantitatifs). Tier 3 : environ 20 pays (acces interdit). Regle rescindee en mai 2025 par l'administration Trump, remplacement en attente.
5. Brookings (2025), 'Trump's AI export controls and the AI Diffusion Rule'. Caps initiaux : environ 50 000 GPU par pays Tier 2 sur 2025-2027.
6. BIS (juillet 2025), America's AI Action Plan. Promotion d'export de full-stack AI export packages aux allies, durcissement vers les adversaires.
7. ABDC (2025), Brazilian Data Center Association. Mix electrique bresilien : 83 pct renouvelable. Hub Fortaleza : connexions cables sous-marins vers Europe et Afrique.
8. ABDC (2025) ; Mordor Intelligence (2026). Marche DC IA Bresil : 0,55 Md USD (2025) vers 1,24 Md USD (2030), CAGR 17,5 pct.
9. BNDES (2025) ; Mesure provisoire Redata (septembre 2025) : reduction 50 pct du cout du capital DC via exoneration impots IT, valide jusqu'a decembre 2026.
10. Bloomberg (decembre 2025), 'ByteDance Plans 200 Billion-Real Brazilian Data Center'. Partenariat Omnia (Patria Investments) + Casa dos Ventos. 300 MW initiaux, extensibles a 1 GW.
11. Microsoft (2025), engagement 50 Md USD pour le Sud global d'ici 2030. 2,7 Md USD specifiquement Bresil sur 3 ans.
12. Scala Data Centers (2025) ; Elea Data Centers (2025). Rio AI City : partenariat Oracle + Nvidia.
13. Brookings (janvier 2025), op. cit. Pays Tier 2 risquent de developper chaines d'approvisionnement independantes des US, dont liens technologiques renforces avec la Chine.
14. GAIN AI Act (2025), discussion au Congres americain. Priorite d'acces aux semi-conducteurs avances aux consommateurs americains avant les commandes internationales.
15. ILIA 2025 (CEPALC/CENIA), section sur le talent IA. Acceleration brain drain de specialistes depuis 2022.

16. Banque mondiale et OIT (2024-2025) : deficit de productivite persistant en Amerique latine. FMI (mars 2025) : gains TFP IA significativement plus eleves dans les economies avancees.
17. Designation des cartels de drogue comme organisations terroristes etrangeres (Trump, 2025). Exposition accrue des entreprises operant au Bresil et au Mexique aux regles de controle des exportations US.
18. BIS, Suspension of the Affiliates Rule for One Year (10 novembre 2025). Affiliates Rule etend restrictions aux filiales d'entites listees.
19. WEF (2025), proposition de consortium multi-parties prenantes regional (modele GAVI) pour mutualiser les ressources de compute en Amerique latine.

CHAPITRE VI TER - CONSEQUENCES POUR L'ASIE

CHAPITRE VI TER

Consequences pour l'Asie

L'Asie occupe une position unique dans l'architecture du protectionnisme IA americain. Contrairement a l'Europe (alliee Tier 1 mais dependante) ou a l'Amerique du Sud (Tier 2, terrain de competition US-Chine), le continent asiatique concentre simultanement : les cibles principales des restrictions (Chine), les allies industriels critiques de la chaine de valeur (Japon, Coree du Sud, Taiwan), les candidats Tier 2 les plus ambitieux (Inde, Asie du Sud-Est), et le rival systemique en voie d'autonomisation (Chine via Huawei, SMIC, DeepSeek). Ce chapitre analyse les consequences differenciees du protectionnisme IA americain a travers cinq cas asiatiques structurants.

6ter.1 Japon : allie strategique et co-investisseur

6ter.1.1 Le partenariat US-Japon en infrastructure IA

Le Japon illustre le modele de l'allie Tier 1 integre dans l'ecosysteme americain. En 2025-2026, le Japon a conclu avec les Etats-Unis un accord d'investissement de 550 milliards USD en infrastructure IA, energie et semi-conducteurs sur le sol americain, dont 332 milliards pour l'infrastructure energetique (centrales, reseaux de transmission) et le reste pour les semi-conducteurs et les data centers.[1] Mitsubishi Electric contribue a hauteur de 30 milliards USD en systemes d'alimentation pour data centers, TDK 25 milliards en modules de puissance, et Fujikura fournit les cables optiques. Le Japon emet 1 780 milliards de yens en obligations speciales pour financer les investissements japonais aux Etats-Unis dans le cadre de l'accord commercial bilateral.[2]

Parallelement, le Japon investit massivement dans son propre ecosysteme IA. Le gouvernement a engage 10 000 milliards de yens (65 milliards USD) pour l'IA et les semi-conducteurs d'ici 2030, avec 330 milliards USD d'investissements public-privé projetes sur la decennie.[3] Le budget METI pour l'exercice 2026 atteint 1 230 milliards de yens (7,9 milliards USD), quasi-quadruple par rapport aux niveaux precedents, dont 387,3 milliards de yens pour les modeles fondation domestiques et l'infrastructure, et 150 milliards de yens pour Rapidus, le projet national de fonderie de puces 2 nm a Hokkaido.

6ter.1.2 Avantages et risques du statut d'allie privilegie

Le Japon beneficie d'un acces illimite aux GPU americaines (Tier 1) et d'investissements massifs des hyperscalers US : Microsoft (2,9 milliards USD sur deux ans), AWS (15,2 milliards USD d'ici 2027), Google (730 millions USD incluant le premier data center dedie de Google au Japon).[4] Le marche japonais des data centers est le troisieme mondial, evalue a 12,76 milliards USD en 2025, projete a 38,92 milliards d'ici 2031 (croissance annuelle de 20,4 pour cent). SoftBank engage plus de 40 milliards USD via le projet Stargate (partenariat avec OpenAI), et le secteur prive japonais (NEC, Fujitsu, NTT, Sakura Internet) developpe des LLM domestiques (Sarashina, Cotomi, Tsuzumi).

Cependant, le statut d'allié privilégié comporte un risque analogue au scénario C européen (partenariat asymétrique). L'accord de 550 milliards USD représente un transfert massif de capital japonais vers les États-Unis, financement qui pourrait alternativement servir à construire l'infrastructure IA domestique. Le Japon devient co-financeur de la suprématie informatique américaine tout en accélérant son propre écosystème - une dualité qui n'est soutenable que tant que le partenariat reste bénéfique aux deux parties. De plus, malgré les efforts de Rapidus, le Japon reste dépendant de TSMC pour la fabrication de puces de pointe et de Nvidia/AMD pour les accélérateurs IA.

6ter.2 Taiwan et Corée du Sud : maillons critiques et otages géopolitiques

6ter.2.1 Taiwan : le silicium shield sous pression

Taiwan occupe la position la plus critique de la chaîne de valeur IA mondiale. TSMC fabrique environ 90 pour cent des puces de pointe (noeuds inférieurs à 7 nm), dont la totalité des GPU Nvidia et AMD. Cette concentration extrême confère à Taiwan un silicium shield (bouclier de silicium) : une protection géopolitique de facto car aucun acteur mondial ne peut se permettre de perturber la production. Mais ce même positionnement fait de Taiwan un otage stratégique : les États-Unis exigent la diversification de la production (TSMC Arizona, usine de 40 milliards USD, production prévue 2025-2026 sur le noeud 4 nm puis 2 nm), tandis que la Chine exerce une pression militaire croissante.[5]

Le protectionnisme américain a des effets contradictoires sur Taiwan. D'un côté, les restrictions d'export vers la Chine réduisent les revenus de TSMC (la Chine représentait environ 10 pour cent du chiffre d'affaires avant les restrictions). De l'autre, la demande américaine de chips IA explose, compensant largement les pertes chinoises. Le CHIPS Act américain et les tarifs Section 232 créent une pression pour que TSMC transfère une part croissante de sa production aux États-Unis, ce qui à terme pourrait éroder l'avantage compétitif de Taiwan lui-même. Taiwan est classé Tier 1 et ne souffre pas de restrictions sur les GPU, mais son modèle économique fondé sur la fabrication de pointe est paradoxalement menacé par le rapatriement américain de cette même fabrication.

6ter.2.2 Corée du Sud : semiconducteurs mémoire et IA

La Corée du Sud, via Samsung Electronics et SK hynix, domine le marché mondial de la mémoire avancée (DRAM, HBM - High Bandwidth Memory), composant critique des GPU IA. SK hynix fournit l'essentiel de la HBM pour les GPU Nvidia H100/H200/Blackwell. Le budget national IA 2026 de la Corée atteint 9 900 milliards de won (environ 6,7 milliards USD), dont près de la moitié dédiée à l'infrastructure.[6]

La Corée, comme le Japon, est classée Tier 1 et bénéficie d'un accès libre. Mais les restrictions vers la Chine impactent significativement Samsung et SK hynix, qui avaient d'importantes opérations de production en Chine. Samsung opère deux usines de mémoire et une usine NAND à Xi'an, tandis que SK hynix a des capacités DRAM à Dalian et Wuxi. Les restrictions américaines limitent les mises à jour technologiques de ces usines, les confinant progressivement à des noeuds moins avancés. L'Affiliates Rule, suspendue jusqu'en novembre 2026, menace d'étendre ces restrictions à d'autres entités. Le protectionnisme américain pousse

Samsung et SK hynix a investir davantage aux Etats-Unis (Samsung : usine de 17 milliards USD au Texas ; SK hynix : emballage HBM en Indiana), accelerant le transfert industriel vers le territoire americain.

6ter.3 Inde : la troisieme voie du compute souverain

6ter.3.1 Ambitions massives et fosse structurel

L'Inde s'est positionnee comme le porte-drapeau du Sud global pour l'IA lors du India AI Impact Summit de fevrier 2026 a New Delhi, accueillant pres de 20 chefs d'Etat ainsi que les PDG de Google, OpenAI et Anthropic. Les annonces d'investissement depassent 200 milliards USD sur deux ans, principalement du secteur prive : Reliance/Jio (110 milliards USD sur sept ans, data centers multi-GW a Jamnagar, premiers 120 MW en ligne au second semestre 2026), Tata Group (data centers IA de 100 MW a 1 GW, avec OpenAI comme premier locataire), et le groupe Adani (energie renouvelable pour data centers).[7]

Mais le fosse entre ambition et realite reste considerable. La capacite installee de data centers en Inde est d'environ 1,4 GW (2025), contre 53,7 GW aux Etats-Unis et 19,6 GW en Chine. L'IndiaAI Mission, dotee de 10 372 crores de roupies (environ 1,2 milliard USD sur cinq ans), a deploye 38 000 GPU a acces subventionne, avec 20 000 GPU supplementaires annonces.[8] Pour comparaison, Baidu seul a annonce un cluster de 30 000 GPU en 2025, et la capacite nationale de compute IA de la Chine atteignait environ 246 EFLOP/s a mi-2024. L'investissement public indien, bien que significatif dans le contexte national, represente ce que les grandes entreprises americaines depensent en quelques mois.

6ter.3.2 Classification Tier 2 et strategie de contournement

Comme le Bresil, l'Inde est classee Tier 2, soumise aux caps quantitatifs de GPU. Brookings identifie l'Inde, avec le Bresil, comme l'un des pays Tier 2 les plus defavorises par les restrictions.[9] Cependant, l'Inde adopte une strategie de contournement sophistiquee : elle se positionne comme exportatrice de compute. Le budget 2026 introduit un cadre fiscal a zero impot jusqu'en 2047 pour les services cloud exportes depuis des data centers indiens.[10] L'idee est d'attirer les hyperscalers americains a construire sur le sol indien pour servir le marche indien et les marches voisins, contournant ainsi les caps d'import de GPU en hebergeant le compute US localement.

Cette strategie rejoint la troisieme voie que revendique l'Inde : cooperer avec les Etats-Unis (acces aux GPU, partenariats OpenAI/Google/Microsoft) tout en construisant des capacites souveraines (IndiaAI Mission, modeles domestiques comme BharatGen) et en amplifiant la voix du Sud global. Le risque est le meme que pour le scenario C europeen : une souverainete applicative sans souverainete hardware, puisque l'Inde reste entierement dependante des GPU americaines et que ses projets de fabrication de semi-conducteurs (India Semiconductor Mission, 10 milliards USD d'incitations) ne produiront pas de puces IA de pointe avant 2028-2030.

6ter.4 Chine : l'autonomisation forcee

6ter.4.1 Impact et adaptation

La Chine est la cible principale et directe du protectionnisme IA américain (Tier 3, accès interdit aux GPU avancées depuis octobre 2022, étendu en 2023 et 2024). Les résultats sont ambivalents. D'un côté, les restrictions ont ralenti l'accès de la Chine au compute de pointe : les GPU Nvidia H100/H200/Blackwell sont interdites, le chip dégradé H20 a nécessité une licence spéciale (approuvée en juillet 2025), et plus de 65 entités chinoises ont été ajoutées à l'Entity List en 2025.[11]

De l'autre, la Chine a accéléré sa course à l'autonomisation avec des résultats notables. Huawei a développé l'Ascend 910c (performances approchant le Nvidia H100, à 60-70 pour cent du coût selon les analystes) et poursuit le 910d. SMIC, bien que privée d'accès aux machines EUV d'ASML, progresse vers la fabrication en 5 nm. DeepSeek-V3, modèle chinois de langage, a atteint des performances compétitives sur les benchmarks mondiaux malgré les contraintes de compute.[12] La Chine a investi plus de 125 milliards USD en infrastructure IA en 2025, vise 70 milliards supplémentaires en data centers pour 2026, et projette 300 EFLOP/s de capacité de calcul IA avec plus de 250 installations dédiées. La part chinoise de la capacité mondiale de fonderies devrait passer de 21 pour cent à 30 pour cent d'ici 2030, dépassant Taiwan.[13]

Note importante : le ratio brut US/Chine apparent dans le tableau de bord public d'avril 2026 (US 76,9 pour cent opérationnel, Chine 0,5 pour cent F_total) sous-représente significativement la capacité chinoise réelle. Epoch AI ne capture qu'une fraction des clusters chinois (anonymisation, opacité des fournisseurs Huawei/Cambricon/Biren), et la capacité annoncée de 246-300 EFLOP/s suggère un ratio réel beaucoup plus proche de 5-10:1 que des 150:1 implicites dans les données publiquement consolidées.

6ter.4.2 Le paradoxe stratégique pour les États-Unis

Le cas chinois révèle un paradoxe fondamental du protectionnisme IA américain. En limitant l'accès de la Chine aux GPU, les États-Unis ont accéléré (plutôt que freiné) la construction d'une chaîne de valeur IA chinoise alternative. Comme le note l'ITIF, les restrictions poussent des concurrents à combler le fossé : Huawei, Biren Technology, MetaX et Enflame innovent dans la conception de puces IA.[14] Le résultat à moyen terme pourrait être l'émergence d'un deuxième écosystème IA mondial complètement indépendant de la technologie américaine, créant les conditions d'une bifurcation technologique permanente. Ce deuxième écosystème est précisément celui qui s'exporte vers le Brésil (ByteDance à Pecem), l'Asie du Sud-Est (ByteDance en Malaisie et Thaïlande), et l'Afrique, créant la fragmentation technologique mondiale analysée dans les chapitres précédents.

6ter.5 Asie du Sud-Est et Golfe : les nouveaux terrains de compétition

6ter.5.1 Singapour, Malaisie, Thaïlande : le corridor IA de l'ASEAN

L'Asie du Sud-Est est classée Tier 2 et représente un terrain de compétition croissante entre investissements US et chinois en infrastructure IA. Singapour, malgré ses contraintes de taille et d'énergie (environ 1 GW de capacité DC), s'est établi comme hub régional grâce à sa stabilité réglementaire et ses investissements en R&D (5 milliards de dollars singapouriens pour l'IA). La Malaisie est devenue un point chaud : ByteDance y investit 2,1 milliards USD dans un hub IA, tandis que Microsoft, Google et AWS y déploient des data centers. [15] La Thaïlande a reçu 8,8 milliards USD de ByteDance pour des data centers. Ces investissements chinois

creent en Asie du Sud-Est une concentration d'infrastructure IA chinoise qui pourrait susciter des restrictions secondaires americaines a terme.

6ter.5.2 Emirats et Arabie Saoudite : compute comme diversification economique

Les Etats du Golfe representent un cas different : des pays Tier 2 a tres haute capacite d'investissement, pour lesquels l'IA est un instrument de diversification post-petrole. Les Emirats arabes unis developpent le plus grand campus IA hors des Etats-Unis (26 km², 5 GW prevus, Abu Dhabi). L'Arabie Saoudite a annonce plus de 15 milliards USD de nouveaux investissements IA au LEAP 2025, dont 10 milliards via un partenariat PIF-Google Cloud et 500 MW chacun de puces AMD et Nvidia via son initiative HUMAIN.[16] L'administration Trump a assoupli les restrictions vers le Moyen-Orient, reconnaissant le potentiel d'alliance strategique et financier. Ces pays Tier 2 deviennent ainsi des partenaires financiers de l'ecosysteme IA americain (le fonds MGX d'Abu Dhabi a co-investi dans Mistral AI), une dynamique de compute-for-capital qui transforme le protectionnisme en un levier de financement de l'infrastructure US.

Le cas des EAU illustre quantitativement cette dynamique : la Fig 1.8 du chapitre I a documente que 99,6 pour cent du F_{total} des EAU (22,9 millions d'equivalents H100) est detenu par des acteurs US-side (Stargate UAE, Microsoft, OpenAI), faisant s'effondrer le CACI souverain de 55,7 (Physique) a seulement 6,0 (Souverain). Cette distinction entre compute physiquement present et compute legalement controlable est centrale pour comprendre la pseudo-souverainete des hubs du Golfe.

6ter.6 Synthese comparative Asie

Le Tableau 18 synthetise les positions relatives des principaux acteurs asiatiques face au protectionnisme IA americain.

6ter.7 Le reequilibrage geopolitique asiatique de l'IA

L'analyse de l'Asie revele que le protectionnisme IA americain produit un reequilibrage geopolitique profond, articule autour de trois dynamiques.

Dynamique 1 : Consolidation de l'alliance technologique US-Japon-Coree-Taiwan. Les allies Tier 1 asiatiques ne sont pas simplement des beneficiaires passifs. Ils deviennent des co-investisseurs massifs dans l'infrastructure US (Japon : 550 milliards, Samsung/SK hynix : dizaines de milliards en usines americaines), tout en accelerant leur propre ecosysteme. Cette alliance est structurellement plus integree que le partenariat US-Europe, car le Japon et la Coree controlent des segments critiques de la chaine de valeur (memoire HBM, equipements, materiaux) que les Etats-Unis ne peuvent pas facilement substituer.

Dynamique 2 : Emergence d'un ecosysteme IA chinois independant. Contrairement a ce que prevoient les architectes des export controls, les restrictions n'ont pas neutralise la capacite d'innovation IA chinoise. DeepSeek, Huawei Ascend, et les investissements massifs en infrastructure (125 milliards USD en 2025) montrent que la Chine construit un ecosysteme parallele. Le retard en GPU de pointe (environ 2-3 generations) est partiellement compense par l'optimisation logicielle, les architectures alternatives et l'accès

au marche interieur (1,4 milliard d'utilisateurs). Cet ecosysteme s'exporte en Amerique du Sud (chapitre VI bis), en Asie du Sud-Est et en Afrique.

Dynamique 3 : L'Inde comme pivot du Sud global. L'AI Impact Summit 2026 a consacre l'Inde comme le pont entre les economies avancees et le Sud global. Avec 200+ milliards USD d'engagements, 1,4 milliard d'habitants, un vivier de talent technique et une strategie de compute comme export, l'Inde se positionne pour capter une part significative de l'infrastructure IA mondiale. Cependant, sa classification Tier 2 cree une tension fondamentale avec cette ambition : les caps de GPU limitent la capacite de l'Inde a construire l'infrastructure qu'elle projette. La resolution de cette tension - promotion au Tier 1, VEU (Validated End User) pour les groupes indiens, ou construction d'alternatives non-US - sera l'un des points de bifurcation majeurs de la geopolitique IA 2026-2030.

Pour l'Europe et la France (objet principal de cette etude), les dynamiques asiatiques creent a la fois des opportunités et des risques. Opportunités : alliances technologiques avec le Japon et la Coree (l'investissement d'ASML dans Mistral, le partenariat TSMC-Dresde), acces aux marches indiens et sud-est asiatiques pour les solutions IA europeennes. Risques : si le bloc US-Japon-Coree-Taiwan se consolide en un ecosysteme ferme, l'Europe pourrait etre marginalisee comme alliee technologique de second rang, d'autant que les investissements japonais massifs aux Etats-Unis accelerent la concentration du compute americain que l'Europe cherche precisement a reduire.

Tableau 18. Synthese comparative de la position asiatique face au protectionnisme IA americain.

Source : compilation de l'auteur, calibration sur baseline avril 2026.

Pays/Region	Tier	Cap. DC (GW) 2025	Invest. IA (Md USD)	Atout principal	Risque principal
Japon	1	~12,8	135 (public+prive)	Alliance US + industrie + R&D	Co-financement US + dependance GPU
Taiwan	1	~3	N/A (producteur)	TSMC 90 pct chips pointe	Transfert production vers US + pression Chine
Coree du Sud	1	~5	6,7 (budget 2026)	HBM (SK hynix) + Samsung	Usines Chine gelees + transfert US
Inde	2	~1,4	200+ (2 ans)	Marche 1,4 Md hab. + talent	Fosse compute + Tier 2 caps
Chine	3	~19,6	125+ (2025)	Autonomisation forcee	Retard GPU + isolement technologique
ASEAN	2	~3	15+ (US+CN combine)	Couts bas + position géographique	Bifurcation US-Chine
Golfe	2 (vers 1 ?)	~2	15+ (Arabie) + 5 GW (EAU)	Capital souverain massif	Dependance technologique + eau/energie + sov. illusoire (EAU 99,6 pct US-side)

Notes

1. Construction Today (novembre 2025), 'Billion-Dollar AI Build Begins as Japan Backs US Data and Energy Push'. Accord US-Japon : 550 Md USD, dont 332 Md USD energie, Bechtel et Kiewit maitres d'oeuvre.
2. Taipei Times (decembre 2025). Obligations speciales japonaises de 1 780 Md JPY via NEXI. Mitsubishi Electric : 30 Md USD, TDK : 25 Md USD, Fujikura : cables optiques.
3. The Economy (novembre 2025), 'Japan Revives State-Led Growth Strategy'. 66 Md USD fonds publics IA/semiconducteurs d'ici 2030, 330 Md USD public-privé sur la decennie. METI budget 2026 : 1 230 Md JPY.
4. Introl Blog (aout 2025), 'Japan 135B USD AI Push'. Microsoft : 2,9 Md USD ; AWS : 15,2 Md USD d'ici 2027 ; Google : 730 M USD incl. DC dedie Inzai. SoftBank : 40 Md USD via Stargate. Arizton : marche DC Japon 12,76 Md USD (2025) vers 38,92 Md USD (2031).
5. TSMC Arizona : usine de 40 Md USD, production prevue 2025-2026 (4 nm), extension 2 nm. Samsung Austin : usine de 17 Md USD. Donnees : sources multiples industrielles.
6. Futurum (fevrier 2026), 'AI Capex 2026 : The 690B USD Infrastructure Sprint'. Budget national IA Coree 2026 : 9 900 Md KRW (~6,7 Md USD).
7. IBTimes India (fevrier 2026), 'India's AI Awakening'. Reliance : 110 Md USD sur 7 ans ; Tata : DC 100 MW-1 GW avec OpenAI ; Adani : energie renouvelable pour DC. Total : 310+ Md USD.
8. Medium / Durgesh Kumar (fevrier 2026). IndiaAI Mission : 10 372 crores roupies, 38 000 GPU + 20 000 annonces, subvention 65 INR/heure. Mind2Markets (fevrier 2026) : capacite DC Inde 1,4 GW, US 53,7 GW, Chine 19,6 GW.
9. Brookings (janvier 2025), op. cit. Inde et Bresil : plus grands marches Tier 2, mais caps insuffisants.
10. Constellation Research (fevrier 2026), 'Compute as an Export : India's Strategy'. Budget 2026 : cadre zero-impot jusqu'en 2047 pour services cloud exportes depuis l'Inde.
11. Introl Blog (janvier 2026), 'AI Export Controls : Navigating Chip Restrictions Globally'. H100/H200/Blackwell interdits Tier 3. 65+ entites ajoutees Entity List en 2025.
12. EastPost (fevrier 2026), 'India's AI Impact Summit Highlights Broad Gaps'. DeepSeek-V3 : performances competitives sous contraintes. Chine : 246 EFLOP/s mi-2024, objectif 300 EFLOP/s. Huawei Ascend 910c : ~H100 a 60-70 pct du cout.
13. IBTimes India (fevrier 2026), op. cit. Chine : 125 Md USD infrastructure IA 2025, 70 Md USD DC 2026, 300 EFLOP/s, 250+ installations. Tom's Hardware (2025) : part fonderies Chine 21 pct vers 30 pct (2030).
14. ITIF (mai 2025), 'Overly Stringent Export Controls Chip Away at US AI Leadership'. Huawei Ascend, Biren, MetaX, Enflame : chaine de valeur alternative en construction.
15. ByteDance : 2,1 Md USD Malaisie (hub IA), 8,8 Md USD Thaïlande (data centers). Microsoft, Google, AWS : regions cloud en Malaisie, Singapour, Indonesie.
16. Futurum (fevrier 2026), op. cit. Arabie Saoudite : 15 Md USD LEAP 2025, 10 Md USD PIF-Google Cloud, HUMAIN 500 MW AMD + 500 MW Nvidia. EAU : campus 26 km2, 5 GW, Abu Dhabi. Voir aussi chapitre I Fig 1.8 pour la decomposition Phys/Sov des EAU (99,6 pct US-side).

CHAPITRE VI QUATER - CONSEQUENCES POUR L'AFRIQUE

CHAPITRE VI QUATER

Consequences pour l'Afrique

L'analyse menee dans les chapitres precedents a couvert l'Europe, l'Amerique du Sud et l'Asie. Or, l'Afrique - identifiee dans la conclusion generale comme un prolongement de recherche necessaire - constitue desormais un terrain de competition geopolitique decisif. Representant 18 pour cent de la population mondiale mais moins de 1 pour cent de la capacite mondiale de data centers, le continent cumule un deficit structurel de compute avec un potentiel energetique (geothermie, solaire, hydroelectricite) et un dynamisme demographique qui en font un enjeu majeur de la recomposition de l'ordre technologique mondial. Ce chapitre complementaire analyse les consequences specifiques du protectionnisme IA americain sur l'Afrique, en distinguant les dynamiques sous-regionales et les effets differences de la rivalite US-Chine.

6quat.1 Position structurelle : le continent du compute paradox

6quat.1.1 Un ecart infrastructurel sans equivalent

L'Afrique presente l'asymetrie compute la plus extreme au monde. Mi-2025, le continent compte 223 data centers repartis dans 38 pays - moins de 2 pour cent du total mondial (11 800+). La capacite installee est estimee entre 780 MW et 1 170 MW, soit l'equivalent d'un seul campus hyperscale americain.[1] La distribution est elle-meme fortement concentree : l'Afrique du Sud (56 data centers), le Kenya (19) et le Nigeria (17) hebergent 41 pour cent de l'infrastructure continentale. L'Egypte et le Maroc dominant l'Afrique du Nord.

En termes de GPU IA - le facteur determinant pour le compute frontier - l'ecart est encore plus brutal. Seuls 5 pour cent des innovateurs IA africains ont acces a du compute avance, tandis que le deficit de demande non satisfaite est estime a 7 millions d'heures GPU sur trois ans.[2] Cet ecart ne reflete pas une absence de demande mais une absence d'offre : le paradoxe du compute africain reside dans la coexistence d'une demande latente croissante et d'une infrastructure insuffisante pour la satisfaire. Le WEF estime que briser ce paradoxe pourrait liberer 1 200 a 1 500 milliards USD de valeur economique d'ici 2030.

La croissance est neanmoins rapide. McKinsey (novembre 2025) projette la demande en data centers africains entre 1,5 et 2,2 GW a horizon 2030, avec un taux de croissance annuel compose de 14,5 a 24 pour cent selon les segments. Le marche africain des data centers, evalue a 1,94 milliard USD en 2025, devrait atteindre 4,36 milliards en 2031.[3] Le marche nigerian seul est evalue a 288 millions USD en 2025 avec une projection a 1,09 milliard en 2031 (CAGR 25 pour cent).

6quat.1.2 Classification Tier et acces au compute US

Dans l'architecture de controle a l'export americaine, la quasi-totalite des pays africains releve du Tier 2 (acces restreint avec caps quantitatifs), voire du Tier 3 pour les pays sous sanctions. Aucun pays africain ne figure dans le Tier 1 (acces illimite), reserve aux 20 allies proches des Etats-Unis. Cette classification a des consequences directes : les caps GPU imposent un plafond structurel a l'infrastructure de compute frontier accessible aux acteurs africains, meme lorsque le financement est disponible. Le cout d'accès aux GPU Nvidia sur le marche secondaire est estime entre 45 000 et 60 000 USD l'unite.[4]

Paradoxalement, cette restriction americaine ouvre un espace strategique pour les fournisseurs chinois. Huawei, present sur le continent depuis les annees 1990 via ses equipements telecom, controle environ 70 pour cent du backbone 4G africain et mene le deploiement 5G dans 30 marches. L'entreprise propose desormais des solutions data center integrees (FusionModule2000, UPS5000-E) incluant des accelerateurs IA Ascend, a des prix significativement inferieurs a ceux de Nvidia.[5] La classification Tier 2 cree donc un push factor vers l'ecosysteme technologique chinois, reproduisant en Afrique le mecanisme identifie pour l'Amerique du Sud (chapitre VI bis).

6quat.2 Les poles emergents : cartographie differenciee

6quat.2.1 Afrique du Sud : hub principal et point d'ancrage des hyperscalers

L'Afrique du Sud detient 40,8 pour cent de la part de marche africaine des data centers en 2025. Le marche sud-africain de l'IA dans les data centers croit a 42 pour cent par an (de 70 millions en 2025 a 572 millions en 2031). Les trois hyperscalers americains ont consolide leur presence : Microsoft (5,4 milliards de rands, environ 300 millions USD d'ici 2027, apres 20,4 milliards de rands investis sur trois ans), AWS (1,7 milliard USD dans la region du Cap), Google (region cloud Johannesburg).[6] Le pays beneficie d'une National AI Strategy, du Centre for AI Research (CAIR) et d'un reseau electrique relativement developpe, malgre des episodes recurrents de load shedding. C'est aussi le siege de la premiere AI Factory africaine de Cassava Technologies/Nvidia (3 000 GPU deployes mi-2025).

6quat.2.2 Nigeria : moteur de croissance de l'Afrique de l'Ouest

Le Nigeria emerge comme le marche data center a la croissance la plus rapide d'Afrique. Lagos concentre l'essentiel des investissements : Equinix (plan d'expansion de 100 millions USD sur le continent), Africa Data Centres, Digital Realty, Rack Centre.[7] Le pays beneficie de sa connectivite sous-marine (cables WACS, ACE, MainOne, Glo-1) et d'un ecosysteme fintech dynamique (13 banques de depot integrant des chatbots IA des 2024). Microsoft s'engage a former un million de Nigerians a l'IA, le pays ayant identifie un potentiel de 15 milliards USD de contribution de l'IA au PIB d'ici 2030. Le National Centre for AI and Robotics (NCAIR) structure l'ecosysteme de recherche.

6quat.2.3 Kenya : la Silicon Savannah et l'atout geothermique

Le Kenya se distingue par la combinaison unique d'un ecosysteme tech dynamique (Silicon Savannah) et d'un avantage energetique structurel : plus de 60 pour cent de son electricite provient de sources renouvelables, dont la geothermie de la zone de Naivasha. C'est cet atout qui a attire l'investissement de 1 milliard USD de Microsoft et G42 (EAU) pour un data center geothermique de 100 MW a Olkaria, extensible a 1 GW.[8] Le

gouvernement offre des incitations fiscales en zones économiques spéciales (exemption de 10 pour cent d'impôt sur les sociétés pendant 10 ans). Le campus IXAfrica de Nairobi, en partenariat stratégique avec Safaricom, fournit déjà une infrastructure AI-ready. La stratégie IA nationale (mars 2025) positionne le Kenya comme leader régional de la recherche et de l'innovation IA.

Le Kenya est également un terrain d'expérimentation pour les partenariats US-Kenya en semi-conducteurs : le USTDA a noué un partenariat avec Kenya Semiconductor Technologies Limited pour établir une installation de fabrication de semi-conducteurs à Nairobi, initiative sans précédent en Afrique subsaharienne.[9]

6quat.2.4 Maroc : le noeud de compute Europe-Afrique

Le Maroc occupe une position stratégique unique : situé à 15 km de l'Europe, connecté par de multiples câbles sous-marins, il se positionne comme hub d'export de compute IA plutôt que comme marché domestique. En juin 2025, un consortium mené par Naver (Corée du Sud) avec Nvidia a annoncé un projet de data center de 500 MW alimenté par énergies renouvelables, avec une première phase de 40 MW équipée de GPU Blackwell GB200. Le Maroc représente environ 35 pour cent de la capacité data center continentale (soit environ 140 MW).[10] L'objectif gouvernemental est ambitieux : 40 milliards de dirhams de revenus en services numériques avancés d'ici 2030, servant principalement des clients européens et moyen-orientaux. Intel (Texas) avait déjà annoncé un investissement de 500 millions USD pour un data center de 386 MW à Tetouan. Le Centre international d'IA affilié à l'Université Mohammed VI Polytechnique, désigné centre UNESCO de catégorie II fin 2023, ancre la recherche.

6quat.2.5 Egypte : ambition régionale et stratégie gouvernementale

L'Égypte a adopté l'une des stratégies IA les plus structurées du continent, avec un cadre d'évaluation fondé sur trois critères (faisabilité technologique, impact sociétal, retour sur investissement). Le pays bénéficie de sa position géographique comme point de connexion entre Europe, Afrique et Moyen-Orient via les principales dorsales internet. L'Égypte figure parmi les cinq pays cibles de la AI Factory Cassava/Nvidia (12 000 GPU au total sur trois à quatre ans).[11]

6quat.2.6 Rwanda : le laboratoire IA de l'Afrique

Le Rwanda se positionne comme le laboratoire IA de l'Afrique (formulation officielle de sa National Policy on AI). Le pays a accueilli en avril 2025 le premier Sommet mondial de l'IA sur l'Afrique à Kigali, réunissant des participants de 40+ pays. Le Rwanda est le seul pays africain à disposer d'une politique nationale IA (distincte d'une stratégie). Le Centre for the Fourth Industrial Revolution (C4IR Rwanda), en partenariat avec le WEF, expérimente des solutions IA en santé, agriculture, éducation et services publics. L'initiative Masakhane, hébergée en partie au Rwanda, développe des modèles NLP pour les langues africaines.[12]

6quat.3 La rivalité US-Chine en Afrique : l'IA comme nouveau terrain de compétition

6quat.3.1 L'offensive américaine : Nvidia, Microsoft et le modèle AI Factory

L'engagement americain le plus structurant est le partenariat Cassava Technologies-Nvidia, annonce en mars 2025. Ce projet constitue l'un des plus importants engagements d'infrastructure technologique privée en Afrique : jusqu'à 720 millions USD pour deployer 12 000 GPU Nvidia dans cinq pays (Afrique du Sud, Egypte, Nigeria, Kenya, Maroc) sur trois à quatre ans. Nvidia a ensuite réalisé un investissement en capital dans Cassava en octobre 2025.[13] Le modèle est l'AI-as-a-Service (AlaaS) : rendre les GPU accessibles en location aux startups, universités et gouvernements africains, permettant de contourner partiellement le coût prohibitif d'acquisition directe.

Parallèlement, les hyperscalers américains intensifient leur présence : Microsoft (300 millions USD en Afrique du Sud, 1 milliard au Kenya avec G42), Google (37 millions USD spécifiquement pour l'IA pour l'Afrique, dans un engagement global de 1 milliard pour la tech africaine). Microsoft a formé plus de 4 millions de jeunes Africains en compétences numériques en cinq ans et s'engage à connecter 124 millions de personnes en Afrique à internet.[14] L'AI Action Plan américain (juillet 2025) intègre explicitement l'Afrique dans sa stratégie d'exportation du full AI technology stack.

6quat.3.2 La pénétration chinoise : Huawei, DeepSeek et les Belt and Road numériques

La présence chinoise en Afrique précède de loin la compétition IA. Huawei a construit l'essentiel de l'infrastructure telecom du continent dans le cadre des Belt and Road Initiatives et domine 70 pour cent du backbone 4G africain avec des opérations dans 30+ marchés.[15] Cette base installée confère un avantage structurel considérable pour la couche IA. Huawei déploie désormais des data centers IA intégrés : en Ethiopie, le FusionModule2000 a été installé à la Cooperative Bank of Oromia (24,7 milliards USD de transactions digitales), faisant de Huawei le premier à deployer une infrastructure IA opérationnelle en Afrique subsaharienne, devant Schneider Electric, Vertiv et Eaton encore en phase pilote.

Le chatbot chinois DeepSeek se répand rapidement au Kenya, où des startups l'utilisent pour l'analyse économique et l'évaluation des risques d'investissement, à un coût inférieur de 94 pour cent à ChatGPT. Huawei a formé 120 000 Africains et développe des chaînes d'approvisionnement locales.[16] Le FOCAC 2024 (Forum on China-Africa Cooperation) a annoncé le développement d'un centre de coopération numérique Chine-Afrique et 20 projets d'infrastructure et de transformation numérique. Le parallèle avec les Belt and Road physiques est direct : les infrastructures IA chinoises améliorent l'accès mais créent une dépendance technologique et politique.

6quat.3.3 Le double bind africain

L'Afrique est prise dans un double bind structurel. D'un côté, le protectionnisme américain (classification Tier 2, tarifs 25 pour cent Section 232) restreint l'accès au compute frontier Nvidia. De l'autre, le recours à l'alternative chinoise (Huawei Ascend, DeepSeek) expose à des risques de surveillance, de dépendance géopolitique et de sanctions secondaires américaines. Les données des utilisateurs de DeepSeek sont stockées sur des serveurs accessibles au gouvernement chinois. Pour les pays africains qui aspirent à maintenir des relations avec les deux blocs, chaque choix d'infrastructure est un choix d'alignement.[17]

6quat.4 Impact du protectionnisme US sur l'Afrique : cinq canaux de transmission

Le protectionnisme IA americain affecte le continent africain a travers cinq canaux structurels.

Premier canal : la restriction d'accès au compute frontier. La classification Tier 2 impose des plafonds quantitatifs sur les exportations de GPU avances. Pour un continent où le déficit de compute est déjà le plus aigu au monde, ces restrictions exacerbent l'écart. Les 12 000 GPU du projet Cassava/Nvidia représentent un volume modeste comparé aux millions de GPU déployés par les hyperscalers américains. L'accès au training de modèles frontier (GPT-5, Claude, Gemini) reste tributaire du cloud US, créant une dépendance structurelle.

Deuxième canal : la bifurcation technologique. Les pays africains incapables d'accéder au compute américain se tournent vers les solutions chinoises. Cette bifurcation est déjà visible : les startups kenyanes utilisent DeepSeek et Qwen, l'Éthiopie déploie Huawei, le FOCAC structure la coopération numérique Chine-Afrique. À terme, deux écosystèmes IA incompatibles pourraient coexister sur le continent, avec des implications en termes d'interopérabilité, de standards et de gouvernance des données.[18]

Troisième canal : l'amplification de la fuite des cerveaux. L'Afrique ne représente que 3 pour cent du talent IA mondial. L'absence de compute local pousse les chercheurs les plus qualifiés vers les États-Unis, l'Europe ou les Émirats. Le protectionnisme américain, en concentrant le compute frontier sur le sol US, renforce la force gravitationnelle du hub américain pour les talents africains. Le programme Deep Learning Indaba en Afrique du Sud et les initiatives Masakhane tentent de contrer cette tendance, mais la disparité des moyens est considérable.[19]

Quatrième canal : le risque énergétique asymétrique. Le développement de data centers IA nécessite une électricité fiable et abondante. Or, 600 millions d'Africains n'ont toujours pas accès à l'électricité. Les opérateurs de data centers comme Raxio (Ouganda, Éthiopie, Mozambique, Côte d'Ivoire, RDC, Angola) doivent investir dans leurs propres lignes électriques et maintenir des générateurs diesel de secours (90 000 litres stockés pour un data center de 1,5 MW).[20] L'avantage géothermique du Kenya et renouvelable du Maroc sont des exceptions, non la règle.

Cinquième canal : le déficit réglementaire. Seuls 16 pays africains sur 54 avaient lancé des stratégies IA nationales en juillet 2025. La Stratégie continentale IA de l'Union africaine (2025-2030) structure un cadre commun en deux phases, mais l'absence de régulation harmonisée crée un vide que les acteurs extérieurs (US et Chine) exploitent pour imposer leurs standards.[21] Le contraste avec l'AI Act européen est frappant : là où l'Europe impose des conditions, l'Afrique subit.

6quat.5 Atouts stratégiques et fenêtres d'opportunité

Malgré ces contraintes, l'Afrique dispose d'atouts spécifiques que le protectionnisme IA américain pourrait, paradoxalement, valoriser.

Avantage energetique selectif. Le Kenya (geothermie), le Maroc (solaire et eolien), l'Afrique du Sud (nucleaire et renouvelables) et la Cote d'Ivoire (solaire : 37,5 MWp a Boundiali, objectif 45 pour cent renouvelable d'ici 2030) offrent des corridors energetiques competitifs pour les data centers. La puissance de l'energie comme moat pour les data centers est desormais reconnue : McKinsey note que la disponibilite energetique, et non la densite de la demande, determine de plus en plus les decisions d'implantation.[22]

Position de noeud geographique. Le Maroc (15 km de l'Europe, hub EMEA) et l'Egypte (carrefour Europe-Afrique-Moyen-Orient) peuvent devenir des noeuds d'export de compute IA, servant les workloads europeens et moyen-orientaux a cout energetique inferieur. Ce positionnement nearshore est comparable a celui de l'Inde pour les services IT, transpose a l'infrastructure IA.

Diversite linguistique comme opportunit  NLP. Avec plus de 1 000 langues parlees, l'Afrique represente un terrain d'innovation unique pour les modeles de traitement du langage naturel. Les projets Masakhane (NLP pour langues africaines) et UlizaLlama developpent des modeles specifiques pour le kinyarwanda, le swahili, le yoruba, le xhosa et le zoulou. Microsoft a engage 5,5 millions USD dans le programme LINGUA Africa.[23]

Marche fintech et donnees mobiles. L'ecosysteme fintech africain (M-Pesa, OPay, Flutterwave) genere des volumes de donnees transactionnelles massifs, exploitables pour l'entrainement de modeles IA specifiques (scoring credit, detection de fraude, inclusion financiere). L'Afrique comptera 2 400+ entreprises specialisees en IA, dont 41 pour cent de startups, et le marche IA continental devrait passer de 4,5 milliards en 2025 a 16,5 milliards en 2030 (croissance annuelle de 27 pour cent).[24]

6quat.6 Scenarios specifiques pour l'Afrique

L'application de la matrice scenarielle 2x2 (chapitre V) au continent africain genere quatre trajectoires, presentees dans le Tableau 22.

Le scenario S4 (non-alignement numerique) constituerait la reponse africaine la plus adaptee, conjuguant multi-sourcing technologique (Nvidia/Huawei/open-source), souverainete des donnees et developpement de modeles ouverts specifiques (langues africaines, agriculture, sante). Cependant, sa realisation suppose une coherence reglementaire continentale (Strategie UA) et un investissement massif estime a plus de 7 milliards USD pour combler les deficits en donnees, compute et competences. Le scenario S3 (bifurcation imposee) est le plus probable en l'absence d'action coordonnee, reproduisant pour l'IA la dependance telecom deja installee par Huawei.[25]

6quat.7 Synthese : le continent de la derniere chance numerique

L'Afrique concentre les paradoxes les plus aigus de la recomposition technologique mondiale. Continent le plus deficitaire en compute (moins de 1 pour cent de la capacite mondiale), mais dote du plus fort potentiel demographique (1,4 milliard d'habitants, age median environ 19 ans) et de ressources energetiques strategiques (geothermie, solaire, hydro). Marche le plus convoite par les deux blocs (US et Chine), mais le moins equipe reglementairement pour negocier les conditions de cette competition. Le Tableau 23 synthetise la position africaine en regard du baseline mondial.

Le protectionnisme IA americain agit sur l'Afrique comme un amplificateur d'inegalite numerique. En limitant l'accès au compute frontier pour les pays Tier 2 (quasi-totalite de l'Afrique) tout en concentrant le compute, le talent et l'innovation sur le sol americain, il creuse un ecart deja abyssal. Simultanement, il ouvre un boulevard strategique a la Chine, qui dispose de la base installee (Huawei telecom) et de l'offre alternative (Ascend, DeepSeek) pour capter ce marche.

Pour l'Afrique, l'enjeu n'est pas de choisir entre les Etats-Unis et la Chine, mais de construire une capacite de negociation vis-a-vis des deux. Cela suppose quatre conditions : (i) acclereler la Strategie continentale IA de l'UA (Phase I 2025-2026), (ii) exploiter les corridors energetiques competitifs (geothermie Kenya, solaire Maroc), (iii) investir dans les modeles ouverts specifiques (NLP langues africaines, IA pour l'agriculture et la sante), et (iv) negocier collectivement les conditions d'accès au compute avec les fournisseurs US et chinois, plutot que de subir la competition.

La fenetre d'opportunite est similaire a celle identifiee pour l'Europe (2026-2028) mais les enjeux sont differents : il ne s'agit pas de rattraper un avantage perdu, mais d'eviter qu'un retard structurel ne devienne un enfermement permanent. Comme le resume le New Lines Institute, la collaboration Cassava/Nvidia est moins une question de technologie que de determiner si l'Afrique sera productrice ou simple consommatrice dans l'economie IA mondiale.[26]

Tableau 19. Cartographie des poles IA africains.

Source : compilation de l'auteur (Mordor Intelligence, McKinsey, Cassava Technologies, sources gouvernementales 2025-2026).

Pole	DC (nb)	Investissement cle	Atout distinctif	Acteur dominant
Afrique du Sud	56	MS 300 M USD ; AWS 1,7 Md USD ; Cassava/Nvidia 3 000 GPU	1er marche DC africain (40,8 pct) ; CAIR ; National AI Strategy	Hyperscalers US
Nigeria	17-20	Equinix 100 M USD ; marche DC 288 M USD (2025) vers 1,09 Md USD (2031)	Population 220 M ; fintech ; cables sous-marins Lagos	Mix US/local
Kenya	19	MS+G42 1 Md USD (geothermie 100 MW vers 1 GW) ; IXAfrica	Geothermie 60 pct+ ; Silicon Savannah ; ZES	MS / G42 (EAU)
Maroc	~15	Naver/Nvidia 500 MW ; lozera 500 M USD ; Cassava AI Factory	Proximite Europe (15 km) ; renouvelables ; export compute	Coree / US
Egypte	~12	Cassava/Nvidia ; hub Moyen-Orient/Afrique	Strategie IA mature ; position geographique carrefour	Mix US/Golfe
Rwanda	3-5	C4IR ; Sommet IA Kigali 2025 ; Masakhane NLP	Politique IA formelle ; AI lab continental	Multilateral/WEF

Tableau 20. Competition US-Chine en Afrique : cartographie des engagements IA.

Source : compilation de l'auteur a partir des annonces officielles 2024-2026.

Dimension	Etats-Unis	Chine
Infrastructure	Cassava/Nvidia (720 M USD, 12 000 GPU) ; MS (300 M USD ZA, 1 Md USD Kenya) ; AWS (1,7 Md USD ZA) ; Google (1 Md USD global)	Huawei 70 pct backbone 4G ; DC integres Ethiopie ; 30 marches 5G ; FOCAC 20 projets numeriques
Modeles IA	ChatGPT (via cloud US) ; Nvidia AI stack ; OpenAI/Penda Health (reduction 16 pct erreurs diagnostiques Kenya)	DeepSeek (-94 pct cout vs ChatGPT) ; Alibaba Qwen ; Huawei Pangu
Talent / Skilling	MS : 1M ZA + 1M Nigeria + 1M Kenya en AI skills ; Google : 100K bourses Ghana ; Intel/AfDB : 3M formes	Huawei : 120K Africains formes ; FOCAC centre numerique Chine-Afrique
Strategie	AI Action Plan : export full stack a allies ; US-Africa Tech Collaboration ; BUILD Act vs BRI	BRI numerique ; prix bas ; base installee telecom ; small & beautiful FOCAC 2024

Tableau 21. Scenarios specifiques pour l'Afrique sous matrice 2x2.

Source : construction de l'auteur, application de la matrice du chapitre V au cas africain.

	Reponse africaine passive	Reponse africaine active
Protectionnisme US modere	S1 - Stagnation dependante. Acces limite au compute US ; consommation passive de cloud importe ; brain drain continu ; IA environ 1 pct du PIB africain 2030	S2 - Rattrapage cible. AI Factories operationnelles ; corridors energetiques Kenya/Maroc ; NLP langues africaines ; IA environ 3 pct PIB 2030
Protectionnisme US intense	S3 - Bifurcation imposee. Basculement vers ecosysteme chinois ; dependance Huawei/DeepSeek ; fragmentation standards ; risque surveillance	S4 - Non-alignement numerique. Strategie continentale UA ; multi-sourcing US/Chine/open-source ; souverainete donnees ; modeles ouverts locaux

Tableau 22. Synthese CACI et position africaine.

Source : construction de l'auteur ; baseline US sur snapshot avril 2026 (76,9 pct compute IA operationnel mondial).

Indicateur	Afrique (2025)	US (2025)	Ratio
Capacite DC (GW IT)	0,78-1,17	53,7	x46-69
Investissement DC (Md USD)	~2	660-690	x330-345
GPU IA (Nvidia)	12 000 (cible 3-4 ans)	Plusieurs millions	x100+
Talent IA	3 pct pool mondial	~40 pct pool mondial	x13
Marche IA (Md USD)	4,5 (2025) vers 16,5 (2030)	~200 (2025)	x44 (2025)

Notes

1. WEF (decembre 2025), 'Investment in green computing can unlock 1.5T USD in Africa'. Africa Data Centres Association : l'Afrique represente 18 pct de la population mondiale mais moins de 1 pct de la capacite DC mondiale.
2. WEF (decembre 2025), ibid. 7 millions d'heures GPU de demande non satisfaite ; seuls 5 pct des innovateurs IA ont acces au compute avance.
3. McKinsey (novembre 2025), 'Building data centers for Africa's unique market dynamics'. Projection 1,5-2,2 GW d'ici 2030. Mordor Intelligence (2026) : marche Africa DC evalue a 1,94 Md USD en 2025.

4. Cassava Technologies / Bloomberg (avril 2025) : cout GPU Nvidia estime a 45 000-60 000 USD l'unité. Nvidia controle environ 93 pct du marche GPU mondial.
5. Ecofin Agency (fevrier 2026), 'Huawei Expands Chinese AI-Integrated Data Centre Solutions to Ethiopian Banking Sector'. Huawei premier a deployer IA operationnelle en Afrique subsaharienne. Ainvest/GSMA : Huawei domine 70 pct du backbone 4G africain.
6. Microsoft (mars 2025), annonce 5,4 Md ZAR d'ici 2027. AWS (2024) : 1,7 Md USD region du Cap. Mordor Intelligence : marche AI DC Afrique du Sud de 70 M USD (2025) a 572 M USD (2031), CAGR 42 pct.
7. GlobeNewsWire (fevrier 2026), 'Nigeria Data Center Market Investment & Growth Report 2026-2031'. Equinix : 22 M USD pour LG3 Lagos (novembre 2025), plan d'expansion 100 M USD Afrique.
8. DCD (mai 2024), 'Microsoft and G42 to build geothermal-powered data center in Kenya'. 1 Md USD d'investissement ; DC 100 MW extensible a 1 GW a Olkaria. Reseau kenyan 60 pct+ renouvelable.
9. Atlantic Council DFRLab / Global Center AI (2025), 'African Countries Are Racing to Create AI Strategies'. Partenariat USTDA-Kenya Semiconductor Technologies.
10. DCD (juin 2025), 'Naver plans 500MW data center campus in Morocco'. Consortium Naver/Nvidia/Nexus Core/Lloyds Capital. Phase 1 : 40 MW, GPU Blackwell GB200. Research & Markets : capacite DC Afrique environ 400 MW fin 2025, Maroc environ 35 pct.
11. Carnegie Endowment (septembre 2025), 'Understanding Africa's AI Governance Landscape'. Cassava Technologies : 12 000 GPU dans 5 pays (ZA, Egypte, Nigeria, Kenya, Maroc).
12. Future of Privacy Forum (2025), 'The African Union's Continental AI Strategy'. Rwanda : seul pays avec politique nationale IA. C4IR Rwanda en partenariat WEF.
13. Bloomberg (avril 2025), 'Nvidia, Cassava's AI Factory in Africa Tie-Up to Cost 720 Million USD'. TechCabal (octobre 2025) : Nvidia investissement en capital dans Cassava. New Lines Institute (juillet 2025) : plus important engagement infrastructure tech privée en Afrique.
14. Semafor (juillet 2025), 'Google raises African AI bet' : 37 M USD specifiquement pour IA en Afrique, dans engagement global de 1 Md USD. Microsoft (fevrier 2026) : 124 millions de personnes connectees en Afrique sur 299 millions mondialement.
15. Rest of World (novembre 2025), 'Huawei pushes AI and cloud into emerging markets after U.S. ban'. Huawei present depuis les annees 1990. Forrester (novembre 2025) : Ascend 910C a une generation des offres US les plus avancees.
16. Africa Defense Forum (novembre 2025), 'China's DeepSeek Chatbot Expansion in Africa Raises Alarms'. DeepSeek 94 pct moins cher que ChatGPT. Donnees stockees sur serveurs accessibles au gouvernement chinois. Ainvest (aout 2025) : Huawei 120 000 Africains formes.
17. Africa Defense Forum, ibid. Parallele avec Belt and Road : amelioration d'acces mais dependance financiere et politique. New Lines Institute (2025) : FOCAC Action Plan 2025-2027, 20 projets numeriques.
18. Rest of World (novembre 2025), ibid. Rebecca Arcesati, Mercator Institute : 'We are seeing a bifurcation of the global AI stack'.
19. Union africaine (mai 2025), 'Africa Declares AI a Strategic Priority'. 83 pct du financement IA startups en Q1 2025 vers Kenya, Nigeria, Afrique du Sud, Egypte. Seuls 3 pct du talent IA mondial en Afrique.
20. African Business (decembre 2025), 'Inside the race to fire up Africa's power-hungry data centres'. Raxio Group : 90 000 litres de diesel stockes pour DC 1,5 MW.
21. Intelpoint (aout 2025) : 16 pays africains sur 54 avec strategie IA nationale. White & Case : Strategie continentale UA Phase I (2025-2026) focus gouvernance + mobilisation ressources.
22. McKinsey (novembre 2025), ibid. 'Power availability, not demand density, increasingly determines siting decisions.' African Energy Chamber (2025) : Kenya 60 pct+ renouvelable ; Cote d'Ivoire 37,5 MWp solaire Boundiali.
23. Microsoft LINGUA Africa : 5,5 M USD pour modeles IA langues africaines sous-representees. Mastercard (aout 2025), 'AI in Africa' : plus de 1 000 langues parrees, projets Masakhane et UlizaLlama.
24. Tech In Africa (octobre 2025), 'North vs. Sub-Saharan Africa : AI Investment Trends'. Marche IA africain de 4,51 Md USD (2025) a 16,53 Md USD (2030), CAGR 27,42 pct. 2 400+ entreprises IA, 41 pct startups.
25. Carnegie Endowment (2025), ibid. Estimation 7 Md USD+ necessaires pour combler deficits donnees, compute et competences. UA Continental AI Strategy : Phase II (2028) pour implementation projets core.

26. New Lines Institute (juillet 2025), 'Accelerating U.S.-Africa Tech Collaboration'. Analyse du partenariat Cassava/Nvidia comme modele pour l'engagement technologique US-Afrique.

CHAPITRE VII - RECOMMANDATIONS STRATEGIQUES

CHAPITRE VII

Recommandations strategiques pour la France et l'Europe

Les chapitres precedents ont etabli que le protectionnisme IA americain cree un avantage competitif structurel mesurable (CACI Power Mode US/UE de 3,46:1 sur le snapshot avril 2026, ratio brut compute installe operationnel de 17,6:1), accelere par les tarifs Trump de 2026 et la concentration du compute aux Etats-Unis (76,9 pct du compute IA operationnel mondial, 660-690 milliards USD de capex annuel des seuls hyperscalers). Ce chapitre formule des recommandations strategiques articulees en trois horizons temporels et cinq axes structurants, en s'appuyant sur les avantages comparatifs specifiques de la France (nucleaire, Mistral, regulation) et les instruments europeens existants (AI Continent Action Plan, Chips Act, InvestAI).

7.1 Axe 1 - Infrastructure compute : combler le gap

7.1.1 Court terme (2026-2027) : accelerer les AI Factories

Le point de depart est l'ecart d'infrastructure. L'UE dispose d'environ 35 GW de capacite IT data centers contre 53,7 GW aux Etats-Unis et 19,6 GW en Chine. En compute IA strict, le tableau de bord public d'avril 2026 etablit une part UE(13) F_total de 3,3 pct contre 76,9 pct pour les Etats-Unis, soit un ratio brut operationnel de 17,6:1 et un ratio CACI Power Mode (formule geometrique $F^{0,40} \times L^{0,20} \times R^{0,15} / E^{0,25}$) de 3,46:1. Trois mesures immediates s'imposent.

Premierement, accelerer la mise en service des 13 AI Factories europeennes deja creees dans 17 Etats membres (AI Continent Action Plan, avril 2025), avec un objectif de pleine operationnalite fin 2027 au lieu de l'horizon 2028-2029 actuellement envisage.[1] Deuxiemement, mettre en oeuvre les Special Compute Zones proposees par le Centre for Future Generations, c'est-a-dire des zones derogatoires (permis acceleres, fiscalite allgee, connexion reseau prioritaire) pour les data centers IA d'importance nationale.[2] La France a deja amorce cette demarche avec la legislation envisagee pour designer les data centers comme projets d'interet national majeur. Troisiemement, securiser les contrats long-terme de GPU avec Nvidia, AMD et Intel via des accords cadres multilateraux (UE-Nvidia, UE-AMD) garantissant un volume annuel plancher de livraison.

Une nuance cle issue de l'analyse Phys/Sov du chapitre I (Fig 1.8) : sur le compute physiquement installe, l'UE est deja largement souveraine (99,2 pct du F_total UE est detenu par des operateurs UE). La fenetre de vulnerabilite n'est donc pas tant sur le F installe que sur la couche des charges cloud (le compute reellement utilise par les entreprises UE, majoritairement heberge sur AWS/Azure/GCP). Les recommandations qui suivent ciblent prioritairement cette couche operationnelle.

7.1.2 Moyen terme (2027-2029) : les AI Gigafactories et le cloud souverain

Le programme InvestAI prevoit 200 milliards EUR (50 milliards publics, 150 milliards prives), dont 20 milliards pour cinq AI Gigafactories qui permettront de creer des modeles frontiers souverains.[3] Ce programme doit

etre calibre en fonction du benchmark americain : les 660-690 milliards USD de capex 2026 des seuls cinq hyperscalers US representent plus de trois fois l'enveloppe europeenne sur cinq ans. L'ecart d'investissement est structurel et ne sera pas comble par les seuls fonds publics.[4]

La France dispose d'un avantage distinctif dans cette competition. Le campus IA MGX-Bpifrance-Mistral-Nvidia, annonce au Choose France Summit 2025, prevoit 1,4 GW de puissance compute alimentee par le nucleaire, avec des capacites exascale operationnelles d'ici 2028.[5] Mistral Compute, lance avec 18 000 superchips Nvidia Grace Blackwell dans un data center de 40 MW en Essonne, constitue la premiere offre europeenne credible de compute frontier sans exposition au CLOUD Act. Le capex de Mistral de 1 milliard EUR pour 2026, complete par le data center de Borlange (Suede, 1,2 milliard EUR, energie verte, ouverture 2027), montre qu'un champion europeen peut constituer une infrastructure alternative.[6]

Le cloud souverain constitue le complement necessaire. La certification SecNumCloud 3.2 de l'ANSSI et la joint-venture S3NS (Thales-Google Cloud, certifiee SecNumCloud decembre 2025), la joint-venture Bleu (Orange-Capgemini-Microsoft, milestone 1 atteint novembre 2025), et l'AWS European Sovereign Cloud (lance janvier 2026, GmbH allemande separee) creent un ecosysteme graduellement souverain.[7] L'objectif devrait etre d'atteindre 30-40 pct des workloads IA sensibles heberges sur cloud souverain certifie d'ici 2029. C'est precisement l'augmentation du facteur F_{sov} (Chap V section 5.9.2) qui protege contre l'activation hypothetique des Cloud Sovereignty Mandates US en 2028.

7.2 Axe 2 - Energie : transformer l'atout nucleaire en avantage compute

7.2.1 L'avantage energetique francais

La France dispose d'un avantage energetique unique en Europe : 70 pct d'electricite nucleaire decarbonee, un parc de 56 reacteurs (plus Flamanville 3 a pleine puissance), des couts electriques competitifs et une infrastructure de transport robuste. Sur le snapshot avril 2026 du tableau de bord public, le cout PPA-ajuste France/USA s'etablit a 115 contre 85 USD/MWh, soit un ratio de 1,35x bien plus favorable que la moyenne UE (135 USD/MWh, ratio 1,59x). EDF a identifie quatre sites industriels totalisant 2 GW (extensibles a six sites d'ici 2026), avec connexion directe au reseau, reduisant les delais de raccordement.[8] L'initiative Nuclear for AI d'EDF prevoit 250 MW connectes a des chips IA fin 2026, creant un marche off-take nouveau pour le nucleaire.

Cet avantage est explicitement reconnu par les investisseurs internationaux. Les investissements annonces lors de l'AI Action Summit de fevrier 2025 totalisent 109 milliards EUR, dont Brookfield/Data4 (20 milliards), EAU (30-50 milliards), et Fluidstack (10 milliards pour un supercalculateur de 1 GW alimente par le nucleaire, operationnel 2026).[9] La France est le seul pays europeen capable d'offrir simultanement electricite decarbonee abondante, stabilite du reseau baseload, et competitivite tarifaire pour les data centers IA - un triptyque que ni l'Allemagne (sortie du nucleaire), ni les Pays-Bas (contraintes grid), ni l'Irlande (saturation energetique) ne peuvent reproduire.

7.2.2 Recommandations energetiques

Premierement, accelerer le programme EPR 2. Les six reacteurs EPR 2 annonces (Penly, Bugey, 9 900 MW, construction a partir de 2027) doivent etre explicitement integres dans la planification energetique des data centers. L'ajout de huit reacteurs optionnels supplementaires devrait etre confirme avant 2028, pour anticiper la demande 2032-2035.[10]

Deuxiemement, soutenir les SMR (Small Modular Reactors). Le programme France 2030 alloue 1 milliard EUR aux SMR. NUWARD (filiale EDF, 340 MWe) reste le projet le plus avance. Trois start-ups (Newcleo, Stellaria, Jimmy Energy) ont depose des dossiers aupres de l'ASN fin 2025-debut 2026. L'objectif devrait etre le premier SMR commercial dedie data center d'ici 2033-2035, avec un pilote connecte a un campus IA. Cependant, l'incertitude sur les delais de commercialisation des SMR impose de ne pas en faire la strategie unique.[11]

Troisiemement, planifier l'integration energetique IA-reseau. RTE projette un besoin supplementaire de 10 GW pour les data centers d'ici 2030 en France. L'integration des previsions de demande IA dans la planification du reseau national (conformement a la recommandation McKinsey d'alignement de la croissance IA avec l'expansion energetique durable) est indispensable pour eviter les goulets d'etranglement.[12]

7.3 Axe 3 - Alliances technologiques et diversification des chaines d'approvisionnement

7.3.1 Consolider les partenariats industriels asymetriques

L'analyse des chapitres VI, VI bis, VI ter et VI quater revele que la France et l'Europe n'ont pas vocation a reproduire l'ensemble de la chaine de valeur IA (ce qui est irrealiste a l'horizon 2030), mais doivent construire des alliances strategiques ciblees qui reduisent les dependances les plus critiques.

Alliance ASML-Mistral. L'investissement d'ASML de 1,3 milliard EUR dans Mistral AI (septembre 2025, ASML devenu premier actionnaire a 11 pct) est le partenariat europeen le plus significatif, reliant le leader mondial de la lithographie (segment critique ou l'Europe domine) au champion europeen de l'IA.[13] Ce type de couplage vertical hardware europeen plus IA europeenne devrait etre systematise.

Partenariat TSMC-Europe. L'usine TSMC de Dresde (10 milliards EUR, production debutee 2027) fabrique des puces sur noeud 28/16/12 nm - insuffisant pour les GPU IA de pointe mais critique pour l'automobile et l'IoT industriel. La negociation d'un second investissement TSMC en Europe sur des noeuds plus avances (7/5 nm) devrait etre une priorite diplomatique.

Alliances Japon-UE et Coree-UE. Le Japon et la Coree controlent des segments critiques de la chaine de valeur que les Etats-Unis ne peuvent pas substituer (memoire HBM de SK hynix, equipements et materiaux de Tokyo Electron et Shin-Etsu). Des accords bilateraux UE-Japon et UE-Coree sur la securite d'approvisionnement en composants IA, structures hors du cadre trilateral US-Japon-Coree, renforceraient l'autonomie europeenne. Le chapitre VI ter a documente que l'engagement japonais aux Etats-Unis (550 milliards USD) est unilateral - un investissement croise UE-Japon equilibrerait cette dynamique.

7.3.2 Reduire l'exposition au risque protectionniste

L'experience Biden-Trump montre que les controles a l'export et les tarifs peuvent etre etendus rapidement et de maniere imprevisible. Trois mesures de reduction du risque s'imposent.

Constitution de reserves strategiques de GPU. Sur le modele des reserves strategiques de petrole (90 jours), constituer un stock national/europeen d'accelerateurs IA couvrant 6 a 12 mois de besoins projetes. Ce stock servirait d'amortisseur face a une activation eventuelle de l'Affiliates Rule (suspendue jusqu'en novembre 2026) ou des tarifs Section 232 etendus.

Diversification des fournisseurs hardware. Accelerer l'evaluation et le deploiement d'alternatives aux GPU Nvidia : AMD MI300X/MI350X, Intel Gaudi 3, Graphcore (UK), et a terme SiPearl (europeen, processeur Rhea pour supercalculateurs). Financer via le Chips Act europeen un programme de qualification d'accelerateurs IA multi-fournisseurs. Le projet DARE (RISC-V europeen, EuroHPC JU) est l'horizon 2030-2032, mais les alternatives intermediaires sont disponibles immediatement.

Clauses anti-weaponisation dans les accords commerciaux. Integrer dans le futur accord commercial UE-US des clauses empechant l'utilisation unilaterale des controles a l'export comme instrument de competitivite commerciale, sur le modele des clauses de non-discrimination de l'OMC.

7.4 Axe 4 - Regulation comme avantage competitif

7.4.1 De l'AI Act a l'Apply AI Strategy

Le CEO de Mistral, Arthur Mensch, a resume le paradoxe europeen : on ne peut pas reguler son chemin vers la suprematie du compute.[14] L'AI Act, entre en application progressive depuis 2024, impose des obligations (transparence, evaluations de risques, conformite) qui constituent a la fois une charge pour les entreprises europeennes et un avantage de differenciation sur les marches mondiaux. L'Apply AI Strategy (2025) complete l'AI Act en adoptant une approche AI first pour le secteur public et en promouvant un buy European, particulierement pour les solutions open-source.[15]

La recommandation est de transformer la regulation en levier offensif plutot que defensif. Trois mesures concretes peuvent y contribuer.

(a) Exiger que les AI Factories et AI Gigafactories financees par InvestAI utilisent en priorite des modeles europeens (Mistral, Aleph Alpha, etc.) et des clouds certifies (SecNumCloud, EUCS niveau eleve).

(b) Exploiter l'effet Bruxelles : les entreprises mondiales se conformant a l'AI Act pour acceder au marche europeen (450 millions de consommateurs) adoptent de facto des standards europeens, creant un avantage normatif. Accelerer les accords de reconnaissance mutuelle avec le Japon, le Bresil et l'Inde.

(c) Creer un CLOUD Act Shield europeen : legislation bloquante (sur le modele du reglement de blocage UE de 1996) empechant les entreprises europeennes de se conformer aux demandes d'accès extraterritoriales americaines sans autorisation de l'autorite nationale competente. Cette mesure est l'instrument legal qui donne corps au Cloud Sovereignty Framework SOV-3 publie par la Commission en octobre 2025 (Chap V section 5.10.4).

7.4.2 Regulation du compute comme bien strategique

L'analyse comparative (chapitres V et VI ter) montre que le compute de pointe est désormais traite par les Etats-Unis, la Chine, le Japon, l'Inde et les Etats du Golfe comme un actif strategique national au meme titre que l'energie ou les matieres premieres critiques. L'Europe doit formaliser cette reconnaissance. Gartner prevoit que les pays poursuivant des stacks IA independants devront investir au minimum 1 pct du PIB dans l'infrastructure d'ici 2029.[16] Pour la France, cela représenterait environ 28 milliards EUR annuels, un ordre de grandeur coherent avec les 109 milliards d'investissements annonces en 2025 (dont une part significative provient de capitaux etrangers).

Le cas des EAU documente au chapitre I (Fig 1.8) constitue un avertissement : 99,6 pct du F_total emirati est detenu par des operateurs US-side, faisant chuter le CACI souverain de 55,7 a 6,0. Une politique d'attraction d'investissements indifferente a la nationalite legale des operateurs reproduirait ce schema en Europe. La regulation europeenne du compute doit prevoir des seuils minimaux de propriete domestique (par exemple, 50 pct minimum d'operateurs sous juridiction UE pour les sites de plus de 100 MW), avec un mecanisme analogue a l'Investment Screening Mechanism deja applique aux investissements strategiques.

7.5 Axe 5 - Talent et capital humain

L'infrastructure sans talent ne produit rien. L'Europe perd des chercheurs IA au profit des laboratoires americains (salaires, acces au compute frontier, echelle des projets). Deux mesures complementaires s'imposent.

Premierement, des bourses IA et des visas talents europeens (recommandation McKinsey : lancement avant fin 2026) pour attirer des chercheurs de rang mondial.[17] La France dispose d'un avantage avec l'ecosysteme Mistral/LightOn/Hugging Face et les grandes ecoles (Polytechnique, ENS, CentraleSupélec), mais doit egaler les salaires offerts par les GAFAM (ecart moyen x2 a x4 pour les profils seniors IA).

Deuxiemement, garantir aux chercheurs europeens un acces au compute equivalent a celui des laboratoires americains. Le deploiement de 500 000 GPU via Fluidstack (operationnel 2026), les 18 000 superchips Mistral Compute, et les AI Factories EuroHPC constituent le debut de reponse. L'objectif est qu'aucun chercheur europeen ne quitte le continent pour des raisons d'accès au compute d'ici 2028.

7.6 Synthese : matrice temporelle des recommandations

Le Tableau 23 ci-apres recapitule les recommandations en croisant trois horizons (2026-2027, 2027-2029, 2029-2032) avec les axes Compute, Energie, et Alliances. Les axes Regulation et Talent se déploient transversalement sur les trois horizons et ne sont pas detailles ligne par ligne dans la matrice.

7.7 Conditions de succes et limites

Plusieurs conditions determineront l'efficacite de ces recommandations.

Condition 1 : la competitivite de Mistral. L'ensemble de la strategie francaise de souverainete IA repose en partie sur la capacite de Mistral a maintenir des performances competitives face a OpenAI, Anthropic et

Google DeepMind. Si l'écart de capacité se creuse, l'infrastructure française servira des besoins de conformité (hébergement souverain de modèles US) plutôt que de véritable souveraineté technologique. [18] La levée de fonds de 1,7 milliard EUR (évaluation 11,7 milliards) et l'établissement de Mistral Compute sont des signaux positifs, mais l'échelle de compétition (OpenAI : 20 milliards USD de revenus récurrents 2025) reste démesurée.

Condition 2 : l'exécution industrielle. Les programmes d'infrastructure IA européens ont historiquement souffert de retards (EuroHPC, Chips Act). Les 13 AI Factories doivent être opérationnelles, pas simplement annoncées. L'expérience du Japon (programme Rapidus 2 nm) et de l'Inde (fosse entre annonces de 200+ milliards et capacité installée de 1,4 GW) illustrent les risques de décalage entre ambition et réalisation.

Condition 3 : la cohérence européenne. La fragmentation intra-européenne (27 régimes énergétiques, positions divergentes sur le nucléaire, approches nationales de souveraineté concurrentes) reste le principal obstacle. Le scénario C du chapitre V (partenariat asymétrique, baseline 3,46:1 vers 2,0-2,5:1) ne fonctionne pour l'Europe que si elle parle d'une seule voix dans les négociations avec Washington.

Condition 4 : le facteur temps. Le point de basculement identifié au chapitre V (2028, saturation compute plus énergie UE, et activation potentielle des Cloud Sovereignty Mandates) impose un calendrier contraint. Si les AI Factories ne sont pas opérationnelles et les sites EDF non raccordés à cette date, le gap de compute se solidifiera en dépendance structurelle. La fenêtre d'action stratégique se situe entre 2026 et 2028 - après quoi les positions se cristallisent autour de la baseline 17,6:1 brut / 3,46:1 CACI Power Mode.

7.8 Conclusion du chapitre

La France dispose d'un ensemble d'atouts uniques en Europe pour répondre au protectionnisme IA américain : un parc nucléaire incomparable (70 pct de l'électricité, en cours d'extension), un champion IA compétitif (Mistral, 11,7 milliards EUR de valorisation, infrastructure compute propre), un écosystème cloud souverain en formation (S3NS, Bleu, OVHcloud, Scaleway, OUTSCALE), et une capacité d'attraction d'investissements étrangers (109 milliards EUR en 2025).

Mais ces atouts ne constituent pas une garantie. L'écart de capex avec les États-Unis (660-690 milliards USD annuels contre 200 milliards EUR sur cinq ans), l'écart de compute (CACI Power Mode 3,46:1 et brut opérationnel 17,6:1), et la dépendance structurelle aux GPU américaines (Nvidia : 80 pct du marché des accélérateurs IA) définissent le périmètre réaliste de l'autonomie atteignable. L'objectif n'est pas l'autarcie technologique - elle est impossible à horizon 2030 - mais une autonomie stratégique suffisante pour que le protectionnisme américain ne se traduise pas en dépendance irréversible. La distinction Phys/Sov établie au chapitre I est ici opérationnelle : l'Europe est déjà largement souveraine sur le compute installé, le travail consiste à sécuriser la couche des charges cloud avant que les Cloud Sovereignty Mandates 2028 ne transforment cette dépendance en levier géopolitique.

Les leçons comparatives sont claires. Le Japon investit 550 milliards USD aux États-Unis pour sécuriser son accès au compute, au prix d'un co-financement de la suprématie américaine. L'Inde promet 200 milliards USD mais ne dispose que de 1,4 GW installé. La Chine, sous restriction maximale, construit un écosystème parallèle avec un retard de 2-3 générations en GPU mais une capacité réelle (246-300 EFLOP/s)

significativement superieure aux 0,5 pct apparents dans les donnees Epoch AI consolidees. Le Bresil hesite entre les deux blocs et risque la fragmentation. L'Afrique cumule l'asymetrie compute la plus extreme (deficit x44 a x417 selon les indicateurs) et le risque de bifurcation imposee. La France, avec son atout nucleaire et Mistral, dispose d'une trajectoire mediane credible : ni alignement total (Japon), ni confrontation (Chine), ni hesitation (Bresil), mais construction methodique d'une autonomie energetique et compute qui garantit la capacite de choix. Le temps pour agir est mesure : la fenetre 2026-2028 est decisive.

Tableau 23. Matrice temporelle des recommandations strategiques par axe (2026-2032).

Source : construction de l'auteur ; baseline avril 2026 (compute brut operationnel US/UE 17,6:1, CACI Power Mode 3,46:1).

Horizon	Axe Compute	Axe Energie	Axe Alliances
2026-2027	13 AI Factories operationnelles ; Special Compute Zones FR ; contrats GPU long-terme	250 MW nucleaire-IA (EDF) ; 6 sites EDF data centers ; Fluidstack 1 GW operationnel	Accord UE-Nvidia volumes ; reserves strategiques GPU ; visas talents IA
2027-2029	5 AI Gigafactories (20 Md EUR) ; 30-40 pct workloads souverains ; Campus MGX-Mistral 1,4 GW	6 EPR 2 construction lancee ; integration IA dans plan reseau ; 8 EPR optionnels confirmes	TSMC Europe noeud 7/5 nm ; accords UE-Japon/Coree HBM ; CLOUD Act Shield europeen
2029-2032	40 pct compute local (vs 5 pct) ; modeles frontier souverains ; SiPearl accelerateur IA UE	Premier SMR data center ; +20 GW nucleaire 2035 ; mix energetique IA integre	Multi-fournisseur GPU qualifie ; normes IA export (effet Bruxelles) ; autonomie 60 pct chaine valeur

Notes

1. Commission europeenne (avril 2025), AI Continent Action Plan. 13 AI Factories dans 17 Etats membres, programme InvestAI 200 Md EUR. Apply AI Strategy (2025) : approche AI first, buy European.
2. Centre for Future Generations (octobre 2025), 'Special Compute Zones : Europe's Recipe'. Zones derogatoires pour reduire les delais d'installation de data centers de 3-5 ans a 12-18 mois.
3. Deloitte (novembre 2025), 'A New Era of Self-Reliance'. InvestAI : 20 Md EUR pour 5 AI Gigafactories, modeles frontier souverains.
4. Euronews (fevrier 2026), 'Will Big Tech's AI Spending Crush Europe's Data Sovereignty ?' Capex 2026 : Amazon 200 Md USD, Alphabet 185 Md USD, Microsoft 145 Md USD, Meta 135 Md USD, Oracle 50 Md USD. Total : 660-690 Md USD. Depenses cloud souverain europeen : 10,6 Md EUR 2026.
5. Global Data Center Hub (mai 2025), 'France's 8.5 Bn USD AI Campus'. Campus MGX-Bpifrance-Mistral-Nvidia : 1,4 GW, exascale, operationnel 2028.
6. Euronews, op. cit. Mistral Compute : 18 000 Grace Blackwell, 40 MW Essonne. Capex 1 Md EUR (2026). Data center Borlange (Suede) : 1,2 Md EUR, EcoDataCenter, energie verte, ouverture 2027.
7. Julien Simon, Medium (janvier 2026), 'AI Sovereignty in Europe : A Decision Framework'. S3NS : SecNumCloud decembre 2025. Bleu : milestone 1 novembre 2025. AWS European Sovereign Cloud : janvier 2026, GmbH Brandebourg.
8. World Nuclear News (fevrier 2025), 'France Tempts AI Firms with Nuclear Electricity'. EDF : 4 sites, 2 GW total, appel a manifestation d'interet. Data4 : 40 MW nucleaire fournis par EDF. Cout PPA-ajuste France 115 USD/MWh selon tableau de bord public (avril 2026).
9. Introl Blog (2025), 'France's AI Sovereignty Push'. AI Action Summit : 109 Md EUR. Bpifrance : 10 Md EUR. Fluidstack : 10 Md EUR, 500 000 GPU, 1 GW, operationnel 2026.

10. Enki AI (fevrier 2026), 'Top 10 Nuclear & SMR Projects in France'. EPR 2 : 6 reacteurs (Penly, Bugey), 9 900 MWe, construction 2027. Option 8 reacteurs supplementaires. 20 reacteurs existants : extension de vie (26 GW).
11. Enki AI, op. cit. NUWARD : 340 MWe, filiale EDF/Naval Group. France 2030 : 1 Md EUR SMR. Newcleo, Stellaria, Jimmy Energy : dossiers ASN deposes. Contre-point : Beyond Nuclear International (janvier 2026) signale des difficultes financieres de certaines start-ups SMR.
12. McKinsey (decembre 2025), 'Accelerating Europe's AI Adoption : The Role of Sovereign AI'. Recommandation : integrer previsions demande IA dans planification energetique nationale. Gains productivite : jusqu'a 40 pct dans les lighthouse factories.
13. S&P Global (decembre 2025), 'Geopolitics of Data Centers'. ASML : 1,3 Md EUR dans Mistral (septembre 2025), 11 pct du capital. Levee Mistral : 1,7 Md EUR, valorisation 11,7 Md EUR.
14. Euronews, op. cit. Citation Arthur Mensch (2025) : 'US companies are building the equivalent of a new Apollo program every year' et 'you cannot regulate your way to computing supremacy'.
15. Commission europeenne (2025), Apply AI Strategy. AI first pour le secteur public, buy European pour les solutions open-source. AI Observatory pour suivi des tendances.
16. Intelligent CIO Europe (fevrier 2026). Gartner : 1/3 des entreprises utiliseront des plateformes IA localisees d'ici 2027 (vs 5 pct aujourd'hui). Investissement minimum 1 pct du PIB en infrastructure IA d'ici 2029.
17. McKinsey, op. cit. Bourses IA et visas talents a lancer avant fin 2026. 44 pct des leaders tech europeens citent la securite des donnees comme frein au cloud public ; 31 pct la localisation des donnees.
18. Introl Blog, op. cit. 'If the capability gap widens, French infrastructure may serve compliance requirements without enabling competitive AI applications.' OpenAI : 20 Md USD ARR 2025 (x3 en un an).

CONCLUSION GENERALE

CONCLUSION GENERALE

Du protectionnisme IA a la recomposition de l'ordre technologique mondial

Cette conclusion synthetise les resultats de l'etude conduite sur la periode 2022-2026, valide l'hypothese centrale d'un regime protectionniste IA americain, expose les contributions a la litterature, identifie les limites et pistes de recherche, et argumente l'enjeu de civilisation que represente le compute IA comme quatrieme facteur de production. Elle se cloture par le tableau recapitulatif des onze chapitres et l'inventaire des sources principales mobilisees.

1. Validation de l'hypothese centrale

Cette etude partait d'une hypothese precise : l'administration Trump 2.0 transformerait les controles a l'export Biden en un regime protectionniste plus large, utilisant le compute IA comme instrument de puissance economique et geopolitique - un decret implicite AI for Americans First. L'analyse empirique conduite sur la periode 2022-2026 valide cette hypothese de maniere substantielle.

Le 15 janvier 2026, l'administration Trump a simultanement promulgue un tarif de 25 pour cent (Section 232) sur les semi-conducteurs IA avances (Nvidia H200, AMD MI325X) pour les reexportations vers la Chine, et publie la regle finale BIS regissant les exportations de puces IA. La combinaison tarifs plus controles a l'export constitue precisement le mecanisme hybride que nous anticipions : une taxe sur l'accès au compute de pointe qui genere des revenus pour le Tresor americain tout en ralentissant les concurrents, combinee a un acces domestique illimite qui renforce l'avantage competitif des Big Tech US.[1]

Plus encore, l'AI Action Plan de juillet 2025 formalise une doctrine qui depasse les simples controles de securite nationale : exporter le stack IA complet (hardware, modeles, logiciels, applications et standards) aux pays disposes a rejoindre l'alliance IA americaine, sous condition de conformite aux exigences de securite US.[2] L'IA n'est plus traitee comme une technologie parmi d'autres, mais comme un instrument de projection de puissance analogue au dollar dans le systeme monetaire ou au petrole dans le systeme energetique.

2. Synthese des resultats

2.1 Un avantage competitif americain mesurable et croissant

L'indice CACI (Compute-Adjusted Competitive Index) developpe dans cette etude permet de quantifier l'asymetrie structurelle. Sur le snapshot du tableau de bord public d'avril 2026, le ratio brut compute installe operationnel US/UE(13) s'etablit a 17,6:1, traduit par une formule geometrique ponderee $F^{0,40} \times L^{0,20} \times R^{0,15} / E^{0,25}$ en un ratio CACI Power Mode de 3,46:1. La concentration de 76,9 pour cent du compute IA

operationnel mondial aux Etats-Unis (49,9 pour cent en incluant les capacites planifiees), un capex annuel des hyperscalers de 660-690 milliards USD (superieur au PIB de la Suede), et un cout de training des modeles frontier 5 a 10 fois inferieur au cout europeen confirment cette domination. L'avantage est auto-renforçant : les entreprises disposant d'un acces abondant au compute captent des rentes d'innovation et de donnees qui sont tres difficiles a rattraper ensuite (chapitre IV).

Une nuance methodologique importante issue du chapitre I (Fig 1.8) : la decomposition Phys/Sov rigoureusement calculee a partir du champ Owner d'Epoch AI revele que l'asymetrie est differenciee selon les juridictions. Les Etats-Unis et la Chine sont integralement souverains sur leur compute installe (CACI Phys = CACI Sov). L'UE est aussi tres largement souveraine sur son F installe (99,2 pour cent UE-owned). Le cas extreme est celui des Emirats arabes unis : 99,6 pour cent du F_total emirati est detenu par des operateurs US-side (Stargate UAE, Microsoft, OpenAI), faisant chuter le CACI souverain de 55,7 (Physique) a 6,0. Cette dissociation Phys/Sov, formalisee au chapitre V section 5.9.2 sous l'hypothese d'activation des Cloud Sovereignty Mandates 2028, transforme radicalement la lecture de l'asymetrie : la vulnerabilite europeenne se situe non sur le compute installe mais sur la couche operationnelle des charges cloud (majoritairement hebergees sur AWS/Azure/GCP).

2.2 Une architecture protectionniste a trois etages

L'analyse revele que le protectionnisme IA americain opere a trois niveaux distincts mais cumulatifs.

Premier etage : les controles a l'export (herites de Biden, maintenus et transformes par Trump). Le systeme de tiers (Tier 1/2/3) segmente le monde en fonction de l'alignement geopolitique : acces libre pour les allies proches (20 pays), caps quantitatifs pour le reste du monde, interdiction pour les adversaires (Chine, Russie). Meme apres l'abrogation formelle de l'AI Diffusion Rule en mai 2025, l'incertitude reglementaire pese sur les decisions d'investissement des pays Tier 2 (chapitre III).

Deuxieme etage : les tarifs douaniers (innovation Trump). Le tarif de 25 pour cent sur les semi-conducteurs IA avances (Section 232, janvier 2026) constitue une rupture : les controles a l'export visaient la securite nationale, les tarifs visent explicitement les revenus et l'avantage concurrentiel. La combinaison tarifs plus exemptions domestiques cree un differentiel de cout direct entre entreprises americaines et non-americaines (chapitre V).

Troisieme etage : la gravite capitalistique. La concentration du capex (660-690 milliards USD chez cinq entreprises en 2026), combinee a l'accès energetique (les Etats-Unis acceptent un recours accru aux fossiles, 53,7 GW de capacite DC installee), cree un effet gravitationnel : les investissements japonais (550 milliards), des Emirats, de SoftBank/Stargate convergent vers le sol americain, renforçant le hub compute sans intervention reglementaire supplementaire (chapitre VI ter).

Un quatrieme etage potentiel se profile a l'horizon 2028 : les Cloud Sovereignty Mandates analyses au chapitre V section 5.9. En etendant les obligations du Framework for AI Diffusion a la couche cloud, ils transformeraient les hyperscalers US operant offshore en intermediaires conditionnels du compute mondial. La fenetre de vulnerabilite europeenne (CADA operationnel au mieux 2027-2028, Mandates US activables 2028) est maximale entre 2028 et 2030.

2.3 Consequences differenciees par region

Le Tableau 24 ci-apres synthetise les positions structurelles et les risques specifiques de chaque region etudiee, en integrant l'extension a l'Afrique developpee au chapitre VI quater.

3. Contributions de cette etude

Cette recherche apporte cinq contributions a la litterature economique et geostrategique.

Premierement, l'integration analytique de trajectoires habituellement traitees separement - energie, semi-conducteurs, compute, regulation, productivite - dans un cadre unifie. L'essentiel des travaux academiques traite separement ces dimensions ; notre analyse montre qu'elles forment un systeme d'interdependances ou chaque contrainte amplifie les autres (l'energie contraint le compute, le compute contraint la productivite, la productivite determine la competitivite).

Deuxiemement, la proposition de l'indice CACI (Compute-Adjusted Competitive Index), qui offre un cadre de mesure pour comparer la competitivite IA entre regions en integrant FLOPs disponibles, capital humain, regulation et cout energetique selon une formule geometrique ponderee. Si cet indice reste a affiner empiriquement, il constitue une premiere tentative de synthetiser le concept de compute-adjusted competitiveness identifie comme manquant dans la litterature (chapitre II). L'extension Phys/Sov introduite au chapitre I et formalisee au chapitre V ($F = F_{\text{phys}} \times F_{\text{sov}}$) ajoute une dimension juridictionnelle qui distingue le compute physiquement present du compute legalement controlable - distinction operationnelle des le snapshot avril 2026 (cas EAU 99,6 pct US-side) et systemique sous regime Cloud Sovereignty Mandates 2028.

Troisiemement, la demonstration que le protectionnisme IA americain produit des effets paradoxaux systemiques. Les restrictions destinees a maintenir l'avantage US accelerent la construction d'un ecosysteme chinois alternatif (DeepSeek, Huawei Ascend, capacite reelle 246-300 EFLOP/s contre 0,5 pct apparent dans les donnees Epoch AI consolidees), poussent les pays Tier 2 vers la Chine (ByteDance au Bresil, en ASEAN, en Afrique), et incitent les allies Tier 1 a co-financer la suprematie US plutot qu'a construire une autonomie veritable (Japon : 550 milliards vers les Etats-Unis). Le protectionnisme IA ne produit pas un monde unipolaire mais un monde fragmente en blocs technologiques.

Quatriemement, l'analyse comparative inedite des reponses regionales au protectionnisme IA (Europe, Amerique du Sud, Asie, Afrique), montrant que la position geopolitique, la dotation energetique et la proximite avec les chaines de valeur determinent des trajectoires de dependance fondamentalement differentes, irreductibles a un modele unique de rattrapage ou de decrochage.

Cinquiemement, l'extension a l'Afrique (chapitre VI quater) documente l'asymetrie compute la plus extreme au monde (deficit x44 a x417 selon les indicateurs) et montre comment le protectionnisme americain cree pour ce continent un double bind specifique : restriction d'accès au compute frontier US d'un cote, exposition aux risques de surveillance et de sanctions secondaires du recours a l'alternative chinoise de l'autre.

4. Limites et pistes de recherche

Cette étude comporte plusieurs limites qu'il convient d'expliciter.

Incertitude réglementaire. L'environnement des export controls évolue rapidement. L'AI Diffusion Rule de Biden a été abrogée en mai 2025 ; la règle finale Trump de janvier 2026 pourrait elle-même être modifiée (Commerce doit fournir une mise à jour au Président d'ici juillet 2026). Les scénarios proposés au chapitre V reflètent cette incertitude, mais l'espace des possibles est plus large que les quatre scénarios formalisés.

Données fragmentaires. Les données de compute IA par région restent incomplètes malgré le snapshot rigoureux du tableau de bord public d'avril 2026. Les estimations Epoch AI sous-représentent significativement la capacité chinoise réelle (Chine 0,5 pct apparent vs 246-300 EFLOP/s revendiqués) en raison de l'anonymisation des clusters chinois et de l'opacité des fournisseurs Huawei/Cambricon/Biren. Le CACI est un indice exploratoire, calibre sur le snapshot avril 2026 mais non encore valide sur séries temporelles longues.

Horizon temporel. L'analyse porte sur 2026-2030, mais des ruptures technologiques (quantum computing, nœuds sub-2 nm, architectures neuromorphiques) pourraient redistribuer les cartes après 2030. L'avantage actuel de Nvidia en GPU pourrait être contesté par des ASIC spécialisés (Google TPU, Amazon Trainium, Huawei Ascend) ou des architectures radicalement différentes (DARE/RISC-V européen, horizon 2030-2032).

Sensibilité aux pondérations CACI. Les pondérations de la formule géométrique ($F^{0,40} \times L^{0,20} \times R^{0,15} / E^{0,25}$) ont été choisies au chapitre II en fonction de la littérature mais ne sont pas issues d'une calibration économétrique. Une analyse de sensibilité systématique sur ces pondérations pourrait révéler des trajectoires alternatives non explorées.

Pistes de recherche futures. Quatre prolongements s'imposent. Premièrement, le calibrage empirique du CACI sur données d'enquête (productivité sectorielle par accès au compute) permettrait de valider ou ajuster les pondérations actuelles. Deuxièmement, l'approfondissement sectoriel de la couverture Afrique (chapitre VI quater) - notamment l'analyse pays par pays des 16 stratégies IA nationales recensées et de la mise en œuvre de la Stratégie continentale UA Phase II 2028. Troisièmement, la modélisation dynamique de l'interaction énergie-compute-productivité via des modèles d'équilibre général calculable (CGE) intégrant les contraintes de compute comme facteur de production. Quatrièmement, l'observation longitudinale du régime Cloud Sovereignty Mandates 2028 (s'il s'active effectivement) et de ses effets sur la trajectoire F_{sov} des différentes juridictions.

5. L'enjeu de civilisation

Au-delà des métriques économiques et des scénarios géopolitiques, cette étude révèle un enjeu plus fondamental. Le compute IA est en passe de devenir le quatrième facteur de production (après le capital, le travail et la terre/énergie), structurant l'accès aux gains de productivité, à l'innovation, et in fine à la prospérité. Comme le pétrole au XX^e siècle, le contrôle du compute au XXI^e siècle déterminera quelles nations et quelles entreprises captent les rentes de l'innovation.

Les Etats-Unis l'ont compris. L'AI Action Plan de juillet 2025 traite explicitement le stack IA comme un instrument d'alliance geopolitique, comparable au Plan Marshall ou au systeme de Bretton Woods : l'accès au compute americain est conditionne a l'alignement strategique, creant un systeme de dependances hierarchisees. Carnegie note que la regle visait a utiliser les exportations d'IA comme levier sur les Etats pivots geopolitiques, en etablissant des incitations pour que d'autres gouvernements adoptent les standards et protections technologiques americains en echange de puces US.[3]

Face a ce nouveau systeme, la France et l'Europe disposent d'un choix strategique qui se resume, au fond, a trois options. La premiere est l'integration subordonnee : accepter le statut de junior partner technologique dans le bloc americain, comme le Japon l'a choisi en investissant 550 milliards USD sur le sol US. Cette option minimise le risque de rupture d'accès mais maximise la dependance. La deuxieme est la confrontation souverainiste : construire un ecosysteme IA entierement autonome, comme la Chine y est contrainte. Cette option est irrealiste a l'horizon 2030 pour l'Europe, qui ne dispose ni de la base industrielle de semi-conducteurs ni de la capacite de marche interieur suffisantes.

La troisieme option - celle que cette etude recommande au chapitre VII - est l'autonomie strategique ciblee. Elle consiste a batir une souverainete sur les segments ou l'Europe possede un avantage comparatif (energie nucleaire francaise au cout PPA 1,35x USA, equipements de lithographie ASML, modeles IA ouverts Mistral, cadre reglementaire AI Act) tout en maintenant l'interopabilite avec l'ecosysteme americain. L'objectif n'est pas l'autarcie mais la capacite de choix : disposer d'alternatives credibles (cloud souverain SOV-3, compute local sous juridiction UE, modeles ouverts) pour ne jamais etre captif d'un fournisseur dont les interets geopolitiques pourraient diverger des notres. La distinction Phys/Sov etablie au chapitre I est ici operationnelle : il s'agit d'augmenter F_{sov} sur la couche des charges cloud, pas seulement F_{phys} sur l'infrastructure installee.

Le temps presse. Le point de basculement identifie dans cette etude se situe en 2028 : convergence de la saturation compute et energie UE (chapitre V section 5.7.3), activation potentielle des Cloud Sovereignty Mandates (chapitre V section 5.9), et fin probable de la fenetre de vulnerabilite avant cristallisation des positions. Apres cette date, les positions se rigidifient autour de la baseline 17,6:1 brut / 3,46:1 CACI Power Mode et les dependances deviennent structurelles. La fenetre d'action strategique 2026-2028 est etroite. Les 109 milliards EUR d'investissements IA annonces pour la France, le programme InvestAI de 200 milliards EUR, la montee en puissance de Mistral Compute, et les sites nucleaires EDF dedies constituent les elements d'une reponse. Mais entre l'annonce et l'execution, il y a la distance qui separe la strategie du reel. L'Inde promet 200 milliards USD mais ne dispose que de 1,4 GW installee. L'Europe ne peut pas se permettre un ecart comparable entre ambition et realisation.

En definitive, AI for Americans First n'est pas seulement un scenario de politique commerciale. C'est le signal d'une recomposition de l'ordre technologique mondial comparable aux grandes restructurations du XXe siecle - Bretton Woods, le choc petrolier, la fin de la guerre froide. Chacune de ces ruptures a cree des gagnants et des perdants pour des decennies. La question pour la France et l'Europe n'est plus de savoir si cette recomposition aura lieu - elle est en cours - mais de determiner si nous en serons les architectes ou les sujets.

Fabrice Pizzi, Paris, fevrier 2026.

Tableau 24. Synthèse des conséquences régionales du protectionnisme IA américain.

Source : construction de l'auteur, calibration sur le snapshot avril 2026 (US 76,9 pct compute IA opérationnel, ratio brut UE 17,6:1, CACI Power Mode 3,46:1).

Region	Position structurelle	Impact principal	Risque spécifique
Europe / France	Tier 1, dependante GPU + cloud US (72-80 pct workloads)	Compute gap 17,6:1 brut / 3,46:1 CACI ; couts training x5-10	Vendor lock-in geopolitique ; marginalisation si bloc US-Asie se ferme ; vulnerabilite F_sov sur charges cloud
Amerique du Sud / Bresil	Tier 2, terrain de competition US-Chine	Bifurcation technologique ; brain drain amplifie	Triple fracture (Nord-Sud, Est-Ouest, intra-regionale)
Japon / Coree / Taiwan	Tier 1, maillons critiques chaine de valeur	Co-financement suprematie US (550 Md USD Japon) ; transfert production	Partenariat asymetrique ; erosion avantage Taiwan ; investissement japonais aux US plutot qu'en UE
Inde	Tier 2, pivot Sud global	Tension caps GPU vs ambition hub compute	Souverainete applicative sans souverainete hardware
Chine	Tier 3, autonomisation forcee	Ecosysteme IA parallele (Huawei/DeepSeek) ; capacite reelle 246-300 EFLOP/s ; retard 2-3 generations GPU	Bifurcation technologique permanente ; exportation aux Tier 2/3 (Bresil, ASEAN, Afrique)
Afrique	Tier 2/3, deficit compute x44-x417	Asymetrie extreme ; double bind US/Chine	Dependance Huawei/DeepSeek ; surveillance ; enfermement structurel ; cas EAU 99,6 pct US-side

Tableau 25. Recapitulatif des chapitres, volume et appareil critique de l'etude.

Source : construction de l'auteur. Le volume (en pages indicatives) inclut figures et tableaux mais exclut les annexes econométriques.

Chapitre	Titre	Pages indicatives	Notes
I	Cadre theorique : protectionnisme technologique et IA	~12	22
II	Methodologie : matrice scenarielle et indice CACI	~8	10
III	Diagnostic empirique 2020-2026 : energie, semi-conducteurs, compute	~11	20
IV	Mecanismes de l'avantage competitif US	~9	19
V	Scenarios prospectifs 2026-2030 et Cloud Sovereignty Mandates	~14	29
VI	Conséquences pour la France et l'Europe	~10	14
VI bis	Conséquences pour	~11	19

	l'Amerique du Sud et le Bresil		
VI ter	Consequences pour l'Asie	~12	16
VI quater	Consequences pour l'Afrique	~13	26
VII	Recommandations strategiques pour la France et l'Europe	~11	18
Conclusion	Du protectionnisme IA a la recomposition de l'ordre technologique mondial	~9	3
TOTAL	11 chapitres	~120	196

Sources principales mobilisees : AIE, McKinsey, Bruegel, Brookings, Carnegie Endowment, Commission europeenne, White House/BIS, Parlement europeen, CSIS, S&P Global, Epoch AI, Centre for Future Generations (CFG), Euronews, CEPALC/CENIA (ILIA 2025), Banque mondiale, Futurum, Introl, World Nuclear News, Arizton, Pillsbury Law, ITIF, Foreign Policy, Hudson Institute, Mordor Intelligence, McKinsey Global Institute, FMI. Donnees complementaires : Bloomberg, DCD, Morgan Lewis, Tom's Hardware, Serrari Group, Data Center Knowledge, WEF, Africa Defense Forum, Atlantic Council DFRLab, Carnegie Endowment, New Lines Institute, RTE, EDF, ANSSI, USDA. Donnees primaires : tableau de bord public Epoch AI snapshot avril 2026 (<https://mo0ogly.github.io/America-First-IA/dashboard/>).

Notes

1. Pillsbury Law (janvier 2026), 'Trump Admin Targets Advanced AI Semiconductors'. Section 232 : tarif 25 pct sur Nvidia H200, AMD MI325X pour reexportation Chine. Exemptions domestiques US. Regle finale BIS simultanee. Mise a jour marche DC prevue juillet 2026.
2. White House / CM Trade Law (juillet 2025), 'America's AI Action Plan'. Pilier III : exporter le full AI technology stack aux allies. Quatre principes : export aux allies, renforcement enforcement, alignement global, protection mesures.
3. Carnegie Endowment for International Peace (mai 2025), 'The Trump Administration May Be About to Repeal the AI Diffusion Rule'. Analyse du trilemme controle/promotion/levier. Recommandation : elargir le groupe Tier 1, augmenter les allocations Inde, renforcer les exigences de localisation.

Licence et credits

Cette these, AI for Americans First, est mise a disposition selon les termes de la licence Creative Commons Attribution - Pas d'Utilisation Commerciale - Partage dans les Memes Conditions 4.0 International (CC BY-NC-SA 4.0).

Tableau de bord public : <https://moOogly.github.io/America-First-IA/dashboard/>

Depot : <https://github.com/moOogly/America-First-IA>

Auteur : Fabrice Pizzi (handle moOogly), Universite Paris-Sorbonne, Master 2 Intelligence Economique - Intelligence Warfare. Paris, fevrier 2026.