

AI FOR AMERICANS FIRST

AI Protectionism, Energy and Semiconductors:
US/Europe Divergence Trajectories 2024–2030

Integrated Geostrategic and Economic Analysis

Chapter II

Fabrice Pizzi

Universite Sorbonne

Master Economic Intelligence — Intelligence Warfare

72 computação IA global = EUA | **1.6×** custo energia UE/EUA | **3.4:1**
razão CACI EUA/EU (Power Mode)

Paris — February 2026

7 chapters • 4 prospective scenarios • 3 geographic zones

Keywords: artificial intelligence, technology protectionism, semiconductors, export controls, sovereign compute, AI geopolitics, France, United States, China

CAPÍTULO II

Metodologia

2.1 Abordagem geral: análise prospectiva multi-cenários com método misto

O presente estudo combina uma análise empírica retrospectiva (diagnóstico 2020–2026) e uma projeção prospectiva por cenários (2026–2030). Essa arquitetura em duas vertentes responde à natureza do fenômeno estudado: o protecionismo tecnológico em IA é ao mesmo tempo um fato observável (os controles de exportação, as tarifas Seção 232) e um processo em andamento cuja trajetória futura depende de variáveis políticas discricionárias, de reações estratégicas europeias e de evoluções tecnológicas parcialmente imprevisíveis.

A vertente retrospectiva emprega um método quantitativo descritivo, baseado na agregação e na consistência cruzada de dados provenientes de fontes institucionais (IEA, SIA/WSTS, Eurostat, EIA), de relatórios setoriais (McKinsey, Deloitte, Epoch AI) e de documentos regulatórios (Federal Register, BIS, Casa Branca). O objetivo é estabelecer uma base factual rigorosa e referenciada, cobrindo três dimensões: o consumo energético dos data centers, o mercado de semicondutores e a capacidade de computação de IA instalada por região.

A vertente prospectiva insere-se na tradição do *scenario planning* conforme formalizado por Schwartz (1991) e praticado no âmbito da Royal Dutch/Shell desde a década de 1970.¹ Este método, pertencente à escola das *Intuitive Logics* (Bradfield et al., 2005), consiste em construir cenários plausíveis e internamente coerentes — não para prever o futuro, mas para explorar o espaço dos possíveis e avaliar a robustez de diferentes estratégias diante de evoluções divergentes do ambiente.² É particularmente adequado a situações caracterizadas por forte incerteza política e tecnológica, onde os modelos econométricos clássicos atingem seus limites — o que é precisamente o caso do protecionismo tecnológico em IA.

Justificativa da escolha metodológica

Três razões fundamentam o recurso ao método de cenários em vez de uma modelagem econométrica pura. Primeiro, as variáveis-chave da análise são em grande parte *políticas e discricionárias*: a decisão de um presidente americano de impor ou não cotas de GPU à Europa não pode ser modelada por uma função de regressão. Segundo, as interações entre as dimensões energética, tecnológica e geopolítica são *não lineares e sistêmicas*: uma restrição sobre GPUs pode, por efeito cascata, modificar os fluxos de investimento energético, a localização dos data centers e a estrutura concorrencial de setores inteiros. Terceiro, os dados disponíveis sobre a computação instalada por região são *parciais e heterogêneos*: não existe um

banco de dados unificado e público que recenseie os FLOPs de IA por país, o que torna uma calibração econométrica rigorosa prematura.

O método escolhido combina, portanto, o rigor quantitativo do diagnóstico empírico (dados referenciados, séries temporais, razões mensuráveis) com a flexibilidade qualitativa da construção por cenários, no espírito do que Schoemaker (1995) chama de “*heurística disciplinada*.”⁸ Os cenários não são previsões probabilísticas, mas *narrativas estratégicas coerentes*, cada uma baseada em hipóteses explícitas e desdobrando suas consequências por meio de métricas mensuráveis.

2.2 Fontes de dados: classificação e avaliação crítica

O estudo mobiliza três categorias de fontes, cuja confiabilidade e vieses potenciais devem ser explicitamente reconhecidos.

2.2.1 Fontes primárias (documentos oficiais e regulatórios)

Esta categoria inclui textos com força normativa ou institucional: proclamações presidenciais (Seção 232), regras do BIS (AI Diffusion Rule, Entity List), relatórios da IEA, publicações do Parlamento Europeu (EPRS), dados estatísticos oficiais (SIA/WSTS para semicondutores, Eurostat e EIA para energia, RTE para a França). Essas fontes oferecem a mais alta confiabilidade factual, mas podem conter vieses de enquadramento institucional: a IEA tende a privilegiar cenários moderados, o Parlamento Europeu a enfatizar os riscos para a soberania da UE. Levamos isso em conta em nossa interpretação.

2.2.2 Fontes acadêmicas e think tanks

Esta categoria inclui artigos revisados por pares (Farrell & Newman, 2019; Bresnahan & Trajtenberg, 1995; Brynjolfsson et al., 2019; Mügge, 2024) e publicações de think tanks reconhecidos (Bruegel, Carnegie Endowment, CSIS, OCDE, Federal Reserve Board). Os primeiros fornecem ancoragem teórica robusta; os segundos oferecem análises de políticas públicas empiricamente fundamentadas, mas potencialmente influenciadas pelas orientações ideológicas de cada instituição. Privilegiamos o cruzamento de fontes de orientações diferentes (Bruegel / Carnegie / Fed) para limitar esse viés.

2.2.3 Fontes de indústria e consultoria

McKinsey, Deloitte, Accenture, Epoch AI e CFG Europe fornecem dados de mercado, projeções setoriais e estimativas de capacidade que não estão disponíveis em fontes públicas. *Essas fontes apresentam um viés sistemático potencial*: as consultorias têm incentivo para amplificar tendências (para justificar missões de transformação), e as estimativas de mercado são frequentemente otimistas. Atenuamos esse viés triangulando os números com dados institucionais e sinalizando explicitamente as divergências entre fontes. Por exemplo, as vendas de semicondutores em 2024 são de US\$ 627,6 bilhões segundo a SIA (perímetro tradicional), mas de US\$ 775 bilhões

segundo a McKinsey (perímetro ampliado) — uma diferença de 24% que reflete diferenças metodológicas, não inconsistências.⁴

Categoria	Fontes Principais	Dados Extraídos	Viés Potencial
Primárias oficiais	IEA, SIA/WSTS, BIS, Casa Branca, Eurostat, RTE, Parlamento UE	TWh data centers, vendas de semis, regras de exportação, consumo de energia	<i>Enquadramento institucional, conservadorismo</i>
Acadêmicas think tanks	/ Bruegel, Carnegie, CSIS, OCDE, Fed, SSRN (Hawkins et al.)	Quadros teóricos, análises políticas, métricas de computação	<i>Orientação ideológica variável</i>
Indústria consultoria	/ McKinsey, Deloitte, Accenture, Epoch AI, CFG Europe	Projeções de mercado, estimativas de capacidade, custos de treinamento	<i>Otimismo sistemático, interesses comerciais</i>

Tabela 1. Classificação e avaliação crítica das fontes mobilizadas.

2.3 Construção dos cenários

A construção dos cenários segue um protocolo em quatro etapas, inspirado na metodologia da matriz 2×2 (Schwartz, 1991; van der Heijden, 2004) e adaptado ao contexto geoestratégico da IA.⁵

Etapas 1 — Identificação das forças motrizes

Identificamos as forças motrizes que estruturam a evolução do sistema estudado. Essas forças são classificadas em duas categorias, seguindo a distinção clássica de Schwartz entre elementos predeterminados e incertezas críticas.

Os elementos predeterminados — cuja evolução é razoavelmente previsível independentemente do cenário — incluem: (i) o crescimento contínuo da demanda mundial por computação de IA, (ii) o aumento estrutural do consumo energético dos data centers, (iii) a dependência europeia de fundições asiáticas e americanas para chips de ponta, (iv) a concentração da nuvem mundial em torno de três hyperscalers americanos, e (v) o aumento exponencial dos custos de treinamento dos modelos de fronteira. Essas tendências são documentadas no Capítulo III e constituem a base comum a todos os cenários.

As incertezas críticas — cuja evolução depende de escolhas políticas, reações estratégicas ou rupturas tecnológicas — são agrupadas em duas dimensões:

Dimensão 1: A intensidade do protecionismo tecnológico dos EUA. Esta dimensão cobre um espectro que vai da manutenção das restrições atuais (tarifas direcionadas à China, UE amplamente isenta, acesso à nuvem preservado) até um endurecimento agressivo (cotas de GPU para a UE, restrições sobre APIs e modelos, priorização explícita de entregas a empresas americanas). Os fatores determinantes incluem a evolução das relações EUA-China, as pressões do lobby industrial

americano e os arbitramentos internos da administração Trump entre segurança nacional e interesses comerciais.

Dimensão 2: A capacidade de resposta europeia. Esta dimensão cobre um espectro que vai de uma postura passiva (adaptação marginal, aceitação da dependência, ausência de investimentos massivos em computação soberana) até uma resposta ativa (Compute Zones com energia derogada, AI Factories aceleradas, nuclear SMR para data centers, parcerias alternativas com Japão-Coreia-Taiwan, revisão do AI Act para reduzir custos de conformidade). Os fatores determinantes incluem a vontade política da UE, a capacidade de mobilização orçamentária e a velocidade de implantação das infraestruturas energéticas.

Etapa 2 — Matriz 2x2 e geração dos cenários

O cruzamento das duas dimensões de incerteza gera uma matriz de quatro cenários, cada um representando uma combinação coerente de hipóteses:

	UE Passiva	UE Ativa (Resposta)
EUA status quo reforçado	Cenário A — Deriva lenta. Gap estável, dependência crescente, vassalização suave.	Cenário B — Recuperação parcial. UE investe massivamente, gap reduzido, autonomia reforçada.
EUA endurecimento agressivo	Cenário C — Vassalização. Cotas de GPU para UE, gap de produtividade de -25%, deslocalizações massivas.	Cenário D — Guerra fria tecnológica. Fragmentação do bloco ocidental, custos elevados, autonomia forçada.

Tabela 2. *Matriz dos quatro cenários 2026–2030.*

A escolha de quatro cenários em vez de três é deliberada. Schwartz (1991) e os praticantes do método Shell recomendam *nunca construir três cenários*, pois a mente humana tende a tratar o cenário mediano como o “mais provável”, reduzindo assim a utilidade do exercício.⁶ A matriz 2x2 obriga o analista a explorar os quadrantes extremos (C e D), que são precisamente onde as rupturas estratégicas se desenrolam.

Etapa 3 — Desenvolvimento narrativo e quantificação

Cada cenário é desenvolvido segundo um protocolo padronizado em três componentes:

(a) Uma narrativa estratégica descrevendo a sequência plausível de eventos entre 2026 e 2030 (decisões políticas, reações dos atores, evoluções de mercado). Essa narrativa deve ser internamente coerente: cada consequência decorre logicamente das hipóteses estabelecidas.

(b) Uma quantificação das métricas-chave (detalhadas na seção 2.4), calibrada nos dados empíricos de 2020–2026 e projetada segundo as hipóteses do cenário.

Essa quantificação é apresentada como uma ordem de grandeza plausível, não como uma previsão pontual.

(c) Indicadores de alerta precoce (*leading indicators*) que permitem identificar, já em 2026–2027, para qual cenário a realidade está convergindo. Por exemplo: o volume de GPUs entregues à UE (indicador de intensidade do protecionismo dos EUA), ou o número de GW de Compute Zones autorizadas (indicador de capacidade de resposta da UE).

Etapas 4 — Análise de sensibilidade e robustez

Para cada recomendação formulada no Capítulo VII, avaliamos sua robustez frente aos quatro cenários. Uma recomendação é considerada robusta se produz resultados positivos ou neutros em pelo menos três dos quatro cenários. Essa abordagem, coerente com a lógica de robustez do planejamento por cenários, privilegia estratégias que não apostam em um único futuro.

2.4 Métricas-chave e indicador original: o CACI

2.4.1 As seis métricas de divergência

Definimos seis métricas que serão calculadas ou estimadas no diagnóstico empírico (Capítulo III) e depois projetadas em cada cenário (Capítulo V). Juntas, elas formam um painel de controle da divergência EUA/UE em matéria de IA.

#	Métrica	Definição	Fonte(s)	Unidade
M1	Gap de computação	Razão de FLOPs de IA instalados EUA/UE, normalizada pelo PIB	Epoch AI, CFG, Top500	Razão
M2	Custo relativo dos FLOPs	Preço médio do TFlop-segundo para treinamento, EUA vs UE	Bruegel, Epoch AI, provedores de nuvem	\$/TFlop·s
M3	Dependência de nuvem	Parcela das cargas de trabalho de IA da UE executadas em infraestrutura dos EUA (%)	Synergy Research, Accenture	%
M4	Produtividade setorial de IA	Ganho de produtividade atribuído à IA nos setores-chave	McKinsey, Fed Board, Eurostat	% ganho
M5	Restrição energética	Razão demanda energética de data centers / capacidade disponível	IEA, RTE, Ember	Razão
M6	Deslocalizações de IA	Parcela dos projetos críticos de IA da UE deslocalizados para os EUA	Estimativa própria (pesquisas setoriais)	% projetos

Tabela 3. *As seis métricas de divergência EUA/UE.*

2.4.2 O Compute-Adjusted Competitiveness Index (CACI): fundamentos teóricos e construção

Ancoragem na literatura. A construção de um indicador composto de competitividade em IA centrado no compute responde a uma necessidade identificada por várias correntes de investigação convergentes. Desde 2023–2024, a literatura académica e institucional sublinha crescentemente que a capacidade de cálculo se tornou o fator de produção mais discriminante para a IA de fronteira (Sevilla et al., 2022; Epoch AI, 2025; Pilz et al., 2025). Os controlos de exportação americanos colocam explicitamente o compute avançado no cerne da competição geopolítica, enquanto Hawkins, Lehdonvirta & Wu (2025) introduzem o conceito de «soberania do compute» como dimensão estruturante da autonomia estratégica.¹¹

Contudo, os índices de competitividade em IA existentes não colocam o compute no centro da sua construção. O AI Preparedness Index do FMI (Cazzaniga et al., 2024), cobrindo 174 países, agrega quatro dimensões sem medir diretamente a capacidade de cálculo instalada.¹² O Global AI Index da Tortoise Media (2024) classifica 83 países mas dilui o sinal do compute num composto de múltiplos indicadores.¹³ O Stanford AI Index (2025) fornece dados ricos sobre tendências de compute mas não propõe nenhum índice composto. Nenhum destes instrumentos formaliza o mecanismo pelo qual o compute, ajustado do seu custo energético e relacionado com a capacidade de absorção de uma economia, determina a competitividade em IA.

O CACI visa colmatar esta lacuna propondo um indicador parcimonioso mas teoricamente fundamentado, que captura a interação multiplicativa entre três fatores: o compute acessível, o custo energético que o condiciona, e a capacidade económica e humana para o explorar.

Definição formal. O CACI para uma região r no período t é definido como:

$$\text{CACI}(r) = F(r)^{0.40} \times L(r)^{0.20} \times R(r)^{0.15} / E(r)^{0.25} \text{ (Power Mode), ou } \text{CACI}(r) = F(r)^{0.40} \times L(r)^{0.20} \times R(r)^{0.15} / (E(r)^{0.25} \times \text{PIB}) \text{ (Intensity Mode)}$$

$F(r,t)$ = capacidade de compute IA instalada e acessível na região r , medida em FLOP/s agregados (performance 16-bit). Utilizamos os dados Epoch AI GPU Clusters agregados por país e ano, complementados pelas estimativas da OCDE de compute cloud acessível.

$E(r,t)$ = custo energético médio do compute na região r , em €/MWh para data centers. A FLOPs iguais, um país com eletricidade duas vezes mais cara tem um CACI duas vezes mais baixo.

$\text{PIB}(r,t)$ = produto interno bruto da região r (Banco Mundial, Eurostat). A normalização pelo PIB assegura a comparabilidade entre economias de dimensões muito diferentes.

$L(r,t)$ = população ativa com competências em IA (proxy: licenciados STEM + formações IA certificadas). Este fator captura a capacidade de absorção no sentido de Cohen & Levinthal (1990).¹⁴

Justificação da forma multiplicativa. A escolha de uma agregação multiplicativa (geométrica) em vez de aditiva (aritmética) é deliberada. Primeiro, a teoria das General Purpose Technologies (Bresnahan & Trajtenberg, 1995) postula uma forte

complementaridade entre os inputs de inovação. Segundo, o OECD/JRC Handbook (2008, p. 33) recomenda a agregação geométrica quando as componentes não são perfeitamente substituíveis. Terceiro, trabalhos recentes (Koronakos, Kritikos & Sotiros, 2024) confirmam que as dimensões de competitividade em IA apresentam interações que tornam problemática uma agregação linear simples.¹⁵

Interpretação económica. Em forma logarítmica: $\ln(\text{CACI}) = 0,40 \cdot \ln(F) + 0,20 \cdot \ln(L) + 0,15 \cdot \ln(R) - 0,25 \cdot \ln(E)$ (Power Mode). O indicador é concebido para comparação bilateral: o rácio $\text{CACI}(\text{EUA})/\text{CACI}(\text{UE})$ mede a vantagem competitiva relativa. Um rácio de 3,4 significa que, por unidade de recursos e a capital humano igual, os atores americanos dispõem de 3,4 vezes mais compute efetivo que os atores europeus.

2.4.3 Protocolo de calibração e fontes de dados

A calibração do CACI segue um protocolo em quatro etapas conforme às recomendações do OECD/JRC Handbook (2008): (i) identificação e recolha de dados brutos, (ii) tratamento de valores em falta e normalização, (iii) agregação, e (iv) análise de sensibilidade.

F(r,t) — Capacidade de compute IA instalada. A estimação segue uma abordagem bottom-up em três camadas. A camada principal provem do dataset Epoch AI GPU Clusters (versão fevereiro 2026, 746 clusters). As quotas nacionais em maio 2025 são: EUA ~74,5%, China ~14,1%, UE ~4,8%, Noruega ~1,8%, Japão ~1,4%.¹⁶ A camada complementar provem da OCDE (Lehdonvirta et al., 2025). A terceira camada utiliza dados parciais publicados pelos hyperscalers e estimativas CFG Europe.¹⁷

E(r,t) — Custo energético. Dados Eurostat (tarifas industriais de eletricidade) e EIA (preços EUA), ajustados para PPAs dos hyperscalers via estimativas IEA (2025). O custo UE é tipicamente 2 a 3 vezes superior ao dos EUA para eletricidade industrial.¹⁸

PIB(r,t) e L(r,t). O PIB está disponível via o Banco Mundial e Eurostat. O proxy de capital humano IA L(r,t) combina três sub-indicadores: licenciados STEM (OCDE), densidade de competências IA (LinkedIn Economic Graph) e certificações IA.¹⁹

Normalização do CACI e escolha do benchmark

O CACI bruto — calculado como $\text{CACI}(r) = F(r)^{0,40} \times L(r)^{0,20} \times R(r)^{0,15} / E(r)^{0,25}$ (Power Mode) — produz valores absolutos heterogêneos cuja interpretação direta é dificultosa. Em conformidade com a prática padrão em construção de indicadores compostos (Nardo et al., 2008; Saisana & Tarantola, 2002), procedemos a uma normalização min-max ao líder: o CACI normalizado de cada país é expresso como percentagem do CACI bruto dos Estados Unidos, de modo que $\text{CACI_norm}(\text{EUA}) = 100$ por construção.

Essa escolha de normalização é metodologicamente fundamentada em três argumentos. Primeiro, os Estados Unidos constituem um benchmark natural em razão de sua posição dominante nos quatro fatores do CACI: ~80% do compute de IA mundial instalado (Epoch AI, 2026), os custos energéticos industriais mais baixos entre as grandes economias da OCDE (US\$ 81,5/MWh vs. US\$ 184,7/MWh na França, US\$ 251,6/MWh na Alemanha — EIA/Eurostat, 2024), o maior PIB nominal, e um ecossistema de capital humano em IA sem equivalente (concentração dos laboratórios de fronteira, fluxos internacionais de talento). Segundo, a normalização

ao líder é a convenção estabelecida para os índices de competitividade relativa: o RCA de Balassa (1965), o GCI do WEF (Schwab, 2019) e o Competitive Industrial Performance Index da UNIDO procedem por ratio ao líder setorial ou nacional. Terceiro, essa normalização elimina as ambiguidades de interpretação dos valores absolutos e permite comparações temporais: um CACI França passando de 12 a 18 entre 2024 e 2028 significa uma recuperação parcial, mesmo que os valores brutos dos dois países tenham aumentado.

A consequência metodológica mais importante dessa normalização é a evidenciação de uma lacuna estrutural que os índices tradicionais dissimulam. O AI Preparedness Index do FMI (Cazzaniga et al., 2024) atribui pontuações de 0,85 (EUA) e 0,74 (França), ou seja, um ratio de 1,15:1 — sugerindo uma quase-paridade. O Tortoise Global AI Index produz diferenças similares. Porém, o CACI normalizado posiciona a França em ~29 e a Alemanha em ~40 numa escala onde os Estados Unidos = 100, ou seja, ratios de 3,4:1 e 2,5:1 respectivamente (Power Mode). Essa divergência não é contraditória: resulta do fato de que os índices multidimensionais (AIPI: 4 pilares, 28 indicadores; Tortoise: 3 pilares, 122 indicadores) agregam linearmente dimensões normativas (regulação, ética, publicações) que compensam aritmeticamente os déficits nos fatores materiais (compute, energia). O CACI, ao isolar esses fatores materiais, expõe o abismo físico que as métricas compostas diluem.

Essa propriedade do CACI — revelar a magnitude real do gap de compute — constitui a contribuição analítica central do índice e a tese empírica fundamental do presente estudo. A diferença no CACI não é um artefato da normalização: é o resultado científico.

2.4.4 Posicionamento face aos índices de competitividade IA existentes

O AI Preparedness Index do FMI (AIPI) cobre 174 países (2023) e agrega quatro pilares sem medir o compute instalado.²⁰ O Global AI Index da Tortoise Media (GAIL) classifica 83 países em 122 indicadores, mas dilui o sinal do compute. O Stanford AI Index (2025) fornece dados ricos mas não propõe índice composto.²¹

Valor acrescentado específico do CACI: (i) coloca o compute no centro; (ii) integra explicitamente o custo energético; (iii) utiliza agregação multiplicativa teoricamente fundamentada; (iv) é parcimonioso (quatro variáveis), transparente e reproduzível.

2.4.5 Limitações do CACI e análise de sensibilidade

Primeira limitação: opacidade de $F(r,t)$. O dataset Epoch AI cobre apenas 10–20% do compute mundial. Atenuação: documentamos margens de incerteza, apresentamos intervalos e verificamos a estabilidade dos resultados quando F varia $\pm 30\%$.

Segunda limitação: heterogeneidade qualitativa do compute. O CACI agrega FLOPs sem distinguir gerações de GPU. Atenuação: o dataset Epoch AI fornece equivalentes H100; propomos fator de ponderação em anexo.

Terceira limitação: o proxy de capital humano. Viés em favor de países anglófonos. Atenuação: replicamos a análise com o sub-índice Human Capital do AIPI como proxy alternativo.

Quarta limitação: estaticidade. Calculamos o CACI em vários anos (2022, 2024, 2026) e projetamo-lo em cada cenário.

Quinta limitação: endogeneidade. O choque exógeno dos controlos BIS de outubro 2022 oferece um quasi-experimento natural para uma estratégia de identificação

causal em Difference-in-Differences. Identificamos o tratamento formal desta endogeneidade (DiD, IV, ou GMM Arellano-Bond) como pista de investigação prioritária.²²

Apesar destas limitações, o CACI responde a uma necessidade identificada na literatura: não existe atualmente nenhum indicador formalizado de competitividade ajustada ao compute. A contribuição metodológica reside no framework mais do que na precisão dos números.

Sexta limitação: viés de normalização para pequenas economias (“small-economy bias”)

A análise comparativa do CACI com os índices FMI AIPI e Tortoise GAII revela uma anomalia instrutiva: certos países com PIB reduzido e força de trabalho em IA limitada obtêm scores CACI desproporcionalmente elevados, em descompasso radical com a sua classificação nos outros índices. O caso da África do Sul é emblemático: última ou penúltima nos índices FMI AIPI e Tortoise, aparece como líder mundial no CACI (score normalizado de 100, superior aos Estados Unidos).

Explicação mecânica. Este resultado contra-intuitivo explica-se inteiramente pela estrutura multiplicativa do denominador $PIB(r) \times L(r)$. A África do Sul apresenta um PIB relativamente modesto (~400 mil milhões de dólares) e uma força de trabalho em IA (L) muito reduzida. O denominador do CACI é, portanto, minúsculo. Paralelamente, o país dispõe de alguns clusters de compute (numerador F não nulo) e de eletricidade industrial entre as mais baratas do mundo (tarifas Eskom ~0,05–0,07 \$/kWh, apesar dos episódios de load-shedding), mantendo E^{-1} num nível elevado. A divisão de um numerador modesto mas não negligenciável por um denominador muito pequeno produz mecanicamente um score artificialmente inflacionado.

Diagnóstico metodológico. Este fenómeno é um caso clássico de *viés de normalização* identificado na literatura sobre indicadores compostos. O OECD/JRC Handbook (Nardo et al., 2008, pp. 27-29) alerta que a normalização pelo PIB ou pela população pode produzir resultados enganosos para pequenas economias: da mesma forma que o PIB per capita do Luxemburgo ou da Islândia não reflete uma «produtividade» superior à dos Estados Unidos, o CACI da África do Sul não reflete uma competitividade em IA superior. O problema é estrutural: na fórmula $CACI = F^{0.40} \times L^{0.20} \times R^{0.15} / E^{0.25}$ (Power Mode), um país pode obter um score elevado sem massa crítica de compute, simplesmente porque o seu denominador é suficientemente pequeno.²⁵

Estratégias de correção. Propomos três mecanismos de atenuação, por ordem crescente de intervenção:

(a) Limiar de massa crítica sobre F. Excluir do cálculo do CACI os países cuja capacidade de compute instalada $F(r)$ seja inferior a um limiar mínimo (por exemplo, os 20 primeiros países em FLOPs absolutos segundo o dataset Epoch AI, ou um limiar absoluto de 10.000 equivalentes H100). Este limiar garante que o CACI só é calculado para economias que atingiram uma massa crítica de compute suficiente para que o indicador seja significativo.

(b) Fator de escala (scaling factor). Introduzir um fator multiplicativo ligado à massa absoluta de compute: $CACI^*(r) = CACI(r) \times \alpha(r)$, onde $\alpha(r) = \min(1, F(r)/F_mediana)$. Este fator penaliza progressivamente os países cujo compute absoluto é inferior à mediana mundial, evitando as descontinuidades do limiar binário e corrigindo o viés.

(c) Dupla classificação (intensidade vs. escala). Apresentar sistematicamente o CACI sob duas formas: uma classificação em *intensidade* (CACI tal como definido, adaptado a comparações bilaterais EUA/UE/FR) e uma classificação em *escala* (F bruto, adaptado a comparações de potência absoluta). O índice Tortoise (2024) já utiliza esta distinção entre AI capacity (scale) e AI capacity (intensity). O CACI tal como definido corresponde a uma medida de intensidade e deve ser interpretado como tal.

No presente estudo, adotamos principalmente a solução (a): o CACI é calculado e discutido para os países que ultrapassam o limiar de massa crítica, e as comparações bilaterais concentram-se nas grandes economias (Estados Unidos, UE, França, China). Os resultados para economias menores (Brasil, África do Sul, Emirados, etc.) são apresentados a título indicativo, com a advertência explícita de que o viés de normalização os afeta. O caso do Brasil merece atenção particular: embora a sua economia seja substancialmente maior que a da África do Sul (~2,2 bilhões de dólares de PIB), o Brasil também apresenta uma força de trabalho em IA relativamente limitada face ao seu PIB, o que pode gerar alguma sobre-estimativa do CACI, embora numa magnitude inferior à da África do Sul. Esta transparência está conforme à recomendação do Handbook OECD/JRC de documentar sempre os casos em que o indicador produz resultados potencialmente enganosos.²⁶

2.5 Âmbito e delimitações

Âmbito geográfico. A análise concentra-se na relação bilateral EUA / UE, com foco específico na França. A China é tratada como variável contextual.

Âmbito temporal. O diagnóstico cobre 2020–2026, os cenários cobrem 2026–2030.

Âmbito tecnológico. O estudo cobre a IA de fronteira e os seus pré-requisitos materiais (GPU/ASIC, data centers, energia). Integra a robótica IA como fator amplificador da procura energética.

2.6 Limitações metodológicas gerais

Incerteza política radical. O protecionismo tecnológico depende de decisões políticas discricionárias. Propomos quatro cenários em vez de uma trajetória única.

Ruturas tecnológicas. O episódio DeepSeek (janeiro 2025) ilustra a possibilidade de ruturas de eficiência. A IEA (2025) conclui que mesmo com melhorias significativas, o crescimento da procura absorve os ganhos (efeito ricochete de Jevons).²³

Opacidade dos dados de compute. As nossas estimativas comportam margens de erro significativas, sistematicamente documentadas.

Viés das fontes de consultoria. Atenuamos por triangulação mas não podemos eliminar inteiramente.

Estas limitações não comprometem a validade da análise. O método de cenários é precisamente concebido para funcionar em ambientes de forte incerteza. Como sublinha Schwartz, «os cenários não são previsões; são histórias plausíveis que vos ajudam a refletir.»²⁴

Notas

- ¹ Schwartz, P. (1991), *The Art of the Long View*, New York, Doubleday. Ver também Wack, P. (1985), «Scenarios: Uncharted Waters Ahead», HBR, pp. 72-89.
- ² Bradfield, R. et al. (2005), «The Origins and Evolution of Scenario Techniques», *Futures*, 37(8), pp. 795-812.
- ³ Schoemaker, P.J.H. (1995), «Scenario Planning: A Tool for Strategic Thinking», *MIT Sloan Management Review*, 36(2), pp. 25-40.
- ⁴ Nardo, M. et al. (2008), *Handbook on Constructing Composite Indicators*, OECD Publishing, Paris.
- ⁵ O desvio SIA/McKinsey explica-se pelo perímetro: McKinsey inclui captive designers e fables não contabilizados nas estatísticas WSTS.
- ⁶ Pilz, K.F. et al. (2025), «Trends in AI Supercomputers», arXiv:2504.16026. Dataset acessível em <https://epoch.ai/data/gpu-clusters>.
- ⁷ Epoch AI (2025), GPU Clusters Documentation. Cobertura estimada: ~20–37% dos H100, ~12% dos A100, <4% dos TPU Google.
- ⁸ Lehdonvirta, V. et al. (2025), «Measuring Domestic Public Cloud Compute Availability for AI», *OECD AI Papers*, No. 49.
- ⁹ Van der Heijden, K. (2004), *Scenarios: The Art of Strategic Conversation*, 2nd ed., Wiley.
- ¹⁰ Schwartz (1991), op. cit., pp. 241-243.
- ¹¹ Hawkins, Z.J. et al. (2025), «AI Compute Sovereignty», SSRN. Sevilla, J. et al. (2022), «Compute Trends Across Three Eras», arXiv:2202.05924.
- ¹² Cazzaniga, M. et al. (2024), «Gen-AI: AI and the Future of Work», *IMF SDN* 2024/001.
- ¹³ Tortoise Media (2024), *Global AI Index 2024*. Ver Koronakos et al. (2024), *Expert Systems with Applications*.
- ¹⁴ Cohen, W.M. & Levinthal, D.A. (1990), «Absorptive Capacity», *ASQ*, 35(1), pp. 128-152.
- ¹⁵ Agregação geométrica também utilizada pelo IDH do PNUD desde 2010. Ver *OECD/JRC Handbook* (2008), pp. 31-33.
- ¹⁶ Epoch AI (2025), «The US Hosts the Majority of GPU Cluster Performance», junho 2025.
- ¹⁷ Código Python e dados reproduzíveis. CSV em https://epoch.ai/data/gpu_clusters.csv.
- ¹⁸ Federal Reserve Board (outubro 2025). IEA (2025), *Energy and AI*.
- ¹⁹ Viés LinkedIn documentado: subestimação mecânica em países onde LinkedIn é pouco utilizado.
- ²⁰ FMI (2024), *AI Preparedness Index Dashboard*.
- ²¹ Maslej, N. et al. (2025), *Stanford AI Index Report 2025*. Dados públicos via Google Drive.
- ²² Arellano, M. & Bond, S. (1991), «Some Tests of Specification for Panel Data», *RES*, 58(2), pp. 277-297.
- ²³ IEA (2025), *Energy and AI*, estudo de caso DeepSeek e efeito ricochete de Jevons.
- ²⁴ Schwartz (1991), op. cit., p. 38.
- ²⁵ O problema é análogo ao “efeito Singapura” nos índices de competitividade: pequenas economias abertas e especializadas (Singapura, Luxemburgo, Irlanda) dominam sistematicamente as classificações normalizadas pelo PIB ou população, não por serem estruturalmente superiores, mas porque o denominador amplifica o sinal. Ver Saisana, M. & Tarantola, S. (2002), *State-of-the-art Report on Current*

Methodologies and Practices for Composite Indicator Development, JRC European Commission, pp. 14-16.

²⁶ OECD/JRC Handbook (2008), pp. 27-29: “When normalising by GDP or population, users should be aware that small economies may obtain extreme values [...] Presenting both raw and normalised data is recommended.” A solução da dupla classificação (intensidade/escala) é também utilizada pela Tortoise Media (2024) no Global AI Index.

Licença e Aviso. Este trabalho, "America-First-IA", é disponibilizado sob os termos da Licença Creative Commons Atribuição-NaoComercial-CompartilhaIgual 4.0 Internacional (CC BY-NC-SA 4.0). Documento fornecido para fins educativos e de investigação.