

ESTUDO DE PESQUISA - FEVEREIRO DE 2026

AI FOR AMERICANS FIRST

Protecionismo de IA, Energia e Semicondutores: Trajetorias de Divergencia EUA/Europa 2024-2030

Analise geoestrategica e economica integrada - Capitulo II

**78,9 pct do compute IA
operacional mundial = EUA**

1,59x custo de energia UE/EUA

**3,64:1 razao CACI EUA/UE
(Power Mode)**

Fabrice Pizzi

Universite Paris-Sorbonne

Mestrado 2 Inteligencia Economica - Intelligence Warfare

Paris - fevereiro de 2026 | 7 capitulos | 4 cenarios prospectivos | 3 zonas geograficas

Palavras-chave: inteligencia artificial, protecionismo tecnologico, semicondutores, controles de exportacao, compute soberano, geopolitica da IA, Franca, Estados Unidos, China

CAPITULO II

Metodologia

2.1 Abordagem geral: analise prospectiva multi-cenario por metodo misto

Este estudo combina uma analise empirica retrospectiva (diagnostico 2020-2026) com uma projecao prospectiva por cenarios (2026-2030). Esta arquitetura em duas vertentes responde a natureza do fenomeno investigado: o protecionismo tecnologico em IA e simultaneamente um fato observavel (controles de exportacao, tarifas Secao 232) e um processo em curso cuja trajetoria futura depende de variaveis politicas discricionarias, das respostas estrategicas europeias e de desenvolvimentos tecnologicos parcialmente imprevisiveis.

O componente retrospectivo emprega um metodo quantitativo descritivo, baseado na agregacao e cruzamento de dados de fontes institucionais (AIE, SIA/WSTS, Eurostat, EIA), relatorios industriais (McKinsey, Deloitte, Epoch AI) e documentos regulatorios (Federal Register, BIS, Casa Branca). O objetivo e estabelecer uma base factual rigorosa e referenciada cobrindo tres dimensoes: consumo de energia dos data centers, mercado de semicondutores e capacidade de compute IA instalada por regiao.

O componente prospectivo apoia-se na tradicao do scenario planning conforme formalizada por Schwartz (1991) e praticada na Royal Dutch/Shell desde a decada de 1970.[1] Este metodo, pertencente a escola

Intuitive Logics (Bradfield et al., 2005), consiste em construir cenários plausíveis e internamente coerentes - não para prever o futuro, mas para explorar o espaço de possibilidades e avaliar a robustez de diferentes estratégias frente a desenvolvimentos ambientais divergentes.[2] É particularmente adequado a situações caracterizadas por alta incerteza política e tecnológica, onde os modelos econométricos clássicos atingem seus limites - precisamente o caso do protecionismo tecnológico em IA.

Justificativa da escolha metodológica. Três razões fundamentam a escolha do método de cenários em vez de modelagem econométrica pura. Primeiro, as variáveis analíticas-chave são em grande parte políticas e discricionárias: a decisão de um presidente americano de impor ou não cotas de GPU à Europa não pode ser modelada por uma função de regressão. Segundo, as interações entre as dimensões energética, tecnológica e geopolítica são não lineares e sistêmicas: uma restrição sobre GPUs pode, por efeitos em cascata, alterar fluxos de investimento energético, decisões de localização de data centers e a estrutura competitiva de setores inteiros. Terceiro, os dados disponíveis sobre compute instalado por região são parciais e heterogêneos: não existe banco de dados público unificado de FLOPs IA por país, tornando prematura uma calibração econométrica rigorosa.

O método escolhido combina, portanto, o rigor quantitativo do diagnóstico empírico (dados referenciados, séries temporais, razões mensuráveis) com a flexibilidade qualitativa da construção de cenários, no espírito do que Schoemaker (1995) chama de heurística disciplinada.[3] Os cenários não são previsões probabilísticas, mas narrativas estratégicas coerentes, cada uma baseada em pressupostos explícitos e desenvolvendo suas consequências por meio de métricas mensuráveis.

2.2 Fontes de dados: classificação e avaliação crítica

O estudo se baseia em três categorias de fontes, cuja confiabilidade e potenciais vieses devem ser explicitamente reconhecidos. Esta transparência metodológica está em conformidade com as recomendações do OECD/JRC Handbook on Constructing Composite Indicators (Nardo et al., 2008), que prescreve a documentação sistemática de fontes, suas limitações e seus vieses em qualquer construção de indicador composto.[4]

2.2.1 Fontes primárias (documentos oficiais e regulatórios)

Esta categoria inclui textos normativos ou institucionais: proclamações presidenciais (Secção 232), regras BIS (AI Diffusion Rule, Entity List), relatórios da AIE, publicações do Parlamento Europeu (EPRS), dados estatísticos oficiais (SIA/WSTS para semicondutores, Eurostat e EIA para energia, RTE para França). Essas fontes oferecem a maior confiabilidade factual, mas podem conter vieses de enquadramento institucional: a AIE tende a privilegiar cenários moderados, o Parlamento Europeu a enfatizar riscos para a soberania da UE.

2.2.2 Fontes acadêmicas e think tanks

Esta categoria inclui artigos com revisão por pares (Farrell e Newman, 2019; Bresnahan e Trajtenberg, 1995; Brynjolfsson et al., 2019; Mugge, 2024) e publicações de think tanks reconhecidos (Bruegel, Carnegie Endowment, CSIS, OCDE, Federal Reserve Board). Os primeiros fornecem fundamentação teórica robusta; os segundos oferecem análises políticas empiricamente fundadas, mas potencialmente influenciadas pela

orientacao ideologica de cada instituicao. Priorizamos o cruzamento de fontes de orientacoes diferentes (Bruegel / Carnegie / Fed) para limitar esse vies.

2.2.3 Fontes industriais e de consultoria

McKinsey, Deloitte, Accenture, Epoch AI e CFG Europe fornecem dados de mercado, projecoes setoriais e estimativas de capacidade indisponiveis em fontes publicas. Essas fontes apresentam um vies sistematico potencial: as consultorias tem interesse em amplificar tendencias (para justificar engajamentos de transformacao) e as estimativas de mercado sao frequentemente otimistas. Mitigamos esse vies triangulando os numeros com dados institucionais e sinalizando explicitamente as divergencias entre fontes. Por exemplo, as vendas de semicondutores em 2024 sao de 627,6 bilhoes de USD segundo a SIA (escopo tradicional), mas de 775 bilhoes de USD segundo a McKinsey (escopo ampliado), uma diferenca de 24 por cento refletindo diferencas metodologicas e nao inconsistencias.[5]

2.2.4 Dados de compute IA: o conjunto Epoch AI GPU Clusters

Medir o compute IA instalado por pais constitui o desafio metodologico central deste estudo. Apoiamo-nos primariamente no conjunto de dados Epoch AI GPU Clusters (Pilz, Rahman, Sanders e Heim, 2025), que cataloga mais de 500 supercomputadores e clusters GPU em todo o mundo para o periodo 2019-2025.[6] Este conjunto de dados, disponivel sob licenca aberta Creative Commons Atribuicao, constitui a fonte mais completa e sistematicamente documentada sobre infraestrutura global de compute IA ate hoje. E usado como referencia pelo Stanford AI Index Report (2025), por varios relatorios governamentais e por instituicoes como OpenAI e DeepMind.

O conjunto de dados cobre, para cada cluster: pais de localizacao, tipo de chip (H100, A100, GB200, TPU, etc.), desempenho computacional em FLOP/s 16 bits, numero de equivalentes H100, data operacional, setor (privado/publico), potencia eletrica (MW) e custo de hardware estimado. Essa granularidade permite a agregacao por pais e ano, atendendo diretamente as necessidades de nossa variavel $F(r)$ no CACI.

Limitacoes do conjunto Epoch AI. Tres limitacoes devem ser destacadas. Primeiro, a cobertura e estimada em 10-20 por cento do desempenho de compute IA agregado global (marco de 2025), com heterogeneidade significativa entre empresas e tipos de chip: aproximadamente 20-37 por cento dos NVIDIA H100, 12 por cento dos A100, mas menos de 4 por cento dos TPU Google e uma fracao desprezivel dos chips customizados de AWS, Microsoft ou Meta.[7] Segundo, os sistemas chineses sao anonimizados (nomes removidos, valores arredondados a um algarismo significativo), limitando a precisao analitica para a China. Terceiro, a localizacao fisica de um cluster nao determina o acesso: muitos clusters sao acessiveis via servicos cloud a partir de outros paises.

Complementamos esses dados com o Working Paper da OCDE de Lehdonvirta, Wu, Hawkins et al. (outubro de 2025), que desenvolve uma metodologia para estimar a disponibilidade de compute IA em cloud publico por pais, contando regioes cloud dos principais fornecedores equipadas com aceleradores IA (A100, H100, GB200) em 39 economias.[8] Essa abordagem complementar distingue compute instalado (Epoch AI) de compute acessivel (OCDE), uma distincao crucial para o CACI.

2.3 Construcao dos cenarios

A construcao dos cenarios segue um protocolo de quatro etapas, inspirado na metodologia da matriz 2x2 (Schwartz, 1991; van der Heijden, 2004) e adaptado ao contexto geoestrategico da IA.[9]

Etapla 1 - Identificacao das forcas motrizes. Os elementos predeterminados (cuja evolucao e razoavelmente previsivel independentemente do cenario) incluem: o crescimento continuo da demanda mundial de compute IA; o aumento estrutural do consumo de energia dos data centers; a dependencia europeia das fundicoes asiaticas e americanas para chips de ponta; a concentracao do cloud global em torno de tres hyperscalers americanos; e o aumento exponencial dos custos de treinamento de modelos de fronteira.

As incertezas criticas (cuja evolucao depende de escolhas politicas, reacoes estrategicas ou disrupcoes tecnologicas) sao agrupadas em duas dimensoes. Dimensao 1 - Intensidade do protecionismo tecnologico americano: esta dimensao cobre um espectro que vai da manutencao das restricoes atuais ao endurecimento agressivo (cotas GPU para a UE, restricoes a APIs e modelos, priorizacao explicita de entregas a empresas americanas). Dimensao 2 - Capacidade de resposta europeia: esta dimensao cobre um espectro que vai de uma postura passiva (adaptacao marginal, aceitacao da dependencia) a uma resposta ativa (Compute Zones com energia derogada, AI Factories aceleradas, SMR nucleares para data centers, parcerias alternativas Japao-Coreia-Taiwan, revisao do AI Act).

Etapla 2 - Matriz 2x2 e geracao de cenarios. O cruzamento das duas dimensoes de incerteza gera uma matriz de quatro cenarios. A escolha de quatro em vez de tres cenarios e deliberada. Schwartz (1991) e os praticantes do metodo Shell recomendam nunca construir tres cenarios, pois a mente humana tende a tratar o cenario mediano como o mais provavel, reduzindo a utilidade do exercicio.[10] A matriz 2x2 forca o analista a explorar quadrantes extremos - precisamente onde se desenrolam as rupturas estrategicas.

Etapla 3 - Desenvolvimento narrativo e quantificacao. Cada cenario e desenvolvido segundo um protocolo padronizado composto de tres componentes: uma narrativa estrategica descrevendo a sequencia plausivel de eventos entre 2026 e 2030; uma quantificacao de metricas-chave calibradas em dados empiricos 2020-2026 e projetadas conforme os pressupostos do cenario; e indicadores antecipados (leading indicators) que permitem identificar, a partir de 2026-2027, para qual cenario a realidade esta convergindo.

Etapla 4 - Analise de sensibilidade e robustez. Para cada recomendacao formulada no Capitulo VII, avaliamos sua robustez ao longo dos quatro cenarios. Uma recomendacao e considerada robusta se produz resultados positivos ou neutros em pelo menos tres dos quatro cenarios.

2.4 Metricas-chave e indicador original: o CACI

Definimos seis metricas a serem calculadas ou estimadas no diagnostico empirico (Capitulo III), e em seguida projetadas em cada cenario (Capitulo V). Em conjunto, formam um painel da divergencia EUA/UE em IA: M1 (compute gap, razao EUA/UE de FLOPs IA instalados normalizada pelo PIB), M2 (custo relativo do FLOP para treinamento), M3 (dependencia cloud, parcela de cargas IA UE em infraestrutura EUA), M4 (produtividade IA setorial), M5 (restricao energetica, razao demanda/capacidade dos data centers) e M6 (deslocalizacoes IA).

2.4.1 Fundamentos teóricos do CACI

Ancoragem na literatura. A construção de um indicador composto de competitividade IA centrado no compute responde a uma necessidade identificada por vários fluxos de pesquisa convergentes. Desde 2023-2024, a literatura acadêmica e institucional enfatiza cada vez mais que a capacidade computacional se tornou o fator de produção mais discriminante para a IA de fronteira (Sevilla et al., 2022; Epoch AI, 2025; Pilz et al., 2025). Os controles de exportação americanos (BIS, outubro de 2022; atualizações 2023 e 2025) colocam explicitamente o compute avançado no cerne da competição geopolítica, enquanto Hawkins, Lehdonvirta e Wu (2025) introduzem o conceito de soberania do compute como dimensão estruturante da autonomia estratégica.[11]

No entanto, os índices existentes de competitividade IA não colocam o compute no centro de sua construção. O AI Preparedness Index do FMI (Cazzaniga et al., 2024), cobrindo 174 países, agrega quatro dimensões (infraestrutura digital, capital humano, inovação/integração econômica, regulação/ética) sem medir diretamente a capacidade de compute instalada.[12] O Global AI Index da Tortoise Media (2024), classificando 83 países em 122 indicadores em três pilares (Implementation, Innovation, Investment), inclui um componente de infraestrutura/supercomputação, mas o subsume em um índice aditivo ponderado onde o compute é apenas um fator entre muitos.[13] O Stanford AI Index (2025) fornece dados ricos sobre tendências de compute, mas não propõe nenhum índice composto. Nenhum desses instrumentos formaliza o mecanismo pelo qual o compute, ajustado por seu custo energético e relacionado a capacidade de absorção de uma economia, determina a competitividade IA.

O CACI visa preencher essa lacuna propondo um indicador parcimonioso, mas teoricamente fundamentado, que captura a interação multiplicativa entre quatro fatores: compute acessível, força de trabalho relevante, condições de acesso geopolítico e custo energético.

2.4.2 Definição formal

O CACI para uma região r no período t é definido em dois modos complementares. Em Power Mode (absoluto): $CACI(r,t) = F(r,t)^{0,40} \times L(r,t)^{0,20} \times R(r,t)^{0,15} / E(r,t)^{0,25}$. Em Intensity Mode (por unidade de riqueza nacional): $CACI(r,t) = F(r,t)^{0,40} \times L(r,t)^{0,20} \times R(r,t)^{0,15} / (E(r,t)^{0,25} \times PIB(r,t))$.

$F(r,t)$ - capacidade de compute IA instalada e acessível na região r no período t . Agregamos o conjunto Epoch AI GPU Clusters por país, em equivalentes H100 (a métrica utilizada pelo Epoch AI), complementado por estimativas OCDE de compute cloud acessível. F admite duas especificações utilizadas em paralelo: F_{total} (todos os clusters localizados no território independentemente da propriedade, definindo o CACI físico) e F_{dom} (clusters possuídos e operados por atores domésticos, definindo o CACI soberano).

$L(r,t)$ - população em idade ativa com competências IA (proxy: graduados STEM mais formações IA certificadas mais densidade de competências IA pelo LinkedIn Economic Graph). Este fator captura a capacidade de absorção no sentido de Cohen e Levinthal (1990): compute abundante sem capital humano para explorá-lo não produz competitividade.[14]

$R(r,t)$ - índice de acesso geopolítico (entre 0 e 1) capturando a posição do país no regime de controles de exportação. $R = 1$ para os Estados Unidos (acesso ilimitado ao compute de fronteira), $R = 0,95$ para aliados

Tier-1 proximos (Reino Unido), $R = 0,9$ para a UE e a Franca (Tier-1 com restricoes seletivas), $R = 0,85$ para a India (Tier-2), $R = 0,7$ para a China (fortemente restrito).

$E(r,t)$ - custo energetico efetivo medio do compute na regioao r , em USD por MWh, ajustado pelos Power Purchase Agreements dos hyperscalers. Os valores de referencia do painel para o snapshot de abril de 2026 sao EUA 85, China 92, Franca 115, Alemanha 140, Reino Unido 190 USD por MWh. Estes numeros correspondem aos precos ajustados PPA efetivamente enfrentados pelos data centers, nao aos tarifas Eurostat industriais brutos (que sao tipicamente mais altos na Europa). Os custos efetivos UE neste escopo PPA-ajustado sao 1,4 a 1,7 vezes os niveis EUA.[15]

$PIB(r,t)$ - produto interno bruto da regioao r (Banco Mundial, Eurostat). Utilizado apenas em Intensity Mode para normalizar entre economias de tamanhos muito diferentes.

Justificativa da forma multiplicativa. A escolha de uma agregacao multiplicativa (geometrica) em vez de aditiva (aritmetica) e deliberada e repousa em tres argumentos. Primeiro, a teoria das General Purpose Technologies (Bresnahan e Trajtenberg, 1995) postula uma forte complementaridade entre os insumos de inovacao: compute sem energia acessivel ou sem capital humano qualificado nao produz ganhos de competitividade, justificando uma forma onde a fraqueza em um fator penaliza o conjunto. Segundo, o OECD/JRC Handbook (2008, p. 33) recomenda a agregacao geometrica quando os componentes nao sao perfeitamente substituiveis: ao contrario da media aritmetica, a media geometrica nao permite que um escore muito alto em uma dimensao compense plenamente um escore muito baixo em outra. Terceiro, trabalhos recentes sobre construcao de indices IA (Koronakos, Kritikos e Sotiros, 2024; analise do GAI Tortoise via integral de Choquet) confirmam que as dimensoes de competitividade IA apresentam interacoes (complementaridades e redundancias) que tornam problematica a agregacao linear simples.[16]

Interpretacao economica. Em forma logaritmica, o CACI em Intensity Mode pode ser escrito $\ln(CACI) = 0,40 \ln(F) + 0,20 \ln(L) + 0,15 \ln(R) - 0,25 \ln(E) - \ln(PIB)$. Esta transformacao lineariza a relacao e permite interpretar cada coeficiente como uma elasticidade. O indicador e concebido para a comparacao bilateral: a razao $CACI(EUA)/CACI(UE)$ mede a vantagem competitiva relativa. O snapshot de abril de 2026 produz uma razao de 3,64:1 em Power Mode (F_{total}) - este e o numero principal deste estudo.

2.4.3 Protocolo de calibracao e fontes de dados

A calibracao do CACI segue um protocolo de quatro etapas consistente com as recomendacoes do OECD/JRC Handbook (2008): identificacao e coleta de dados brutos; tratamento de valores ausentes e normalizacao; agregacao; e analise de sensibilidade.

$F(r,t)$ - Capacidade de compute IA instalada. A estimacao segue uma abordagem bottom-up. A camada principal vem do conjunto Epoch AI GPU Clusters (versao abril de 2026), fornecendo o desempenho em FLOP/s 16 bits e em equivalentes H100 agregado por pais para 2019-2026. As parcelas nacionais de compute operacional no snapshot de abril de 2026 sao: EUA 76,9 por cento, China 12,8 por cento, UE (13 economias principais) 4,4 por cento, Noruega 1,1 por cento, Japao 1,0 por cento.[17] Quando todos os clusters reportados sao includidos (operacionais mais planejados), a parcela EUA passa para cerca de 50 por cento, com o Golfo (EAU, Arabia Saudita) e a Coreia capturando uma grande parcela da construcao projetada 2027-

2030. A camada complementar vem da OCDE (Lehdonvirta et al., 2025), catalogando regiões cloud com aceleradores IA em 39 economias, capturando a dimensão de acessibilidade que o compute fisicamente instalado não reflete plenamente.

Procedimento de agregação de F. Para cada par país-ano, extraímos do conjunto Epoch AI a soma dos equivalentes H100 de todos os clusters localizados no país, filtrando os sistemas confirmados (certeza maior ou igual a Likely); aplicamos um fator de extrapolação para corrigir a sub-cobertura do conjunto (10 a 20 por cento do compute global), usando as estimativas de cobertura setorial do Epoch AI por tipo de chip; e adicionamos as capacidades cloud acessíveis estimadas via metodologia OCDE para países onde o compute cloud estrangeiro representa uma parcela significativa da capacidade efetiva. Os dados brutos e o código de cálculo (Python/pandas) estão documentados no apêndice metodológico e no painel público.[18]

$E(r,t)$ - Custo energético. Os valores de referência do CSV do painel utilizados ao longo deste estudo, em USD por MWh e ajustados PPA, são: EUA 85, China 92, França 115, Alemanha 140, Reino Unido 190, Índia 88. Estes números incorporam tarifas negociadas para grandes consumidores (PPAs hyperscalers), usando estimativas IEA (2025, Energy and AI) do mix energético dos data centers por região. São sistematicamente menores do que as tarifas Eurostat industriais brutas na Europa, porque os PPAs hyperscalers e o sourcing direto nuclear/renovável reduzem materialmente o custo efetivo enfrentado pelos data centers IA. O Federal Reserve Board (outubro de 2025) documenta uma correlação negativa significativa entre custos energéticos e adoção IA no nível das empresas europeias.[19]

$PIB(r,t)$ e $L(r,t)$. O PIB está disponível no Banco Mundial (World Development Indicators) e no Eurostat. O snapshot de abril de 2026 do painel utiliza valores de PIB em trilhões de USD: EUA 29,3; China 18,7; UE 18,9; França 3,16; Alemanha 4,68; Reino Unido 3,6. O proxy de capital humano IA $L(r,t)$ combina três sub-indicadores: número de graduados STEM (OCDE, Education at a Glance); densidade de competências IA medida pelo LinkedIn Economic Graph (perfis com competências IA em relação à população ativa); e certificações IA (estimativas baseadas em programas cloud certificados AWS/Google/Microsoft por país). O snapshot do painel utiliza, em milhões de trabalhadores qualificados em IA: EUA 3,5; China 4,8; UE 3,1; França 1,5; Alemanha 1,9; Reino Unido 1,8. Reconhecemos um vies favorecendo países de língua inglesa e economias onde o LinkedIn é dominante, e documentamos o efeito desse vies na análise de sensibilidade (seção 2.4.5).[20]

Normalização do CACI e seleção do benchmark. O CACI bruto produz valores absolutos heterogêneos cuja interpretação direta é difícil. Em conformidade com a prática padrão (Nardo et al., 2008; Saisana e Tarantola, 2002), aplicamos uma normalização min-max ao líder: o CACI normalizado de cada país é expresso como porcentagem do CACI bruto dos Estados Unidos, de modo que $CACI_norm(EUA) = 100$ por construção.

Esta escolha de normalização é metodologicamente fundamentada em três argumentos. Primeiro, os Estados Unidos constituem um benchmark natural dada sua posição dominante em todos os quatro fatores do CACI: 76,9 por cento do compute IA operacional global (Epoch AI, abril de 2026), os custos energéticos industriais efetivos mais baixos entre as principais economias da OCDE (85 USD/MWh, ajustado PPA, contra 115 na França e 140 na Alemanha - CSV do painel, abril de 2026), o maior PIB nominal e um ecossistema de capital humano IA inigualável. Segundo, a normalização ao líder é a convenção estabelecida para índices de

competitividade relativa: o RCA de Balassa (1965), o GCI do WEF (Schwab, 2019) e o Competitive Industrial Performance Index da UNIDO procedem todos por razão ao líder setorial ou nacional. Terceiro, esta normalização elimina ambiguidades interpretativas dos valores absolutos e permite comparações temporais: um CACI da França passando de 25 para 35 entre 2024 e 2028 significa recuperação parcial, mesmo se os valores brutos de ambos os países tiverem aumentado.

A consequência metodológica mais importante desta normalização é a revelação de uma diferença estrutural que os índices tradicionais ocultam. O AI Preparedness Index do FMI (Cazzaniga et al., 2024) atribui escores de 0,85 (EUA) e 0,74 (França), uma razão de 1,15:1, sugerindo quase paridade. O Global AI Index da Tortoise produz diferenças similares. No entanto, o CACI normalizado em Power Mode coloca a França em cerca de 25 e a Alemanha em cerca de 5 em uma escala onde os Estados Unidos = 100, ou seja, razões respectivas de 4:1 e 19:1. A razão principal EUA/UE (UE agregada como 13 economias principais) é de 3,64:1. Esta divergência não é contraditória: resulta do fato de que os índices multidimensionais agregam linearmente dimensões normativas (regulação, ética, publicações) que compensam aritmeticamente os déficits em fatores materiais (computo, energia). O CACI, ao isolar esses fatores materiais, expõe o abismo físico que as métricas compostas em média apagam.

Esta propriedade do CACI - revelar a verdadeira magnitude do *compute gap* - constitui a contribuição analítica central do índice e a tese empírica fundamental deste estudo. A diferença CACI não é um artefato de normalização: é o resultado científico.

2.4.4 Posicionamento em relação aos índices existentes de competitividade IA

O AI Preparedness Index (AIPI) do FMI cobre 174 países (2023) e agrega quatro pilares: infraestrutura digital, capital humano e políticas do mercado de trabalho, inovação e integração econômica, regulação e ética. O AIPI não mede o *compute IA* instalado e não pondera pelo custo energético. Sua correlação esperada com o CACI é positiva, mas imperfeita: países bem classificados no AIPI (Singapura, Dinamarca, Países Baixos) não são necessariamente aqueles com o *compute* efetivo por unidade de PIB mais alto.[21]

O Global AI Index (GAI) da Tortoise Media classifica 83 países em 122 indicadores em três pilares (Implementation, Innovation, Investment). Inclui um componente de infraestrutura/supercomputação, mas o agrega linearmente com pesos subjetivos (reconhecido pela Tortoise como uma limitação). O GAI é mais amplo e mais multidimensional do que o CACI, mas precisamente por ser amplo, dilui o sinal do *compute* em um composto de muitos indicadores. Como mostram Koronakos et al. (2024), a subjetividade das ponderações do GAI pode inverter classificações de países dependendo dos cenários de ponderação escolhidos.

O Stanford AI Index (2025) constitui a referência mais completa em termos de dados brutos (modelos notáveis por país, investimento, publicações, patentes, tendências de *compute*). Não propõe um índice composto, mas fornece as séries temporais usadas por muitos outros índices. Os dados públicos do Stanford AI Index estão disponíveis via uma pasta Google Drive aberta.[22]

Valor agregado específico do CACI. O CACI distingue-se por quatro propriedades: coloca o *compute* no centro em vez de na periferia do indicador, refletindo o papel agora dominante do *compute* na IA de

fronteira; integra explicitamente o custo energetico como gargalo, consistente com as conclusões da IEA (2025); usa uma agregação multiplicativa teoricamente fundamentada em vez de aditiva; e é parcimonioso (quatro variáveis), tornando-o transparente e reproduzível, ao custo de menor abrangência.

2.4.5 Limitações do CACI e análise de sensibilidade

Primeira limitação - opacidade de $F(r,t)$. A medição do compute instalado depende de dados privados incompletos. O conjunto Epoch AI cobre apenas 10-20 por cento do compute global, com cobertura desigual entre setores e empresas. A atribuição nacional é ela mesma discutível: uma parcela crescente do compute é detida por alguns hyperscalers privados operando globalmente. Mitigação: documentamos sistematicamente as margens de incerteza, apresentamos intervalos em vez de valores pontuais e verificamos a estabilidade dos resultados quando F varia em mais ou menos 30 por cento. A decomposição Físico/Soberano trata parcialmente o problema de atribuição.

Segunda limitação - heterogeneidade qualitativa do compute. O CACI agrega FLOPs sem distinguir gerações de GPU (um H200 não equivale a um A100 em eficiência energética e desempenho real). Mitigação: o conjunto Epoch AI fornece o desempenho em equivalentes H100, oferecendo uma normalização parcial. Propomos um fator de ponderação por geração de GPU no apêndice e mostramos que o ajuste modifica marginalmente as classificações.

Terceira limitação - o proxy de capital humano $L(r,t)$. A combinação STEM mais LinkedIn mais certificações apresenta um vies favorecendo os países de língua inglesa. Este vies provavelmente subestima a China e algumas economias asiáticas. Mitigação: replicamos a análise usando o sub-índice Human Capital do AIPI do FMI como proxy alternativo e mostramos a sensibilidade das classificações a esta escolha.

Quarta limitação - estaticidade do indicador. O CACI mede um estado em um momento dado, não uma dinâmica. É por isso que o calculamos em vários anos (2022, 2024, 2026) e o projetamos em cada cenário, permitindo o acompanhamento da trajetória e a avaliação da evolução da diferença.

Quinta limitação - endogeneidade. Os países que ganham produtividade IA investem maciamente em compute, criando um risco de causalidade reversa: o CACI poderia capturar a consequência em vez da causa da competitividade. Este estudo, em seu marco de tese, não instrumentaliza formalmente essa relação (sem variáveis instrumentais ou estratégia GMM). No entanto, observamos que o choque exógeno das regras BIS de outubro de 2022 oferece um quase-experimento natural que poderia fundamentar uma estratégia de identificação causal em Difference-in-Differences. Identificamos o tratamento formal dessa endogeneidade (DiD, IV ou GMM Arellano-Bond) como uma via de pesquisa prioritária para qualquer extensão publicável deste trabalho.[23]

Sexta limitação - vies de normalização para pequenas economias. A análise comparativa do CACI face aos índices AIPI do FMI e GAI da Tortoise revela uma anomalia instrutiva: certos países com baixo PIB e força de trabalho IA reduzida obtêm escores CACI desproporcionalmente altos. A África do Sul é emblemática: classificada em último ou penúltimo lugar nos índices AIPI e Tortoise, pode aparecer como líder global no CACI em Intensity Mode quando a normalização pelo PIB amplifica um efeito de pequeno denominador. Este fenômeno é um caso clássico de vies de normalização identificado na literatura de indicadores compostos. O

OECD/JRC Handbook (Nardo et al., 2008, pp. 27-29) adverte que a normalizacao por PIB ou populacao pode produzir resultados enganosos para pequenas economias. Nossa mitigacao e tripla: um limiar de massa critica em F (excluindo economias abaixo de 10 000 equivalentes H100); um fator de escala $\alpha(r) = \min(1, F(r) / F_{\text{mediano}})$ para testes de sensibilidade; e uma classificacao dupla (Power Mode para potencia absoluta, Intensity Mode para densidade), com a ressalva explicita de que as comparacoes bilaterais neste estudo se concentram em EUA, UE, Franca e China.[24]

2.4.6 Numeros reproduzíveis - snapshot de abril de 2026

Para permitir ao leitor refazer o calculo a partir dos CSVs do painel publico, expomos aqui as entradas e saidas utilizadas ao longo deste estudo. As quatro variaveis de entrada sao provenientes da pasta de dados do painel (energy_prices.csv, gdp_data.csv, workforce_data.csv, gpu_clusters.csv) em <https://mo0ogly.github.io/America-First-IA/dashboard/data/>.

Entradas (snapshot de abril de 2026). EUA: $F_{\text{total}} = 39,65$ milhoes de equiv. H100, $L = 3,5$ milhoes, $R = 1,00$, $E = 85$ USD/MWh, PIB = 29,3 trilhoes USD. UE (13 economias principais agregadas): $F_{\text{total}} = 2,62$ milhoes de equiv. H100, $L = 3,1$ milhoes, $R = 0,90$, $E = 135$ USD/MWh, PIB = 18,9 trilhoes USD. Franca: $F_{\text{total}} = 2,44$ milhoes de equiv. H100, $L = 1,5$ milhoes, $R = 0,90$, $E = 115$ USD/MWh, PIB = 3,16 trilhoes USD. Alemanha: $F_{\text{total}} = 0,05$ milhao de equiv. H100, $L = 1,9$ milhoes, $R = 0,90$, $E = 140$ USD/MWh, PIB = 4,68 trilhoes USD. China: $F_{\text{total}} = 0,40$ milhao de equiv. H100, $L = 4,8$ milhoes, $R = 0,70$, $E = 92$ USD/MWh, PIB = 18,7 trilhoes USD.

Saidas (Power Mode F_{total} , normalizadas em EUA = 100). EUA = 100,0; UE(13) = 27,5; Franca = 25,3; India = 22,2; China = 15,7; Reino Unido = 7,0; Alemanha = 5,4. EAU = 55,7 em CACI Fisico mas apenas 6,0 em CACI Soberano (F_{dom} restrito a clusters detidos por entidades domesticas G42, MGX, Mubadala, Khazna, TII), ilustrando a decomposicao Fisico/Soberano: 99,6 por cento do F_{total} dos EAU e detido por atores US-side (Stargate UAE, Microsoft, OpenAI). Razoes principais: EUA/UE(13) = 3,64:1; EUA/Franca = 3,96:1; EUA/Alemanha = 18,59:1; EUA/China = 7,46:1.

Estas saidas sao reproduzidas ao vivo no painel publico. Qualquer atualizacao subsequente do painel (novos clusters, revisoes energeticas, atualizacao do PIB) atualizara mecanicamente os numeros; a metodologia nao muda. A razao de 3,64:1 em Power Mode F_{total} reportada na capa e ao longo deste estudo corresponde exatamente a este snapshot.

2.5 Escopo e delimitacoes

Escopo geografico. A analise concentra-se na relacao bilateral Estados Unidos / Uniao Europeia, com foco especifico na Franca. A China e tratada como variavel contextual (alvo principal dos controles de exportacao americanos, fator de pressao sobre as capacidades de producao de chips), mas nao e objeto de analise aprofundada. Japao, Coreia do Sul e Taiwan aparecem como atores da cadeia de suprimentos de semicondutores.

Escopo temporal. O diagnostico cobre 2020-2026, os cenarios cobrem 2026-2030. O horizonte 2030 e escolhido porque corresponde a convergencia de varios prazos: projecoes da AIE para a energia dos data

centers, maturidade esperada do EU Chips Act, objetivos da SNIA Franca 2030 e chegada potencial dos primeiros SMR nucleares operacionais.

Escopo tecnologico. O estudo cobre a IA de fronteira (modelos fundacionais, intensivos em compute) e seus pre-requisitos materiais (GPU/ASIC, data centers, energia). Integra a robotica IA como fator amplificador da demanda energetica. Nao trata da IA embarcada edge (smartphones, IoT), exceto na medida em que constitui um objetivo especifico da SNIA francesa.

2.6 Limitacoes metodologicas gerais

Incerteza politica radical. O protecionismo tecnologico depende de decisoes politicas discricionarias com previsibilidade estruturalmente baixa. Uma mudanca de administracao americana em 2028, um acordo comercial UE-EUA inesperado ou uma escalada do conflito EUA-China poderia invalidar certos pressupostos. E precisamente por isso que propomos quatro cenarios em vez de uma trajetoria unica.

Disrupcoes tecnologicas. O episodio DeepSeek (janeiro de 2025), em que um modelo chines alcançou desempenho proximo da fronteira com orcamento de treinamento substancialmente reduzido, ilustra a possibilidade de avancos de eficiencia que alterariam os termos do problema. A IEA (2025, Energy and AI) dedica um estudo de caso ao DeepSeek e conclui que mesmo com melhorias significativas de eficiencia, o crescimento da demanda absorve os ganhos (efeito rebote de Jevons).[25]

Opacidade dos dados de compute. O numero exato de GPUs implantadas por hyperscaler, a distribuicao geografica precisa dos data centers e os volumes de GPUs exportados por regioao sao dados parcial ou totalmente confidenciais. Nossas estimativas de compute instalado carregam margens de erro significativas, que documentamos sistematicamente.

Vies das fontes de consultoria. Como observado na secao 2.2, as fontes industriais carregam um vies sistematico de otimismo. Mitigamos isso por meio da triangulacao, mas nao podemos elimina-lo inteiramente.

Estas limitacoes nao comprometem a validade da analise. O metodo dos cenarios e precisamente concebido para funcionar em ambientes de alta incerteza, onde o objetivo nao e a previsao, mas a exploracao estruturada das possibilidades. Como observa Schwartz, os cenarios nao sao previsoes; sao historias plausiveis que ajudam a pensar.[26] Nossa contribuicao reside no rigor do enquadramento, na explicitacao dos pressupostos, na transparencia das fontes de dados e na originalidade do indicador CACI, em vez de na precisao das projecoes numericas.

Notas

1. Schwartz, P. (1991), *The Art of the Long View: Planning for the Future in an Uncertain World*, New York, Doubleday. See also Wack, P. (1985), 'Scenarios: Uncharted Waters Ahead,' *Harvard Business Review*, Sept.-Oct. 1985, pp. 72-89.
2. Bradfield, R., Wright, G., Burt, G., Cairns, G. and Van Der Heijden, K. (2005), 'The Origins and Evolution of Scenario Techniques in Long Range Business Planning,' *Futures*, 37(8), pp. 795-812.
3. Schoemaker, P.J.H. (1995), 'Scenario Planning: A Tool for Strategic Thinking,' *MIT Sloan Management Review*, 36(2), pp. 25-40.

4. Nardo, M., Saisana, M., Saltelli, A. and Tarantola, S. (2008), *Handbook on Constructing Composite Indicators: Methodology and User Guide*, OECD Publishing, Paris.
5. The SIA/McKinsey gap is explained by scope: McKinsey (January 2026, 'Hiding in Plain Sight') includes the value of captive designers (Apple, Amazon, Tesla) and fabless operators whose sales do not appear in WSTS statistics.
6. Pilz, K.F., Rahman, R., Sanders, J. and Heim, L. (2025), 'Trends in AI Supercomputers,' arXiv:2504.16026, April 2025. Dataset accessible at <https://epoch.ai/data/gpu-clusters> under Creative Commons Attribution licence.
7. Epoch AI (2025), GPU Clusters Documentation. Coverage estimated at 20-37 percent of NVIDIA H100s, 12 percent of A100s and 18 percent of AMD MI300X, but less than 4 percent of Google TPUs.
8. Lehdonvirta, V., Wu, B., Hawkins, Z.J., Caira, C. and Russo, L. (2025), 'Measuring Domestic Public Cloud Compute Availability for Artificial Intelligence,' OECD AI Papers No. 49, <https://doi.org/10.1787/8602a322-en>.
9. Van der Heijden, K. (2004), *Scenarios: The Art of Strategic Conversation*, 2nd ed., Chichester, Wiley.
10. Schwartz (1991), op. cit., pp. 241-243.
11. Hawkins, Z.J., Lehdonvirta, V. and Wu, B. (2025), 'AI Compute Sovereignty,' SSRN, June 2025, <https://ssrn.com/abstract=5312977>. Sevilla, J. et al. (2022), 'Compute Trends Across Three Eras of Machine Learning,' arXiv:2202.05924.
12. Cazzaniga, M. et al. (2024), 'Gen-AI: Artificial Intelligence and the Future of Work,' IMF Staff Discussion Note 2024/001. The AI Preparedness Index is accessible via the IMF dashboard.
13. Tortoise Media (2024), *The Global Artificial Intelligence Index 2024*. See also Koronakos, G., Kritikos, M. and Sotiros, D. (2024), 'Mitigating Subjectivity and Bias in AI Development Indices,' *Expert Systems with Applications*.
14. Cohen, W.M. and Levinthal, D.A. (1990), 'Absorptive Capacity: A New Perspective on Learning and Innovation,' *Administrative Science Quarterly*, 35(1), pp. 128-152.
15. Effective costs are derived from the dashboard `energy_prices.csv` and reflect PPA-adjusted prices. Raw Eurostat industrial tariffs in Europe (consumption band IE) can be 1.5 to 2 times higher; the gap between raw and effective prices is documented in Chapter III. The Federal Reserve Board (October 2025) documents a significant negative correlation between energy costs and AI adoption at the European firm level.
16. Geometric aggregation is also used by the UNDP Human Development Index since 2010, for analogous reasons of non-substitutability between dimensions. See OECD/JRC Handbook (2008), pp. 31-33.
17. Operational shares computed by aggregating Epoch AI clusters with status Existing/Operational/Online/In progress on the April 2026 snapshot.
18. The Python code and data are reproducible. The Epoch AI dataset is downloadable in CSV at https://epoch.ai/data/gpu_clusters.csv (daily refresh). The dashboard CSVs are mirrored at <https://mo0ogly.github.io/America-First-IA/dashboard/data/>.
19. The LinkedIn bias is documented: in countries where LinkedIn is rarely used (China, Russia, some Southeast Asian economies), AI skills density is mechanically underestimated.
20. IMF (2024), *AI Preparedness Index Dashboard*. Singapore, Denmark, Netherlands and the US occupy top positions; China ranks 31st (score 0.63).
21. Maslej, N. et al. (2025), 'Artificial Intelligence Index Report 2025,' Stanford Institute for Human-Centered AI, April 2025.
22. Tortoise Media (2024), op. cit. Stanford AI Index public data: open Google Drive folder.
23. The most promising causal identification strategy would exploit the exogenous shock of the October 2022 BIS rules in a Difference-in-Differences framework. See Arellano, M. and Bond, S. (1991), 'Some Tests of Specification for Panel Data,' *Review of Economic Studies*, 58(2), pp. 277-297.
24. OECD/JRC Handbook (2008), pp. 27-29. The dual ranking solution (intensity / scale) is also used by Tortoise Media (2024) in the *Global AI Index*. Saisana, M. and Tarantola, S. (2002), *State-of-the-art Report on Current Methodologies and Practices for Composite Indicator Development*, JRC European Commission, pp. 14-16.
25. IEA (2025), *Energy and AI*, devotes a case study to DeepSeek and concludes that even with significant efficiency improvements, demand growth absorbs gains (Jevons rebound effect).
26. Schwartz (1991), op. cit., p. 38. Author translation.

Licença e isenção de responsabilidade. Esta obra, 'AI for Americans First', é disponibilizada nos termos da Licença Creative Commons Atribuição - NãoComercial - Compartilhável 4.0 Internacional (CC BY-NC-SA 4.0) do projeto America-First-IA.

Você é livre para compartilhar e adaptar o material para fins não comerciais, desde que credite adequadamente a obra a Fabrice Pizzi (Universidade Paris-Sorbonne) e distribua suas contribuições sob a mesma licença. Este documento é fornecido apenas para fins educacionais e de pesquisa.

Painel público: <https://mo0ogly.github.io/America-First-IA/dashboard/>

Repositório: <https://github.com/mo0ogly/America-First-IA>

AI for Americans First - Fabrice Pizzi - Capítulo II